

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para clasificación retrospectiva de multifatalidad (ONSV 2021–2025)

Rendo Alfonde Tarqui
Yimmy Yeyson Cuyo Zamata

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una red neuronal para clasificar retrospectivamente siniestros viales ya fatales según hayan dejado uno o dos o más fallecidos. La fuente oficial ONSV 2021–2025 contiene 9 104 registros útiles y una prevalencia multifatal de 10.19 %. El protocolo canónico bloquea la mezcla cronológica: entrenamiento en 2021–2022 (4872 registros), selección y calibración exclusivamente en 2023 (2 000), y evaluación de referencia en 2024–2025 (2 232).

El proyecto se desarrolló en dos versiones documentadas. La versión 1, con 162 características derivadas únicamente del registro de siniestros, alcanzó PR-AUC 0.2249 y ROC-AUC 0.7482 en la referencia, sin diferencia significativa frente a la regresión logística. La versión 2 incorporó las bases *companion* oficiales del ONSV, agregando doce variables de escena bajo las mismas reglas anti-fuga. Con 175 características, la búsqueda predeklarada de tres configuraciones completas por tres semillas eligió MLP_32_16 con semilla 314.

En la referencia 2024–2025, la MLP calibrada obtuvo PR-AUC 0.4416 [IC 95 %: 0.3785–0.5124], ROC-AUC 0.8841 [0.8613–0.9055], F1 multifatal 0.5058, precisión 0.4452, *recall* 0.5856, Brier 0.0683 y ECE 0.0169. El salto frente a la versión 1 y el dominio SHAP de personas involucradas respaldan fuertemente la hipótesis informacional, sin demostrar causalidad porque cambian variables y configuración y existe una segunda consulta a la referencia. La MLP supera significativamente a la regresión logística en ROC-AUC; frente al Random Forest no se detectó diferencia significativa, lo que no equivale a demostrar igualdad.

Una auditoría *validation-only* muestra que el ensemble de tres semillas mejora nominalmente PR-AUC, pero todos sus intervalos pareados incluyen cero; se mantiene una sola MLP congelada. La regla simple $n_{\text{personas}} \geq 4$ alcanza F1 similar, pero la MLP la supera en PR-AUC y ROC-AUC en una comparación histórica post-hoc. La disponibilidad de los campos *companion* al instante exacto de notificación no está demostrada; el alcance es retrospectivo.

La interfaz Streamlit consume un *bundle* de solo lectura con hashes verificados, explica el flujo 26 campos→175 features→MLP→Platt→clase, incluye cinco escenarios y presenta las auditorías del diseño. El sistema constituye una demostración académica reproducible de clasificación retrospectiva de multifatalidad.

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica desde 2021 una base a nivel de registro de todos los siniestros fatales del país, con variables de contexto pre-impacto que los registros administrativos anteriores no incluían: zona rural/urbana, red vial, condición climática, característica de la vía (recta, curva, intersección), perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?* La consigna del curso pide una red neuronal para predicción o clasificación con un dataset de la región o a nivel nacional, acompañada de análisis exploratorio, preprocesamiento, ingeniería de características, una interfaz gráfica y un informe. En rigor técnico, el problema abordado es de **clasificación binaria** multifatal/letalidad-simple: la salida es una categoría discreta, y al clasificarla el modelo también produce una probabilidad de siniestro multifatal, lo que cubre ambos términos de la consigna con precisión.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, con al menos ocho hallazgos interpretados.
- **OE2.** Construir al menos doce características derivadas de las variables pre-impacto del registro, cada una justificada.
- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier` (clase mayoritaria), regresión logística y *random forest*. El MLP debe superar claramente al `DummyClassifier`; si no supera a la regresión logística o al *random forest*, se reporta y discute honestamente.
- **OE4.** Identificar los cinco factores de mayor influencia en la alta letalidad mediante SHAP.
- **OE5.** Desplegar una interfaz gráfica en Streamlit que reutilice el pipeline de entrenamiento sin discrepancias.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello se fijaron las métricas antes de ver los datos, como hace un profesional:

- Selección de configuración completa: **mayor mediana de PR-AUC en validación 2023 entre semillas**; desempates por mayor F1 mediana y, después, menor IQR de PR-AUC. Cada configuración combina capas, dropout, L2 y tasa de aprendizaje.
- Métricas de reporte obligatorio: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* solo como referencia.
- Se prohíbe argumentar calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Selección de umbral: máximo F1 en validación, con desempates predeclarados por *recall*, precisión y mayor umbral; no se ajusta después de observar 2024–2025.

3. Marco teórico

3.1. Seguridad vial y alcance condicional

La severidad vial es multifactorial: interactúan infraestructura, condiciones ambientales, vehículo, conductor y respuesta posterior. La base ONSV utilizada registra exclusivamente siniestros con al menos un fallecido; por ello, el modelo no estima ocurrencia ni fatalidad general. Su pregunta es condicional: *dado un siniestro fatal ya registrado, ¿pertenece a la clase de uno o de dos o más fallecidos?* La extracción no contiene timestamps por variable que permitan afirmar disponibilidad operativa al instante de notificación; el alcance defendible es retrospectivo [6, 10].

3.2. Perceptrón multicapa

Una neurona calcula $a = f(Wx + b)$. Un perceptrón multicapa (MLP) encadena capas densas y aprende relaciones no lineales mediante retropropagación [1]. El artefacto canónico contiene **dos capas ocultas** y una capa de salida; durante inferencia, cuando *dropout* está desactivado, su composición es:

$$\hat{y} = \sigma(W_3 f(W_2 f(W_1 x + b_1) + b_2) + b_3),$$

donde f es ReLU y σ es sigmoide. Durante entrenamiento se intercala *dropout* después de **cada** capa oculta. La salida sigmoide es un *score* crudo; no debe llamarse probabilidad operacional hasta evaluar su calibración.

En el paso hacia adelante, ReLU anula activaciones negativas y conserva las positivas; la sigmoide acota la salida entre cero y uno. En el paso hacia atrás, la regla de la cadena propaga el gradiente de la pérdida desde la salida hacia W_3 , W_2 y W_1 ; Adam combina medias móviles del gradiente y de su cuadrado para actualizar cada parámetro. La función objetivo completa es entropía cruzada binaria ponderada más la penalización L2 de los dos kernels ocultos:

$$\mathcal{J} = -\frac{1}{N} \sum_{i=1}^N [w_1 y_i \log \hat{y}_i + w_0 (1 - y_i) \log (1 - \hat{y}_i)] + \lambda (\|W_1\|_2^2 + \|W_2\|_2^2), \quad \lambda = 10^{-4}.$$

Se usó Adam con tasa inicial 1×10^{-3} , lotes de 64, pesos de clase, *dropout* 0.25 después de ambas capas ocultas, regularización L2 de 1×10^{-4} sobre sus kernels y parada temprana por PR-AUC de validación [4, 9, 8]. No se aplicó L2 a los sesgos ni a la capa de salida.




Figura 1: Arquitectura y flujo del modelo definitivo. Azul: capas con parámetros entrenables; ámbar: regularización exclusiva del entrenamiento; verde: calibración posterior y externa a la red.

Tabla 1: Dimensiones y parámetros entrenables de la red canónica.

Elemento	Salida	Activación	Regularización	Parámetros
Entrada	175	—	—	0
Dense oculta 1	32	ReLU	L2 kernel 10^{-4}	$(175 + 1) \times 32 = 5\,632$
Dropout 1	32	—	tasa 0.25	0
Dense oculta 2	16	ReLU	L2 kernel 10^{-4}	$(32 + 1) \times 16 = 528$
Dropout 2	16	—	tasa 0.25	0
Dense de salida	1	Sigmoide	ninguna	$(16 + 1) \times 1 = 17$
Total entrenable				6 177

Fundamento de la forma 32–16. Con 4872 registros de entrenamiento y 175 entradas tabulares, una red compacta limita capacidad innecesaria y facilita regularización y auditoría. La forma decreciente 32–16 comprime gradualmente las variables y permite

aprender interacciones no lineales antes de la decisión binaria; ReLU aporta una transformación eficiente y la sigmoide produce el score de la clase positiva. No se asumió que esta forma fuera universalmente óptima: perteneció a la configuración completa ganadora de una grilla cerrada de tres configuraciones y tres semillas, con 6 177 parámetros entrenables, mediante la regla robusta declarada en la metodología.

3.3. Evaluación bajo desbalance

La clase multifatal representa alrededor del 10 %, por lo que la exactitud aislada es insuficiente. Se reportan precisión, *recall*, F1, PR-AUC, ROC-AUC, matriz de confusión e intervalos bootstrap. PR-AUC debe leerse contra la prevalencia: un clasificador sin capacidad de ordenamiento obtiene aproximadamente la tasa positiva.

El umbral transforma scores en clases. La política canónica maximiza F1 en validación y desempata por *recall*, precisión y mayor umbral. La salida cruda y la calibrada pertenecen a escalas distintas: el umbral 0.80 solo corresponde al score sigmoide, mientras que 0.30 solo corresponde a la probabilidad Platt.

3.4. Calibración probabilística

La calibración pregunta si, entre grupos de casos con probabilidad predicha cercana a p , la frecuencia observada también se aproxima a p ; no promete coincidencia caso por caso. Se evalúa con Brier, ECE y curva de confiabilidad. Platt transforma el score crudo s como $p_{\text{cal}} = \sigma(a \logit(s) + b)$; isotónica aprende una función monótona por tramos. Ambos métodos se compararon con predicciones *out-of-fold* de cinco particiones exclusivamente en validación 2023, siguiendo implementaciones reproducibles de scikit-learn [7]. La calibración puede mejorar Brier y ECE, pero, si conserva el orden, no cambia PR-AUC ni ROC-AUC.

3.5. Control de fuga y reproducibilidad

Se aplicaron tres barreras:

1. Las columnas de resultado (fallecidos, lesionados y vehículos dañados), causa post-investigación y señales con faltantes dependientes del periodo no entran al modelo.
2. Escalador, codificadores y frecuencias de vía se ajustan solo con 2021–2022. Configuración completa, semilla, calibración y umbrales se seleccionan solo con 2023.
3. Los resultados 2024–2025 ya fueron observados; quedan congelados como referencia histórica y no autorizan nuevos ajustes.

Semillas, versiones, hashes, esquema y artefactos se registran en el manifiesto canónico `manifest.json`.

3.6. Interpretabilidad con Gradient SHAP

SHAP distribuye el cambio del score entre las variables respecto de un fondo [5]. Se aplicó `shap.GradientExplainer` al score crudo de la MLP con 256 registros de fondo de entrenamiento 2021–2022 y 512 registros explicados de validación 2023. Las 175 características procesadas se agregaron en 20 grupos interpretables. La contribución firmada media no es un efecto monotónico, una recomendación de intervención ni evidencia causal.

4. Metodología

4.1. Diseño experimental definitivo

El proyecto sigue CRISP-DM con una separación cronológica estricta. Este corte es el mecanismo definitivo para medir deriva entre periodos y bloquear el uso de información futura.

Tabla 2: Particiones y usos permitidos del protocolo canónico.

Partición	Periodo	n	Positivos	Uso autorizado
Entrenamiento	2021–2022	4 872	510	Ajuste de preprocesamiento y pesos
Validación	2023	2 000	196	Configuración completa, semilla, umbrales y calibración OOF
Referencia histórica	2024–2025	2 232	222	Informe final; sin selección ni reajuste

4.2. Flujo reproducible

`base_limpia.parquet` $\xrightarrow{\text{corte cronológico}}$ {2021–22, 2023, 2024–25}
 $\xrightarrow{\text{fit solo 2021–22}}$ 175 features procesadas
 $\xrightarrow{\text{selección 2023}}$ MLP_32_16, seed 314, $t=0.80$
 $\xrightarrow{\text{5-fold OOF 2023}}$ Platt + umbral calibrado 0.30
 $\xrightarrow{\text{congelar}}$ `models/final/`
 $\xrightarrow{\text{referencia 2024–25}}$ métricas, IC y errores.

4.3. Selección del modelo

Se compararon tres **configuraciones completas** MLP y tres semillas (42, 314 y 2718). Cada configuración cambia simultáneamente capas, *dropout*, L2 y tasa de aprendizaje; por ello la búsqueda identifica un paquete ganador, no el efecto aislado de la arquitectura. La configuración se eligió por mediana de PR-AUC en validación, luego mediana de F1 y finalmente menor rango intercuartílico de PR-AUC. La semilla 314 quedó asociada al artefacto seleccionado. Los mismos datos y la misma política de umbral se aplicaron a regresión logística balanceada y Random Forest balanceado para evitar comparaciones ventajosas.

Tabla 3: Grilla cerrada de configuraciones completas; cada fila varía conjuntamente capas, *dropout*, L2 y tasa de aprendizaje.

ID	Capas ocultas	Dropout	L2 kernel	LR inicial	Lote
MLP_32_16	32–16	0.25	10^{-4}	10^{-3}	64
MLP_64_32	64–32	0.35	3×10^{-4}	5×10^{-4}	64
MLP_32	32	0.20	10^{-4}	5×10^{-4}	64

La configuración completa se seleccionó por el agregado robusto entre semillas. Dentro de la configuración ganadora se conservó la corrida más próxima a sus medianas de PR-AUC y F1, no la corrida extrema; esa regla eligió la semilla 314.

4.4. Configuración exacta de entrenamiento

Tabla 4: Técnicas efectivamente aplicadas a la MLP definitiva.

Técnica	Configuración verificable	Propósito
Función objetivo	Entropía cruzada binaria ponderada	Clasificación binaria bajo desbalance
Pesos de clase	Fórmula balanced : $w_0 = 0.5585$, $w_1 = 4.7765$ en 2021–2022	Dar mayor costo a errores multifatales; no es regularización
Optimizador	Adam; tasa inicial 10^{-3}	Actualización adaptativa de gradientes [4]
L2	10^{-4} en los kernels de ambas capas ocultas	Penalizar pesos grandes; no se aplica a sesgos ni salida [1]
Dropout	0.25 después de Dense(32) y después de Dense(16)	Reducir coadaptación durante entrenamiento [9]
Programa de épocas	Máximo 180; lote 64; la corrida seleccionada terminó tras 45 épocas	Fijar un presupuesto común y documentar la ejecución elegida
Parada temprana	val_pr_auc , modo máximo, paciencia 20, restaurar mejores pesos	Detener al agotarse la mejora de validación [8]
Reducción de tasa	Mismo monitor; factor 0.5, paciencia 8, tasa mínima 10^{-5}	Refinar el ajuste al entrar en meseta; por ello el estado final del optimizador puede guardar una tasa menor que la inicial
Repetibilidad	Semillas 42, 314 y 2718; TensorFlow, NumPy y Python sincronizados	Medir sensibilidad y evitar elegir una corrida excepcional

Técnicas no utilizadas. No se emplearon regularización L1 ni *batch normalization*; tampoco SMOTE, sobremuestreo, *stacking*, *bagging* o *boosting* combinados con la MLP. El Random Forest es únicamente un comparador independiente: no integra el predictor desplegado. La capacidad se controla con L2, dos capas de *dropout*, parada temprana y una arquitectura compacta; el desbalance se trata con pesos de clase, sin sintetizar escenas categóricas o geográficas inexistentes.

4.5. Auditoría posterior del diseño, sin reajuste

Para responder si las técnicas y el número de redes están justificados, se añadió una auditoría reproducible que vuelve a entrenar únicamente con 2021–2022 y compara exclusivamente en 2023: cuatro variantes de regularización por tres semillas, la MLP indi-

vidual congelada, un promedio de tres semillas y una alternativa multirrama que separa 162 variables de contexto de 13 variables companion. La auditoría no reemplaza pesos, calibrador ni umbrales canónicos. Un bootstrap pareado de 2 000 remuestreos compara la red individual con el ensemble.

Como control de suficiencia informativa se fija en 2023 una regla ordinal basada solo en `n_personas`; recién después se aplica a la referencia histórica. Esa comparación post-hoc pregunta si la MLP aprende algo más que un conteo obvio, pero no se usa para elegir el modelo. Finalmente se informa 2024 y 2025 por separado como estabilidad descriptiva; 2025 es parcial. El script `src/validation_design_audit.py`, sus tablas y hashes hacen estas decisiones verificables.

4.6. Calibración y umbrales

Platt e isotónica se compararon mediante Brier OOF de cinco particiones estratificadas dentro de 2023 [7]. Se seleccionó Platt por menor Brier OOF; el umbral calibrado 0.30 maximizó F1 sobre esas probabilidades OOF. El umbral crudo 0.80 proviene de la política predeclarada sobre scores de validación. Las escalas no se mezclan y la interfaz toma decisiones visibles solo en la escala calibrada.

4.7. Evaluación e incertidumbre

Se reportan dos vistas del mismo modelo congelado: score crudo y probabilidad Platt. Para las métricas de referencia se calcularon 1000 remuestreos bootstrap al 95 %. La evaluación incluye comparación con prevalencia, regresión logística y Random Forest; no se realizan pruebas o ajustes posteriores que reclasifiquen 2024–2025 como un nuevo periodo no observado.

4.8. Explicabilidad separada de la referencia

Gradient SHAP se ejecutó sin cargar etiquetas ni datos de 2024–2025 [5]. El fondo procede de entrenamiento y la muestra explicada de validación. Esta separación evita que la interpretación se convierta en una vía indirecta de ajuste a la referencia.

4.9. Implementación

La implementación usa Python 3.12, TensorFlow 2.19, scikit-learn 1.9, pandas 3.0, NumPy 2.1, SHAP 0.52, Streamlit y Plotly [2, 3, 7]. `models/final/manifest.json` fija versiones, hashes, particiones, arquitectura, calibrador y umbrales; el cargador de inferencia rechaza artefactos alterados.

5. Dataset

5.1. Fuente oficial

Se utilizó la base *SINIESTROS DE TRANSITO FATALES 2021–2025 (PRELIMINAR)*, publicada el 2026-02-27 por el Observatorio Nacional de Seguridad Vial (ONSV) en su portal de datos abiertos:

<https://www.onsv.gob.pe/datosabiertos>

El portal describe el recurso como: “Detalle de siniestros de tránsito con consecuencias fatales, ocurridos a nivel nacional, 2021–2025 (preliminar)”, autor ONSV. El archivo original se mantiene en `data/raw/BDD_ONSV_SINIESTROS_FATALES_2021-2025.xlsx` (hoja SINIESTROS, encabezado en la fila 5). La fecha de descarga y verificación local fue el 2026-07-09. Es un dato abierto del Estado peruano, lo que permite libre reuso con atribución. El ONSV declara la información de 2025 como preliminar.

5.2. Adecuación de la fuente

La base ONSV aporta fecha, hora, localización, clase notificada, clima, geometría, superficie y clasificación vial. Estas variables permiten estudiar asociaciones de multifatalidad sin mezclar fuentes con criterios de registro incompatibles. Su límite es igualmente claro: al contener solo siniestros fatales, obliga a formular un objetivo condicional de alta letalidad y no una predicción de mortalidad general.

5.3. Diccionario de datos base

La Tabla 5 resume las variables del registro y su rol en el proyecto.

Tabla 5: Variables del registro ONSV y su rol en el proyecto.

Columna	Rol	Justificación
FECHA, HORA	Característica (derivar)	Estacionalidad, nocturnidad, fatiga
DEPARTAMENTO	Característica categórica	Geografía del riesgo
ZONA	Característica categórica	Ruralidad: velocidades y respuesta médica
RED VIAL	Característica categórica	Nacional/departamental/provincial/urbana
TIPO DE VÍA	Característica categórica	Carretera, avenida, calle, vía expresa
COD CARRETERA	Característica (derivar)	Familias de vías y frecuencia
COORDENADAS	Característica numérica	Señal espacial continua
CONDICIÓN CLIMÁTICA	Característica categórica	Visibilidad y adherencia
CARACTERÍSTICAS DE VÍA	Característica categórica	Recta, curva, intersección, estructura
PERFIL LONGITUDINAL	Característica categórica	Plana vs. inclinada
SUPERFICIE DE CALZADA	Característica categórica	Pavimentada, afirmado, trocha
CLASE SINIESTRO	Característica categórica	Mecánica del evento
CANTIDAD DE FALLECIDOS	Solo target	Prohibida como entrada
CANTIDAD DE LESIONADOS	Excluida	Resultado posterior (fuga)
CANTIDAD VEHÍCULOS DAÑADOS	Excluida	Resultado posterior (fuga)
CAUSA (factor y específica)	Excluida	Se determina en la investigación posterior
SEÑALES vertical/horizontal	Excluida	78 % de faltantes concentrados por periodo

5.4. Bases companion: vehículos y personas involucradas (versión 2)

El ONSV publica en el mismo portal dos bases enlazables por CÓDIGO SINIESTRO:

- vehículos: `data/raw/BBDD_ONSV_VEHICULOS_2021-2025.xlsx`, con 12 667 filas, una por vehículo;
- personas: `data/raw/BBDD_ONSV_PERSONAS_2021-2025.xlsx`, con 25 412 filas, una por persona y hasta 74 en un siniestro.

La cobertura del join es del 100 % sobre los 9 104 códigos de la base limpia.

De estas tablas se derivan doce agregados por siniestro: total de vehículos; conteos de buses/minibuses, pesados de carga, motos/trimotos y vehículos no identificados; servicios interprovinciales y de transporte público; total de personas involucradas; pasajeros, peatones y conductores fugados; y edad media. Pertenecen al registro consolidado, pero su disponibilidad al instante de notificación no puede demostrarse sin timestamps por campo. Quedan **vetadas por fuga** las columnas de desenlace por persona y los dosajes étlicos. El conteo de personas involucradas es una variable de exposición estructural; se declara como limitación que el registro de ilesos podría ser más completo en siniestros graves.

5.5. Variable objetivo

Se construyó el target binario condicional al universo de siniestros fatales:

$$y = \begin{cases} 1, & \text{si FALLECIDOS} \geq 2 \quad (\text{“Alta Letalidad”}) \\ 0, & \text{si FALLECIDOS} = 1 \end{cases}$$

La prohibición de LESIONADOS, VEHICULOS_DANADOS y las columnas de causa como entradas se declara explícitamente como decisión metodológica en la Sección 7: los conteos se levantan después del siniestro (fuga directa del resultado) y la causa se codifica al cierre de la investigación (el 49 % figura “en proceso de investigación”).

5.6. Auditoría inicial

La auditoría (Bloque B) verificó y registró:

- Formato: Excel (.xlsx), hoja SINIESTROS, encabezado en fila 5, 27 columnas.
- Número de filas de datos: 9 106.
- Fechas inválidas eliminadas: 2. Duplicados por código de siniestro: 0.
- N final útil: 9 104.
- Casos multifatales: 928 (10.19 %); letalidad simple: 8 176.
- Rango temporal: 2021-01-01 a 2025-12-30 (2025 parcial, 678 registros).
- Coordenadas fuera del territorio peruano anuladas: 1 registro.

El protocolo usa un corte cronológico 2021–2022 / 2023 / 2024–2025. Como la clase multifatal representa 10.19 %, se usan pesos de clase sin SMOTE: sintetizar combinaciones categóricas y geográficas habría introducido casos difíciles de justificar. Tabla 6 resume la auditoría de fuente.

Tabla 6: Resumen de la auditoría del dataset (Bloque B).

Indicador	Valor
Filas de datos originales	9 106
Fechas inválidas eliminadas	2
Duplicados por código	0
Filas útiles finales	9 104
Casos multifatales (2+ fallecidos)	928
Porcentaje de clase multifatal	10.19 %
Rango temporal	2021–2025 (2025 parcial)
Máximo de fallecidos en un siniestro	33

6. Análisis exploratorio de datos

Se ejecutó el análisis exploratorio sobre `base_limpia.parquet`: cada figura se guardó numerada en `report/figures/` (150 dpi, títulos y ejes en español) y cada figura tiene 2–4 líneas de interpretación escrita. Se generaron 14 figuras y un conjunto de hallazgos numerados H1–H11 que alimentaron las decisiones de ingeniería de características.

6.1. Distribución del objetivo y desbalance




Figura 2: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con F1, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales




Figura 3: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 4: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).



Figura 5: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.




Figura 6: Siniestros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro




Figura 7: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 8: Tasa multifatal por clase. DES-PISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 9: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).




Figura 10: Top-15 departamentos por tasa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto




Figura 11: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1032 casos (H7).




Figura 12: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables aportan contexto inicial relevante para el modelo.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía




Figura 13: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.




Figura 14: Porcentaje de faltantes por columna. Las señales viales alcanzan 77.9 % (H10) y por eso se excluyen del modelo; el resto admite imputación simple con *flags*.




Figura 15: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Se redactaron once hallazgos en prosa, cada uno con referencia a su figura. Los más relevantes para el modelado:

- **H1:** la clase multifatal representa 10.2 % de los siniestros fatales (figura 2), confirma desbalance y justifica las métricas.
- **H3:** la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 4 y 5).
- **H5:** CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 7 y 8).
- **H6:** LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCARELI lidera la tasa multifatal con 28.0 % (figuras 9 y 10).
- **H8:** zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 12). Las condiciones pre-impacto separan el riesgo.
- **H11:** el scatter geográfico (figura 15) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

7.1. Contrato anti-fuga

El target es `target_multifatal=1` cuando `FALLECIDOS` ≥ 2 . Por ser resultado directo, `FALLECIDOS` no entra a X . También se excluyen `LESIONADOS`, `VEHICULOS_DANADOS`, causas post-investigación y señalización con faltantes dependientes del periodo. De las bases `companion` se excluyen la gravedad por persona, los lugares de atención y defunción y los dosajes étlicos; solo entran conteos y atributos de escena. Como no existen timestamps de disponibilidad por campo, el análisis se limita a clasificación retrospectiva post-registro.

7.2. Corte cronológico

Las fechas determinan tres bloques sin solapamiento: 2021–2022 para entrenamiento, 2023 para validación y calibración, y 2024–2025 para referencia histórica. El escalador, las categorías, el mapa de frecuencias de vía y cualquier imputación se ajustan únicamente con entrenamiento. Los transformadores no vuelven a ajustarse al procesar periodos posteriores.

7.3. Limpieza y codificación

Las categorías se normalizan a vocabularios cerrados con una categoría explícita `DESCONOCIDO`. Los códigos de carretera no vistos reciben frecuencia cero. Latitud y longitud se convierten a numérico; el *bundle* final exige el par completo para inferencia y la interfaz no inventa ubicaciones. Las continuas se estandarizan con estadísticos 2021–2022; las variables cíclicas permanecen en $[-1, 1]$ y las categóricas se codifican *one-hot*.

7.4. Contrato persistido

`models/final/` contiene `feature_list.json`, `feature_schema.json`, escalador, codificadores, modelo, calibrador, umbrales y manifiesto. El manifiesto registra hashes SHA-256 y el cargador de inferencia los verifica antes de predecir. El vector final tiene exactamente 175 columnas y el orden es parte del contrato.

7.5. Pruebas de frontera

Las pruebas automatizadas verifican que:

- las particiones temporales no se solapen;
- validación, no la referencia, seleccione umbrales y calibración;
- el modelo, el esquema y la lista tengan 175 entradas en el mismo orden;
- las escalas cruda y calibrada conserven umbrales distintos;
- el par de coordenadas sea obligatorio en la inferencia final;
- una entrada inválida elimine cualquier resultado previo de la interfaz.

Los casos de demostración prueban ejecución, no desempeño.

8. Ingeniería de características

El contrato canónico de la versión 2 tiene 175 características construidas a partir del registro consolidado de un siniestro ya fatal. La fuente no aporta timestamps por campo para demostrar disponibilidad inicial o en tiempo real; por ello el alcance es retrospectivo. No se agregaron variables externas inventadas ni proxies del desenlace.

Tabla 7: Familias principales del contrato canónico.

Familia	Transformación	Ejemplos	Justificación
Temporal	Cíclica + indicadores	mes, día semanal, hora, nocturnidad, fin de semana	Respetar proximidad circular y faltantes
Geográfica	Escalado + <i>one-hot</i>	latitud, longitud, departamento, región natural	Contexto territorial sin usar el resultado
Vía	Frecuencia + categorías	código, prefijo, red, tipo, zona	Maneja cardinalidad y códigos nuevos
Registro del evento	Categorías cerradas	clase, clima, geometría, perfil, superficie	Disponibilidad temporal no demostrada
Escena agregada (v2)	Conteos escalados	vehículos, buses, pesados, motos, interprovincial, personas, pasajeros, peatones, fugados, edad media	Exposición y composición vehicular del evento, sin desenlaces por persona
Interacciones	Productos predefinidos	noche×rural, lluvia×curva, tipo×zona, red×clase	Permite relaciones no aditivas defendibles
Faltantes	Indicadores explícitos	hora faltante, coordenadas faltantes, edad faltante	Evita imputación silenciosa

La versión 1 del contrato tenía 162 características; la versión 2 agrega los doce agregados de escena de las bases companion más el indicador de edad faltante. Los conteos se estandarizan con estadísticos de entrenamiento 2021–2022 y la edad media se imputa con la mediana de entrenamiento acompañada de su indicador. El contrato se congeló antes de la evaluación de referencia de la versión 2.

8.1. Disponibilidad y alcance

Fecha, hora, ubicación, vía, zona, clima, geometría y agregados companion aparecen en el registro consolidado, pero la fuente no aporta timestamps que demuestren su disponibilidad en tiempo real. Fallecidos, lesionados, daños, gravedad por persona, dosajes y causas de investigación se excluyen. La afirmación precisa es que el modelo clasifica retrospectivamente registros consolidados.

9. Modelo neuronal

9.1. Búsqueda cerrada y reproducible

Se definieron tres configuraciones completas y tres semillas antes de consultar el periodo de referencia 2024–2025. Cada configuración varía conjuntamente capas, *dropout*, L2 y tasa de aprendizaje. Cada corrida usó el mismo entrenamiento 2021–2022 y validación 2023, con entropía cruzada binaria, pesos de clase, Adam, reducción de tasa de aprendizaje y parada temprana por PR-AUC. La configuración se eligió por mediana de PR-AUC entre semillas; F1 mediana y menor dispersión actuaron como desempates. La misma búsqueda se ejecutó íntegra para la versión 2 con las 175 características.

Tabla 8: Robustez de configuraciones en validación 2023 (contrato v2 de 175 características).

Configuración	PR-AUC mediana	F1 mediana	IQR PR-AUC
MLP_32_16: 32–16	0.4806	0.5093	0.0058
MLP_64_32: 64–32	0.4682	0.5154	0.0047
MLP_32: 32	0.4656	0.5118	0.0080




Figura 16: PR-AUC de validación por configuración completa y semilla. MLP_32_16 presenta la mayor mediana; la variación entre semillas se conserva como evidencia, no se oculta. Nótese que la configuración ganadora de la versión 1 (MLP_64_32) deja de serlo con el contrato v2: la regla predeclarada decide, no la preferencia.

9.2. Arquitectura congelada

La MLP canónica es MLP_32_16 con semilla 314: entrada de 175 variables, capas densas de 32 y 16 neuronas con ReLU, *dropout* 0.25, L2 de 1×10^{-4} , Adam con 1×10^{-3} y lote 64. El modelo final conserva exactamente el hash del artefacto seleccionado; materializar `models/final/` no reentrena ni vuelve a buscar pesos.

9.3. Comparadores y política de umbral

El clasificador constante por prevalencia, la regresión logística balanceada y el Random Forest balanceado se entrenaron con las mismas particiones; los dos modelos aprendidos recibieron las mismas 175 variables. Para cada modelo, el umbral se escogió solo en validación con la misma regla: máximo F1; empates por *recall*, precisión y mayor umbral. Para la MLP cruda se obtuvo 0.80.

9.4. Calibración Platt OOF

Sobre los scores de validación 2023 se generaron predicciones OOF con cinco particiones estratificadas. En esa selección, Platt obtuvo Brier OOF 0.0652 (ECE 0.0086) y quedó seleccionado frente a la isotónica. El umbral calibrado 0.30 se eligió sobre probabilidades OOF calibradas. Estos valores pertenecen exclusivamente a validación; el Brier 0.0683 informado en resultados corresponde a la referencia histórica 2024–2025 después de ajustar Platt con toda la validación. El procedimiento separa selección y referencia, y evita usar las etiquetas 2024–2025 para elegir el calibrador [7].

9.5. Artefactos canónicos

El directorio `models/final/` contiene:

- `model.keras`, `scaler.joblib` y `encoders.joblib`;
- `feature_list.json` y `feature_schema.json`;
- `calibrator.joblib` y `thresholds.json`;
- `calibration_selection.json` y `manifest.json`.

Los hashes permiten demostrar que la aplicación ejecuta el mismo stack que sustenta el informe. La versión del bundle es `canonical-2.0.0`; la versión 1 permanece íntegra en la historia de Git.

10. Resultados

10.1. Estatus de la evaluación

Los 2 232 registros de 2024–2025 contienen 222 casos multifatales (prevalencia 0.0995). Sus etiquetas ya fueron observadas por la versión 1; en consecuencia, los resultados de la versión 2 constituyen la **segunda evaluación predeclarada** sobre esa referencia histórica y se divulgan como tal. Todo el diseño de la versión 2 (contrato de 175 características, grilla, semillas, reglas de selección, calibración y umbrales) se congeló usando exclusivamente 2021–2023, antes de volver a consultar la referencia; después de observarla no se modificó nada.

10.2. MLP cruda y calibrada

Tabla 9: Métricas canónicas e intervalos bootstrap al 95 % (1 000 remuestreos).

Métrica	Score crudo, $t = 0.80$	Platt, $t = 0.30$
F1 multifatal	0.4957 [0.4379, 0.5462]	0.5058 [0.4512, 0.5566]
Precisión multifatal	0.4715 [0.4078, 0.5304]	0.4452 [0.3879, 0.5000]
<i>Recall</i> multifatal	0.5225 [0.4572, 0.5850]	0.5856 [0.5194, 0.6489]
PR-AUC	0.4416 [0.3785, 0.5124]	0.4416 [0.3785, 0.5124]
ROC-AUC	0.8841 [0.8613, 0.9055]	0.8841 [0.8613, 0.9055]
Brier	0.1081	0.0683 [0.0609, 0.0756]
ECE, 10 bins	0.1044	0.0169 [0.0115, 0.0297]

La calibración transforma la escala, no el orden: PR-AUC y ROC-AUC son idénticos. Su aporte aparece donde corresponde, en Brier y ECE. El Brier calibrado 0.0683 mejora con claridad al predictor constante de prevalencia, cuyo Brier es aproximadamente $0.0995(1 - 0.0995) = 0.0896$.

Con el umbral calibrado, la matriz contiene 1 848 verdaderos negativos, 162 falsos positivos, 92 falsos negativos y 130 verdaderos positivos. El modelo identifica el 58.6 % de los multifatales y el 44.5 % de sus alertas son verdaderas: 4.5 veces la prevalencia base.

10.3. Comparación entre versiones: evidencia consistente con la hipótesis informacional

La versión 1 usaba únicamente el registro de siniestros (162 características). La versión 2 agrega los agregados de escena de las bases companion de vehículos y personas. Todo lo demás —particiones, reglas de selección, calibración OOF, política de umbral— es idéntico. La Tabla 10 muestra el efecto.

Tabla 10: Versión 1 vs. versión 2 sobre la misma referencia 2024–2025 (escala calibrada).

	Versión 1	Versión 2	Cambio
Características	162	175	12 agregados + 1 indicador
Arquitectura seleccionada	MLP_64_32	MLP_32_16	Regla predeclarada; semilla 314
PR-AUC	0.2249	0.4416	$\times 1.96$; prevalencia 0.0995
ROC-AUC	0.7482	0.8841	+0.136
F1 multifatal	0.2958	0.5058	+0.210
Precisión	0.2359	0.4452	De 1 de 4 a casi 1 de 2 alertas verdaderas
<i>Recall</i>	0.3964	0.5856	FN: 134 $\rightarrow$ 92
Brier / ECE	0.0831 / 0.0085	0.0683 / 0.0169	Ambas escalas calibradas
Grupo SHAP dominante	clase del siniestro	personas involucradas (43.7 %)	Nueva variable dominante

Esta comparación respalda fuertemente la hipótesis informacional: al incorporar cuántas personas y qué vehículos estaban involucrados, la discriminación prácticamente se duplicó. No es una ablación causal pura porque también cambió la configuración seleccionada y la referencia se consultó por segunda vez; por eso no se afirma que las nuevas

variables sean la única causa del salto. El diseño congelado en 2021–2023 reduce el riesgo de ajuste directo, pero solo un periodo futuro o una cohorte externa puede confirmarlo.

10.4. Comparación honesta con líneas base

Tabla 11: Comparación en la misma referencia temporal y con umbrales seleccionados solo en validación (contrato v2 compartido).

Modelo / escala	F1	Precisión	Recall	PR-AUC	ROC-AUC
MLP cruda	0.4957	0.4715	0.5225	0.4416	0.8841
MLP Platt	0.5058	0.4452	0.5856	0.4416	0.8841
Constante por prevalencia	0.1809	0.0995	1.0000	0.0995	0.5000
Regresión logística	0.4896	0.4230	0.5811	0.4334	0.8580
Random Forest	0.4943	0.4300	0.5811	0.4704	0.8937

Para cuantificar las diferencias se ejecutó un **bootstrap pareado** sobre las predicciones congeladas (2 000 remuestreos de registros, semilla 42, IC percentil; los dos baselines se reajustan con la receta exacta publicada y el script aborta si no reproducen las métricas del bundle). La Tabla 12 resume el resultado.

Tabla 12: Bootstrap pareado de la MLP contra cada baseline sobre la referencia 2024–2025 (`final_paired_bootstrap_2024_2025.csv`). Δ = MLP – baseline, escala cruda con umbrales de validación.

Baseline	Métrica	Δ	IC 95 % de Δ	$P(\Delta > 0)$	Significativa
Logística	PR-AUC	+0.0082	[−0.0184, +0.0362]	0.717	No
Logística	ROC-AUC	+0.0261	[+0.0122, +0.0417]	1.000	Sí
Logística	F1	+0.0062	[−0.0311, +0.0419]	0.623	No
Random Forest	PR-AUC	−0.0288	[−0.0727, +0.0138]	0.089	No
Random Forest	ROC-AUC	−0.0096	[−0.0234, +0.0028]	0.072	No
Random Forest	F1	+0.0015	[−0.0378, +0.0390]	0.522	No

La lectura honesta tiene dos caras. Contra la regresión logística, la red muestra una ventaja **estadísticamente significativa** en ROC-AUC; este resultado es compatible con que las interacciones no lineales aporten capacidad, sin identificar causalmente qué interacción la produce. Contra el Random Forest, el bosque presenta mejor ranking nominal y no se detectó diferencia significativa en ninguna métrica. Esto no demuestra equivalencia: los intervalos todavía admiten ventajas en ambos sentidos. En datos tabulares medianos, los ensambles de árboles siguen siendo competidores de primer nivel.

10.5. Ablación de regularización y estrategia de una sola red

La auditoría validation-only reentrenó cuatro variantes 32–16 con tres semillas. La configuración canónica L2+*dropout* obtuvo PR-AUC mediana 0.4806 (IQR 0.0058), ROC-AUC mediana 0.8911 y F1 mediana 0.5093. Solo *dropout* alcanzó PR-AUC mediana 0.4818; solo L2, 0.4655; y sin ambos, 0.4648. Por tanto, la evidencia favorece mantener regularización y muestra estabilidad, pero no demuestra que L2 y *dropout* sean individualmente

indispensables. Se conserva la configuración ganadora predeclarada y no se reajustan los pesos.

El promedio de tres semillas alcanzó PR-AUC 0.4976 frente a 0.4806 de la MLP congelada; la multirrama 162+13 obtuvo 0.4622. Sin embargo, en el bootstrap pareado del ensemble frente a una red, todos los IC 95 % incluyen cero: $\Delta\text{PR-AUC} +0.0170$ $[-0.0043, +0.0363]$, $\Delta\text{ROC-AUC} +0.0028$ $[-0.0016, +0.0073]$ y $\Delta\text{F1} +0.0097$ $[-0.0270, +0.0489]$. La conclusión es mantener **una sola MLP**: el ensemble queda como hipótesis futura porque incorporarlo exigiría un nuevo holdout y calibración independiente.




Figura 17: Auditoría del diseño usando exclusivamente entrenamiento 2021–2022 y validación 2023. Las mejoras nominales del ensemble no justifican reemplazar la única red congelada.

10.6. Control simple con `n_personas`

La regla fijada exclusivamente en validación fue `n_personas` ≥ 4 . En la referencia histórica obtuvo PR-AUC 0.3941, ROC-AUC 0.8540 y F1 0.4954; la MLP cruda obtuvo 0.4416, 0.8841 y 0.4957, respectivamente. El bootstrap pareado post-hoc favorece a la MLP en ranking: $\Delta\text{PR-AUC} +0.0475$ $[0.0167, 0.0833]$ y $\Delta\text{ROC-AUC} +0.0301$ $[0.0120, 0.0491]$; para F1 no se detectó diferencia ($\Delta = +0.0003$, IC $[-0.0418, 0.0413]$). La red, por tanto, aporta ordenamiento más allá del conteo dominante, aunque al umbral elegido ambas reglas tengan F1 similar.

10.7. Estabilidad anual descriptiva

Sin usarla para decidir, la MLP Platt obtuvo en 2024 ($n = 1\,554$) PR-AUC 0.4448, ROC-AUC 0.8778 y F1 0.4986; en 2025 parcial ($n = 678$), PR-AUC 0.4450, ROC-AUC 0.8976 y F1 0.5217. La similitud de PR-AUC es tranquilizadora, pero dos puntos temporales y un año incompleto no prueban ausencia de deriva.

Evidencia histórica 2024-2025: comparación en escala cruda




Figura 18: Comparación en escala cruda de PR-AUC, ROC-AUC y F1 entre la MLP definitiva y las líneas base en la referencia histórica. El F1 de la MLP es 0.4957; el F1 Platt 0.5058 pertenece a la escala calibrada y no se usa en esta figura.

10.8. Análisis de errores

Los 92 falsos negativos calibrados son el principal límite restante: representan 41.4 % de los 222 casos multifatales, aproximadamente dos de cada cinco. Varios quedan apenas por debajo del umbral y muestran que la etiqueta binaria oculta diferencias pequeñas; por eso la interfaz presenta probabilidad y clase. Los 162 falsos positivos también limitan el desempeño. Las variables aún ausentes —velocidad, uso de cinturón/casco, antigüedad del vehículo y exposición— podrían aportar información, pero su mejora no se presume sin nuevos datos.

10.9. Explicabilidad global

La explicación canónica usa Gradient SHAP sobre la sigmoide cruda. El fondo contiene 256 registros de entrenamiento 2021–2022; se explican 512 registros de validación 2023 con 200 muestras SHAP y semilla 20260709. No se cargaron etiquetas ni datos 2024–2025. Las 175 variables procesadas se sumaron en 20 grupos interpretables.




Figura 19: Importancia Gradient SHAP por grupo interpretable en validación 2023. El signo resume la contribución media respecto del fondo, no un efecto causal.

Tabla 13: Cinco grupos con mayor importancia SHAP global (contrato v2).

Grupo	Features agrupadas	Participación	Dirección media
Personas involucradas	4	43.75 %	Aumenta score crudo
Vehículos involucrados	7	7.68 %	Reduce score crudo
Clase del siniestro	6	6.62 %	Reduce score crudo
Red vial × clase	30	6.04 %	Reduce score crudo
Departamento / región natural	29	4.97 %	Aumenta score crudo

El grupo de personas involucradas domina la explicación con el 43.75 % de la importancia: exactamente la variable cuya ausencia diagnosticó la versión 1. Las direcciones medias no significan que toda categoría de un grupo actúe igual, ni autorizan afirmaciones causales: SHAP describe asociaciones del modelo congelado y de la muestra de validación. No se generaron explicaciones locales para casos individuales.

11. Interfaz gráfica

11.1. Arquitectura de información

La interfaz Streamlit es un consumidor de solo lectura. No entrena, calibra, reescribe tablas ni modifica artefactos. Al iniciar, carga `models/final/manifest.json`, verifica hashes y comprueba que modelo, esquema y lista coincidan en 175 entradas.

Tabla 14: Flujo de información de la interfaz canónica.

Componente	Flujo	Responsabilidad
Formulario validado	→	Campos requeridos vacíos, opcionales como NO INFORMADO y caso demo explícito
app_inference	→	Valida periodo 2021–2025, código vial, par geográfico Perú–departamento y contrato de entrada
Bundle canónico	→	Verifica hashes; calcula score crudo y probabilidad Platt sin escribir archivos
Umbrales separados	→	0.30 para clase visible calibrada; 0.80 solo para diagnóstico crudo
Presentación	→	Probabilidad, clase estimada, evidencia e incertidumbre con trazabilidad

11.2. Cinco páginas funcionales y enlazables

La navegación se sincroniza con el parámetro `?section=`; por ello cada página posee una URL compartible y el estado de navegación no queda oculto en pestañas internas.

1. **Panorama:** propósito en lenguaje llano, funcionamiento en tres pasos y tres demostraciones sobre la referencia 2024–2025: la serie mensual de tasa observada vs. probabilidad media predicha, la multifatalidad real por quintil de score (que crece monotónicamente con el score del modelo) y una comparación interactiva predicho vs. observado por categoría (clase, zona, clima, red vial, tipo de vía o departamento) con seguimiento mensual de la categoría elegida; todo con soporte mínimo de 30 e intervalos de Wilson.
2. **Probar la red:** ofrece cinco escenarios seleccionables, agrupa evento y ubicación, vía y entorno, y vehículos y personas; muestra probabilidad Platt y clase estimada “1 fallecido / 2+ fallecidos”. El mapa completa coordenadas y departamento. Comparar escenarios muestra la respuesta del modelo, no un efecto causal. La disponibilidad operativa de los campos companion no se presume.
3. **Explorar datos:** gráficos Plotly responsivos del target, serie mensual, tasas por clase y condiciones, mapa de puntos y matriz mes×hora. No reutiliza capturas EDA estáticas.
4. **Patrones regionales:** mapa, ranking y tabla departamental con intervalos de Wilson. Las tasas con soporte menor de 30 se enmascaran en lugar de presentarse como estimaciones estables.
5. **Evidencia del modelo:** comparación MLP/logística/Random Forest, confiabilidad, matriz de confusión, curvas PR/ROC y Gradient SHAP canónico. La matriz y las curvas incluyen tablas descargables como alternativa accesible.

11.3. Validación de entradas

La fecha se restringe al periodo cubierto por la evidencia, del 1 de enero de 2021 al 31 de diciembre de 2025. Un algoritmo geométrico puro sobre el GeoJSON versionado admite polígonos, multipolígonos y puntos de frontera; exige que las coordenadas pertenezcan al

Perú y al departamento seleccionado. El código vial se busca entre los códigos persistidos y admite un código nuevo con formato oficial, mostrando que su frecuencia canónica será cero. Los campos de escena opcionales comienzan en NO INFORMADO. El subgrupo histórico coincidente se presenta únicamente con $n \geq 30$.

11.4. Clase y contexto en escalas distintas

La clase visible se calcula únicamente con la probabilidad Platt y el umbral 0.30. El score sigmoide y el umbral 0.80 aparecen en un panel separado para auditoría. Las tasas históricas incluyen soporte e intervalo de Wilson; son comparadores descriptivos y no se superponen conceptualmente con una probabilidad individual.

11.5. Validación funcional

`src/block_g_app_check.py` ejecuta comprobaciones de manifiesto, alineación de 175 variables, finitud, separación de escalas, ausencia de escrituras y latencia en caliente. Además, `streamlit.testing.AppTest` recorre las cinco URLs, verifica campos vacíos, carga demo explícita, resultado válido, coherencia geográfica, limpieza de estado obsoleto y alternativas tabulares. Las pruebas unitarias cubren fechas fuera de dominio, coordenadas interiores, exteriores, fronterizas y departamentalmente incoherentes, códigos viales conocidos y nuevos, separación de umbrales y soporte $n = 29/30$.

El gate `check_release.py` unifica pruebas directas, AppTest, hashes, paridad de 2232 inferencias, lectura segura de explicabilidad, escaneo de notebooks e imports, referencias obsoletas, vigencia del PDF y estado de Git. El modo local informa artefactos aún no versionados; el modo estricto los convierte en fallo de entrega.

No se incluyen capturas de pantalla de una sesión no verificable. La tabla de flujo y el código probado constituyen evidencia reproducible de la arquitectura; la apariencia interactiva se inspecciona ejecutando la aplicación localmente.

12. Discusión

12.1. Evidencia fuerte, no demostración causal, de un límite informacional

La versión 1 cerró con discriminación moderada (PR-AUC 0.2249) y sin diferencia significativa frente a la regresión logística. La versión 2 incorporó agregados de escena de las bases companion del ONSV y obtuvo PR-AUC 0.4416 y ROC-AUC 0.8841. El resultado respalda fuertemente la hipótesis de información insuficiente, pero no la demuestra de forma aislada: también cambió la configuración seleccionada y existe una segunda consulta a la referencia. El aporte metodológico es la evidencia convergente —salto de ranking, dominio SHAP de personas y ventaja frente a la regla `n_personas`—, acompañada de sus límites.

12.2. Segunda evaluación sobre la referencia: divulgación

Las etiquetas 2024–2025 ya habían sido observadas al evaluar la versión 1. La versión 2 se diseñó y congeló usando solo 2021–2023, pero su evaluación constituye una segunda consulta a la misma referencia y se declara como tal. Congelar el diseño reduce el ajuste

directo a esas etiquetas, pero el riesgo de multiplicidad no fue cuantificado y no se lo califica como mínimo. La confirmación exige un periodo futuro no observado o una cohorte externa.

12.3. Red neuronal frente a modelos tabulares

Con el contrato v2, la MLP supera a la regresión logística con significación estadística en ROC-AUC ($\Delta=+0.026$, IC 95 % [$+0.012$, $+0.042$], bootstrap pareado); esto es compatible con capacidad no lineal adicional, sin demostrar el mecanismo. Frente al Random Forest, el bosque muestra mejor ranking nominal (PR-AUC 0.470 vs. 0.442) y no se detecta diferencia significativa. Esto no prueba equivalencia. La conclusión profesional es matizada: la red cumple la pregunta académica con desempeño competitivo, pero no domina a los ensambles de árboles.

12.4. Por qué una sola red y por qué estas técnicas

El ensemble de tres semillas mejora nominalmente PR-AUC en 2023, pero sus intervalos pareados incluyen cero; la multirrama no mejora el ranking. Desplegar dos o más redes agregaría costo, calibración y una nueva decisión de selección sin evidencia concluyente. La única MLP congelada es la opción parsimoniosa. L2, *dropout*, pesos de clase, parada temprana y reducción de tasa actúan en problemas distintos; la ablación muestra que el paquete es estable, no que cada componente sea indispensable por sí mismo. Agregar L1, batch normalization, SMOTE o stacking sin una hipótesis y un holdout nuevo sería complejidad, no rigor.

12.5. Calibración no es discriminación

Platt reduce Brier de 0.1081 a 0.0683 y ECE de 0.1044 a 0.0169, pero PR-AUC y ROC-AUC permanecen iguales: calibrar corrige la escala, no el orden. El umbral calibrado 0.30 proviene exclusivamente de validación OOF 2023 y no fue reajustado a la referencia.

12.6. Errores y utilidad real

Con 130 verdaderos positivos, 92 falsos negativos y 162 falsos positivos, el sistema identifica el 58.6 % de los multifatales con una precisión de 0.445. Los 92 falsos negativos son 41.4 % de los 222 positivos: aproximadamente dos de cada cinco. Los casos cercanos al corte muestran que la etiqueta binaria oculta información; por eso la interfaz académica muestra probabilidad y clase.

12.7. Sesgos y variables ausentes

El registro ONSV proviene de partes administrativos, 2025 es preliminar y puede existir subregistro o cambios de codificación territorial. El conteo de involucrados podría registrarse con mayor completitud en siniestros graves (sesgo de registro que se declara, no se corrige). Aún faltan velocidad estimada, uso de cinturón/casco, antigüedad del vehículo y exposición vial; con la escena ya incorporada, esas variables fijan el próximo techo.

12.8. Alcance retrospectivo y disponibilidad temporal

La extracción no contiene timestamps por campo que demuestren cuándo quedaron disponibles la clase y los agregados companion. Por ello, el alcance defendible es retrospectivo o post-registro, no una operación en tiempo real al instante de notificación. Cualquier uso temporal futuro exige metadatos de disponibilidad, una regla de corte y validación prospectiva.

12.9. Lectura correcta de SHAP

El grupo de personas involucradas concentra el 43.75 % de la importancia global, seguido por vehículos involucrados y clase del siniestro. Esto describe cómo el modelo distribuye su score en 512 casos de validación respecto de 256 casos de fondo; coincide con el mecanismo causal plausible (más ocupantes, mayor techo de víctimas), pero SHAP por sí solo no establece causalidad ni recomienda intervenciones. La ausencia deliberada de explicaciones locales evita narrativas individuales no validadas.

13. Conclusiones

13.1. Cumplimiento de objetivos

- **EDA:** se caracterizaron 9 104 siniestros fatales y el desbalance multifatal, con hallazgos temporales, territoriales y de condiciones registradas.
- **Características:** 26 campos crudos se transforman en 175 variables, incluidos doce agregados companion, sin columnas de resultado o investigación posterior; la disponibilidad temporal se deja explícitamente sin demostrar.
- **Modelo:** la búsqueda predeclarada (tres configuraciones completas, tres semillas) seleccionó una MLP 32–16 regularizada con semilla 314; el periodo 2024–2025 no intervino en la selección numérica ni en la recalibración de la versión 2, aunque constituye una segunda consulta declarada a la referencia.
- **Evaluación:** la MLP calibrada obtuvo PR-AUC 0.4416 [0.3785–0.5124], ROC-AUC 0.8841 [0.8613–0.9055] y F1 0.5058, con ventaja estadísticamente significativa sobre la regresión logística en ROC-AUC; frente al Random Forest no se detectó diferencia significativa. La comparación v1→v2 respalda fuertemente, sin demostrar causalidad, la hipótesis de un límite informacional previo.
- **Interpretabilidad:** Gradient SHAP se ejecutó únicamente con entrenamiento y validación, agrupando 175 features en 20 grupos; el grupo de personas involucradas domina con 43.75 %, coherente con la mejora observada.
- **Interfaz:** la app de cinco secciones consume un stack canónico de solo lectura con hashes, incluye selector de ubicación OpenStreetMap con deducción de departamento, formulario de escena sin desenlaces, y demostraciones interactivas del modelo contra la realidad observada.

13.2. Conclusión general

El proyecto entrega un sistema auditable y evidencia de método. La versión 2 usa información oficial adicional y muestra un salto de desempeño consistente con la hipótesis informacional. La ventaja de ROC-AUC frente a logística confirma una diferencia de ranking en esta referencia, no el mecanismo causal. La auditoría de diseño justifica mantener una sola red compacta: el ensemble mejora nominalmente, pero sus intervalos incluyen cero y necesitaría un holdout nuevo.

Las limitaciones se declaran sin maquillaje: la evaluación v2 es la segunda consulta a la referencia; el riesgo asociado no está cuantificado; el Random Forest lidera nominalmente el ranking; 92 de 222 multifatales (41.4 %, aproximadamente dos de cada cinco) quedan fuera; y no se ha demostrado la disponibilidad de cada campo al instante de notificación. La siguiente evaluación válida exige un periodo futuro o externo no observado.

14. Anexos

14.1. A1. Fuente y diccionario

La base ONSV conserva encabezados descriptivos en la hoja SINIESTROS. El mapeo a nombres canónicos está en `src/block_b_dataset_audit.py`; la auditoría agregada está en `report/tables/tab00_audit_summary_block_b.json`.

14.2. A2. Artefactos definitivos

- Bundle de inferencia y manifiesto: `models/final/`.
- Protocolo: `report/tables/final_model_protocol.md`.
- Métricas, probabilidades, confusión, errores e intervalos: tablas de referencia final.
- Selección y robustez: tablas de selección y `models/final/model_selection.json`.
- Explicabilidad: tablas y figura de importancia global.

14.3. A3. Configuración congelada

```
1 canonical = {  
2     "config_id": "MLP_32_16",  
3     "hidden_units": [32, 16],  
4     "dropout": 0.25,  
5     "l2": 1e-4,  
6     "learning_rate": 1e-3,  
7     "batch_size": 64,  
8     "seed": 314,  
9     "feature_count": 175,  
10    "raw_threshold": 0.80,  
11    "calibrated_threshold": 0.30,  
12    "calibration": "platt",  
13 }
```

14.4. A4. Protocolo cronológico

```
1 train = data[data.FECHA.dt.year.isin([2021, 2022])]
2 selection = data[data.FECHA.dt.year.eq(2023)]
3 reference = data[data.FECHA.dt.year.isin([2024, 2025])]
4
5 # Fit preprocessing and weights: train only.
6 # Select architecture, seed, calibration and thresholds: selection only.
7 # Reference 2024-2025: reporting only; no further tuning.
```

14.5. A5. Decisiones metodológicas

Tabla 15: Controles del modelo definitivo.

Etapas	Decisión	Riesgo controlado	Evidencia
Protocolo	Separar 2021–22, 2023 y 2024–25 por rol	Fuga y optimismo por mezcla cronológica	Protocolo final
Selección	Comparar 3 configuraciones completas $\times$ 3 semillas; congelar MLP_32_16, semilla 314	Selección oportunista	Registro de selección
Versión 2	Incorporar bases companion (vehículos/personas) con desenlaces vetados; segunda evaluación divulgada	Fuga desde tablas enlazadas y multiplicidad silenciosa	Auditoría del join y Tabla 10
Calibración	Elegir Platt mediante Brier OOF de 5 folds en 2023	Ajustar y evaluar calibrador en los mismos casos	Registro de calibración
Referencia	Tratar 2024–25 como periodo ya observado	Reutilizarlo para nuevos ajustes	Métricas finales
SHAP	Gradient SHAP solo con entrenamiento y selección	Interpretación contaminada por la referencia	Procedencia SHAP
Interfaz	Bundle verificado, solo lectura, decisión en escala calibrada	Divergencia informe/aplicación	Manifiesto canónico

14.6. A6. Reproducción y verificación

```
1 # Canonical order: validation audit, manifest/protocol, figures, PDF
2 .venv/bin/python src/validation_design_audit.py
3 .venv/bin/python src/final_model_bundle.py
4 .venv/bin/python src/final_evaluation_figures.py
5 .venv/bin/python src/final_explainability.py
6 cd report && latexmk -pdf -interaction=nonstopmode -halt-on-error main.tex
7 cd ..
8
9 # Contracts and GUI
10 .venv/bin/python tests/test_model_protocol.py
11 .venv/bin/python tests/test_final_model_bundle.py
12 .venv/bin/python tests/test_final_explainability.py
```



```
13 .venv/bin/python tests/test_app_inference.py
14 .venv/bin/python src/block_g_app_check.py
15
16 # Interface
17 streamlit run app/streamlit_app.py
```

Las versiones exactas usadas para el bundle constan en el manifiesto. La reproducción no autoriza reoptimizar el modelo con la referencia 2024–2025.

Referencias

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [2] Google Brain Team. Tensorflow: Large-scale machine learning on heterogeneous systems. <https://www.tensorflow.org/>, 2024.
- [3] Keras Team. Keras 3 documentation. <https://keras.io/>, 2024.
- [4] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [5] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, pages 4765–4774, 2017.
- [6] Observatorio Nacional de Seguridad Vial (ONSV). Siniestros de tránsito fatales 2021-2025 (preliminar). <https://www.onsv.gob.pe/datosabiertos>, 2026. Publicado el 2026-02-27; detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional, 2021–2025 (preliminar); verificado localmente el 2026-07-09.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, et al. scikit-learn: Machine learning in python. <https://scikit-learn.org/>, 2024.
- [8] Lutz Prechelt. Early stopping—but when? In *Neural Networks: Tricks of the Trade*, pages 55–69. Springer, 1998.
- [9] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014.
- [10] World Health Organization. Road traffic injuries. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>, 2023.