

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para priorización posterior a la notificación (ONSV 2021–2025)

Rendo

Yimmy

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una red neuronal para priorizar, después de la notificación, siniestros viales ya fatales que dejaron dos o más fallecidos. La fuente oficial ONSV 2021–2025 contiene 9 104 registros útiles y una prevalencia multifatal de 10.19 %. El protocolo canónico bloquea la mezcla cronológica: entrenamiento en 2021–2022 (4 872 registros), selección y calibración exclusivamente en 2023 (2 000), y evaluación de referencia en 2024–2025 (2 232).

El proyecto se desarrolló en dos versiones documentadas. La versión 1, con 162 características derivadas únicamente del registro de siniestros, alcanzó PR-AUC 0.2249 y ROC-AUC 0.7482 en la referencia, empatada estadísticamente con la regresión logística: el diagnóstico fue un techo informacional. La versión 2 incorporó las bases companion oficiales del ONSV (vehículos y personas involucradas, enlazables por código de siniestro con cobertura total), agregando doce variables de escena —conteos y tipos de vehículos, personas involucradas y edad media— bajo las mismas reglas anti-fuga: los desenlaces por persona quedan vetados. Con el contrato de 175 características, la misma búsqueda pre-declarada (tres arquitecturas, tres semillas, selección por mediana de PR-AUC en 2023) eligió MLP_32_16 con semilla 314.

En la referencia 2024–2025, evaluada una única vez por versión y con divulgación explícita de que la versión 2 constituye la segunda consulta a ese periodo, la MLP calibrada obtuvo PR-AUC 0.4416 [IC 95 %: 0.3785–0.5124], ROC-AUC 0.8841 [0.8613–0.9055], F1 multifatal 0.5058, precisión 0.4452, *recall* 0.5856, Brier 0.0683 y ECE 0.0169. El salto frente a la versión 1 (PR-AUC de 0.22 a 0.44) confirma empíricamente la hipótesis del techo informacional: la variable dominante según Gradient SHAP es el grupo de personas involucradas (43.7 % de la importancia). Un bootstrap pareado muestra que la red supera significativamente a la regresión logística en ROC-AUC ($\Delta=+0.026$, IC [+0.012, +0.042]) y empatata estadísticamente con el Random Forest.

La interfaz Streamlit consume un *bundle* de solo lectura con hashes verificados, incluye un selector de ubicación OpenStreetMap acotado al Perú con deducción determinística del departamento, un formulario de escena sin desenlaces, y demostraciones interactivas del modelo contra la realidad observada. El sistema constituye una demostración académica

reproducibile de clasificación de multifatalidad dentro del universo ONSV de siniestros fatales notificados.

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica desde 2021 una base a nivel de registro de todos los siniestros fatales del país, con variables de contexto pre-impacto que los registros administrativos anteriores no incluían: zona rural/urbana, red vial, condición climática, característica de la vía (recta, curva, intersección), perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?* La consigna del curso pide una red neuronal para predicción o clasificación con un dataset de la región o a nivel nacional, acompañada de análisis exploratorio, preprocesamiento, ingeniería de características, una interfaz gráfica y un informe. En rigor técnico, el problema abordado es de **clasificación binaria** multifatal/letalidad-simple: la salida es una categoría discreta, y al clasificarla el modelo también produce una probabilidad de siniestro multifatal, lo que cubre ambos términos de la consigna con precisión.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, con al menos ocho hallazgos interpretados.

- **OE2.** Construir al menos doce características derivadas de las variables pre-impacto del registro, cada una justificada.
- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier` (clase mayoritaria), regresión logística y *random forest*. El MLP debe superar claramente al `DummyClassifier`; si no supera a la regresión logística o al *random forest*, se reporta y discute honestamente.
- **OE4.** Identificar los cinco factores de mayor influencia en la alta letalidad mediante SHAP.
- **OE5.** Desplegar una interfaz gráfica en Streamlit que reutilice el pipeline de entrenamiento sin discrepancias.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello se fijaron las métricas antes de ver los datos, como hace un profesional:

- Selección de arquitectura: **mayor mediana de PR-AUC en validación 2023 entre semillas**; desempates por mayor F1 mediana y, después, menor IQR de PR-AUC. Esta regla se fija antes de consultar 2024–2025.
- Métricas de reporte obligatorio: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* solo como referencia.
- Se prohíbe argumentar calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Selección de umbral: máximo F1 en validación, con desempates predeclarados por *recall*, precisión y mayor umbral; no se ajusta después de observar 2024–2025.

3. Marco teórico

3.1. Seguridad vial y alcance condicional

La severidad vial es multifactorial: interactúan infraestructura, condiciones ambientales, vehículo, conductor y respuesta posterior. La base ONSV utilizada registra exclusivamente siniestros con al menos un fallecido; por ello, el modelo no estima ocurrencia ni fatalidad general. Su pregunta es condicional: *dado un siniestro ya fatal y notificado, ¿el registro pertenece a la clase multifatal?* Esta restricción evita mezclar universos incompatibles y define un uso de priorización posterior a la notificación [6, 8].

3.2. Perceptrón multicapa

Una neurona calcula $a = f(Wx + b)$. Un perceptrón multicapa (MLP) encadena capas densas y aprende relaciones no lineales mediante retropropagación [1]. Para las dos capas ocultas del modelo canónico:

$$\hat{y} = \sigma(W_3 f(W_2 f(W_1 x + b_1) + b_2) + b_3),$$

donde f es ReLU y σ es sigmoide. La salida sigmoide es un *score* crudo; no debe llamarse probabilidad operacional hasta evaluar su calibración.

La pérdida es entropía cruzada binaria ponderada:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [w_1 y_i \log \hat{y}_i + w_0 (1 - y_i) \log(1 - \hat{y}_i)].$$

Se usó Adam con tasa inicial 1×10^{-3} , lotes de 64, pesos de clase, *dropout* 0.25, regularización L2 de 1×10^{-4} y parada temprana por PR-AUC de validación [4].

3.3. Evaluación bajo desbalance

La clase multifatal representa alrededor del 10 %, por lo que la exactitud aislada es insuficiente. Se reportan precisión, *recall*, F1, PR-AUC, ROC-AUC, matriz de confusión e intervalos bootstrap. PR-AUC debe leerse contra la prevalencia: un clasificador sin capacidad de ordenamiento obtiene aproximadamente la tasa positiva.

El umbral transforma scores en clases. La política canónica maximiza F1 en validación y desempata por *recall*, precisión y mayor umbral. La salida cruda y la calibrada pertenecen a escalas distintas: el umbral 0.80 solo corresponde al score sigmoide, mientras que 0.30 solo corresponde a la probabilidad Platt.

3.4. Calibración probabilística

La calibración pregunta si, entre casos con probabilidad predicha cercana a p , la frecuencia observada también se aproxima a p . Se evalúa con Brier, ECE y curva de confiabilidad. Platt aplica una regresión logística al score; isotónica aprende una función monótona por tramos. Ambos métodos se compararon con predicciones *out-of-fold* de cinco particiones exclusivamente en validación 2023, siguiendo implementaciones reproducibles de scikit-learn [7]. La calibración puede mejorar Brier y ECE, pero, si conserva el orden, no cambia PR-AUC ni ROC-AUC.

3.5. Control de fuga y reproducibilidad

Se aplicaron tres barreras:

1. Las columnas de resultado (fallecidos, lesionados y vehículos dañados), causa post-investigación y señales con faltantes dependientes del periodo no entran al modelo.
2. Escalador, codificadores y frecuencias de vía se ajustan solo con 2021–2022. Arquitectura, semilla, calibración y umbrales se seleccionan solo con 2023.
3. Los resultados 2024–2025 ya fueron observados; quedan congelados como referencia histórica y no autorizan nuevos ajustes.

Semillas, versiones, hashes, esquema y artefactos se registran en el manifiesto canónico `manifest.json`.

3.6. Interpretabilidad con Gradient SHAP

SHAP distribuye el cambio del score entre las variables respecto de un fondo [5]. Se aplicó `shap.GradientExplainer` al score crudo de la MLP con 256 registros de fondo de entrenamiento 2021–2022 y 512 registros explicados de validación 2023. Las 175 características procesadas se agregaron en 20 grupos interpretables. La contribución firmada media no es un efecto monotónico, una recomendación de intervención ni evidencia causal.




Figura 1: Arquitectura canónica MLP_32_16. La salida cruda se calibra después con Platt; la calibración no cambia los pesos.

4. Metodología

4.1. Diseño experimental definitivo

El proyecto sigue CRISP-DM con una separación cronológica estricta. Este corte es el mecanismo definitivo para medir deriva entre periodos y bloquear el uso de información futura.

Tabla 1: Particiones y usos permitidos del protocolo canónico.

Partición	Periodo	n	Positivos	Uso autorizado
Entrenamiento	2021–2022	4 872	510	Ajuste de preprocesamiento y pesos
Validación	2023	2 000	196	Arquitectura, semilla, umbrales y calibración OOF
Referencia histórica	2024–2025	2 232	222	Informe final; sin selección ni reajuste

4.2. Flujo reproducible

```

base_limpia.parquet  $\xrightarrow{\text{corte cronológico}}$  {2021–22, 2023, 2024–25}
 $\xrightarrow{\text{fit solo 2021–22}}$  175 features procesadas
 $\xrightarrow{\text{selección 2023}}$  MLP_32_16, seed 314, t=0.80
 $\xrightarrow{\text{5-fold OOF 2023}}$  Platt + umbral calibrado 0.30
 $\xrightarrow{\text{congelar}}$  models/final/
 $\xrightarrow{\text{referencia 2024–25}}$  métricas, IC y errores.
  
```

4.3. Selección del modelo

Se compararon tres configuraciones MLP y tres semillas (42, 314 y 2718). La configuración se eligió por mediana de PR-AUC en validación, luego mediana de F1 y finalmente menor rango intercuartílico de PR-AUC. La semilla 314 quedó asociada al artefacto seleccionado. Los mismos datos y la misma política de umbral se aplicaron a regresión logística balanceada y Random Forest balanceado para evitar comparaciones ventajosas.

4.4. Calibración y umbrales

Platt e isotónica se compararon mediante Brier OOF de cinco particiones estratificadas dentro de 2023 [7]. Se seleccionó Platt por menor Brier OOF; el umbral calibrado 0.20 maximizó F1 sobre esas probabilidades OOF. El umbral crudo 0.65 proviene de la política predeclarada sobre scores de validación. Las escalas no se mezclan y la interfaz toma decisiones visibles solo en la escala calibrada.

4.5. Evaluación e incertidumbre

Se reportan dos vistas del mismo modelo congelado: score crudo y probabilidad Platt. Para las métricas de referencia se calcularon 1000 remuestreos bootstrap al 95 %. La evaluación incluye comparación con prevalencia, regresión logística y Random Forest; no se realizan pruebas o ajustes posteriores que reclasifiquen 2024–2025 como un nuevo periodo no observado.

4.6. Explicabilidad separada de la referencia

Gradient SHAP se ejecutó sin cargar etiquetas ni datos de 2024–2025 [5]. El fondo procede de entrenamiento y la muestra explicada de validación. Esta separación evita que la interpretación se convierta en una vía indirecta de ajuste a la referencia.

4.7. Implementación

La implementación usa Python 3.12, TensorFlow 2.19, scikit-learn 1.9, pandas 3.0, NumPy 2.1, SHAP 0.52, Streamlit y Plotly [2, 3, 7]. `models/final/manifest.json` fija versiones, hashes, particiones, arquitectura, calibrador y umbrales; el cargador de inferencia rechaza artefactos alterados.

5. Dataset

5.1. Fuente oficial

Se utilizó la base *SINIESTROS DE TRANSITO FATALES 2021–2025 (PRELIMINAR)*, publicada el 2026-02-27 por el Observatorio Nacional de Seguridad Vial (ONSV) en su portal de datos abiertos:

<https://www.onsv.gob.pe/datosabiertos>

El portal describe el recurso como: “Detalle de siniestros de tránsito con consecuencias fatales, ocurridos a nivel nacional, 2021–2025 (preliminar)”, autor ONSV. El archivo original se mantiene en `data/raw/BDD_ONSV_SINIESTROS_FATALES_2021-2025.xlsx` (hoja SINIESTROS, encabezado en la fila 5). La fecha de descarga y verificación local fue el 2026-07-09. Es un dato abierto del Estado peruano, lo que permite libre reuso con atribución. El ONSV declara la información de 2025 como preliminar.

5.2. Adecuación de la fuente

La base ONSV aporta fecha, hora, localización, clase notificada, clima, geometría, superficie y clasificación vial. Estas variables permiten estudiar asociaciones de multifatalidad sin mezclar fuentes con criterios de registro incompatibles. Su límite es igualmente claro: al contener solo siniestros fatales, obliga a formular un objetivo condicional de alta letalidad y no una predicción de mortalidad general.

5.3. Diccionario de datos base

La Tabla 2 resume las variables del registro y su rol en el proyecto.

Tabla 2: Variables del registro ONSV y su rol en el proyecto.

Columna	Rol	Justificación
FECHA, HORA	Característica (derivar)	Estacionalidad, nocturnidad, fatiga
DEPARTAMENTO	Característica categórica	Geografía del riesgo
ZONA	Característica categórica	Ruralidad: velocidades y respuesta médica
RED VIAL	Característica categórica	Nacional/departamental/provincial/urbana
TIPO DE VÍA	Característica categórica	Carretera, avenida, calle, vía expresa
COD CARRETERA	Característica (derivar)	Familias de vías y frecuencia
COORDENADAS	Característica numérica	Señal espacial continua
CONDICIÓN CLIMÁTICA	Característica categórica	Visibilidad y adherencia
CARACTERÍSTICAS DE VÍA	Característica categórica	Recta, curva, intersección, estructura
PERFIL LONGITUDINAL	Característica categórica	Plana vs. inclinada
SUPERFICIE DE CALZADA	Característica categórica	Pavimentada, afirmado, trocha
CLASE SINIESTRO	Característica categórica	Mecánica del evento
CANTIDAD DE FALLECIDOS	Solo target	Prohibida como entrada
CANTIDAD DE LESIONADOS	Excluida	Resultado posterior (fuga)
CANTIDAD VEHÍCULOS DAÑADOS	Excluida	Resultado posterior (fuga)
CAUSA (factor y específica)	Excluida	Se determina en la investigación posterior
SEÑALES vertical/horizontal	Excluida	78 % de faltantes concentrados por periodo

5.4. Bases companion: vehículos y personas involucradas (versión 2)

El ONSV publica en el mismo portal dos bases a nivel de registro enlazables por CÓDIGO SINIESTRO: `data/raw/BDD_ONSV_VEHICULOS_2021-2025.xlsx` (12 667 filas, una por vehículo involucrado) y `data/raw/BDD_ONSV_PERSONAS_2021-2025.xlsx` (25 412 filas, una por persona involucrada, hasta 74 en un mismo siniestro). La cobertura del join es del 100 % sobre los 9 104 códigos de la base limpia.

De estas tablas se derivan doce agregados de escena por siniestro: total de vehículos; conteos de buses/minibuses, pesados de carga, motos/trimotos y vehículos no identifica-

dos; servicios interprovinciales y de transporte público; total de personas involucradas; pasajeros, peatones y conductores fugados; y edad media de los involucrados. Son hechos observables al caracterizar la notificación, con el mismo estatus epistémico que la clase del siniestro. Quedan **vetadas por fuga** las columnas de desenlace por persona (**GRAVEDAD**, lugar de atención y de defunción) y los dosajes étlicos, que se determinan después. El conteo de personas involucradas es la variable de exposición del problema: un siniestro con un solo involucrado no puede ser multifatal, del mismo modo que la clase describe la mecánica; se declara como limitación que el registro de ilesos podría ser más completo en siniestros graves.

5.5. Variable objetivo

Se construyó el target binario condicional al universo de siniestros fatales:

$$y = \begin{cases} 1, & \text{si FALLECIDOS} \geq 2 \quad (\text{“Alta Letalidad”}) \\ 0, & \text{si FALLECIDOS} = 1 \end{cases}$$

La prohibición de **LESIONADOS**, **VEHICULOS_DANADOS** y las columnas de causa como entradas se declara explícitamente como decisión metodológica en la Sección 7: los conteos se levantan después del siniestro (fuga directa del resultado) y la causa se codifica al cierre de la investigación (el 49 % figura “en proceso de investigación”).

5.6. Auditoría inicial

La auditoría (Bloque B) verificó y registró:

- Formato: Excel (.xlsx), hoja **SINIESTROS**, encabezado en fila 5, 27 columnas.
- Número de filas de datos: 9 106.
- Fechas inválidas eliminadas: 2. Duplicados por código de siniestro: 0.
- N final útil: 9 104.
- Casos multifatales: 928 (10.19 %); letalidad simple: 8 176.
- Rango temporal: 2021-01-01 a 2025-12-30 (2025 parcial, 678 registros).
- Coordenadas fuera del territorio peruano anuladas: 1 registro.

El protocolo usa un corte cronológico 2021–2022 / 2023 / 2024–2025. Como la clase multifatal representa 10.19 %, se usan pesos de clase sin SMOTE: sintetizar combinaciones categóricas y geográficas habría introducido casos difíciles de justificar. Tabla 3 resume la auditoría de fuente.

Tabla 3: Resumen de la auditoría del dataset (Bloque B).

Indicador	Valor
Filas de datos originales	9 106
Fechas inválidas eliminadas	2
Duplicados por código	0
Filas útiles finales	9 104
Casos multifatales (2+ fallecidos)	928
Porcentaje de clase multifatal	10.19 %
Rango temporal	2021–2025 (2025 parcial)
Máximo de fallecidos en un siniestro	33

6. Análisis exploratorio de datos

Se ejecutó el análisis exploratorio sobre `base_limpia.parquet`: cada figura se guardó numerada en `report/figures/` (150 dpi, títulos y ejes en español) y cada figura tiene 2–4 líneas de interpretación escrita. Se generaron 14 figuras y un conjunto de hallazgos numerados H1–H11 que alimentaron las decisiones de ingeniería de características.

6.1. Distribución del objetivo y desbalance




Figura 2: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con F1, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales




Figura 3: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 4: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).



Figura 5: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.




Figura 6: Siniestros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro



Figura 7: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 8: Tasa multifatal por clase. DES-PISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 9: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).




Figura 10: Top-15 departamentos por ta-sa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto




Figura 11: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1032 casos (H7).




Figura 12: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables aportan contexto inicial relevante para el modelo.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía




Figura 13: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.




Figura 14: Porcentaje de faltantes por columna. Las señales viales alcanzan 77.9 % (H10) y por eso se excluyen del modelo; el resto admite imputación simple con *flags*.




Figura 15: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Se redactaron once hallazgos en prosa, cada uno con referencia a su figura. Los más relevantes para el modelado:

- **H1:** la clase multifatal representa 10.2 % de los siniestros fatales (figura 2), confirma desbalance y justifica las métricas.
- **H3:** la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 4 y 5).
- **H5:** CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 7 y 8).
- **H6:** LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCARELI lidera la tasa multifatal con 28.0 % (figuras 9 y 10).
- **H8:** zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 12). Las condiciones pre-impacto separan el riesgo.
- **H11:** el scatter geográfico (figura 15) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

7.1. Contrato anti-fuga

El target es `target_multifatal=1` cuando `FALLECIDOS` ≥ 2 . Por ser resultado directo, `FALLECIDOS` no entra a X . También se excluyen `LESIONADOS`, `VEHICULOS_DANADOS`, causas post-investigación y señalización con faltantes dependientes del periodo. De las bases `companion` se excluyen la gravedad por persona, los lugares de atención y defunción y los dosajes étlicos; solo entran conteos y atributos de escena. La clase del siniestro y los agregados de vehículos/personas están disponibles después de la notificación; esto limita el uso a priorización posterior al hecho y descarta cualquier interpretación preventiva.

7.2. Corte cronológico

Las fechas determinan tres bloques sin solapamiento: 2021–2022 para entrenamiento, 2023 para validación y calibración, y 2024–2025 para referencia histórica. El escalador, las categorías, el mapa de frecuencias de vía y cualquier imputación se ajustan únicamente con entrenamiento. Los transformadores no vuelven a ajustarse al procesar periodos posteriores.

7.3. Limpieza y codificación

Las categorías se normalizan a vocabularios cerrados con una categoría explícita `DESCONOCIDO`. Los códigos de carretera no vistos reciben frecuencia cero. Latitud y longitud se convierten a numérico; el *bundle* final exige el par completo para inferencia y la interfaz no inventa ubicaciones. Las continuas se estandarizan con estadísticos 2021–2022; las variables cíclicas permanecen en $[-1, 1]$ y las categóricas se codifican *one-hot*.

7.4. Contrato persistido

`models/final/` contiene `feature_list.json`, `feature_schema.json`, escalador, codificadores, modelo, calibrador, umbrales y manifiesto. El manifiesto registra hashes SHA-256 y el cargador de inferencia los verifica antes de predecir. El vector final tiene exactamente 175 columnas y el orden es parte del contrato.

7.5. Pruebas de frontera

Las pruebas automatizadas verifican que:

- las particiones temporales no se solapen;
- validación, no la referencia, seleccione umbrales y calibración;
- el modelo, el esquema y la lista tengan 175 entradas en el mismo orden;
- las escalas cruda y calibrada conserven umbrales distintos;
- el par de coordenadas sea obligatorio en la inferencia final;
- una entrada inválida elimine cualquier resultado previo de la interfaz.

Los casos de demostración prueban ejecución, no desempeño.

8. Ingeniería de características

El contrato canónico de la versión 2 tiene 175 características construidas a partir de información disponible al registrar inicialmente un siniestro ya fatal. No se agregaron variables externas inventadas ni proxies del desenlace.

Tabla 4: Familias principales del contrato canónico.

Familia	Transformación	Ejemplos	Justificación
Temporal	Cíclica + indicadores	mes, día semanal, hora, nocturnidad, fin de semana	Respetar proximidad circular y faltantes
Geográfica	Escalado + <i>one-hot</i>	latitud, longitud, departamento, región natural	Contexto territorial sin usar el resultado
Vía	Frecuencia + categorías	código, prefijo, red, tipo, zona	Maneja cardinalidad y códigos nuevos
Escena inicial	Categorías cerradas	clase, clima, geometría, perfil, superficie	Disponible después de la notificación
Escena agregada (v2)	Conteos escalados	vehículos, buses, pesados, motos, interprovincial, personas, pasajeros, peatones, fugados, edad media	Exposición y composición vehicular del evento, sin desenlaces por persona
Interacciones	Productos predeclarados	noche×rural, lluvia×curva, tipo×zona, red×clase	Permite relaciones no aditivas defendibles
Faltantes	Indicadores explícitos	hora faltante, coordenadas faltantes, edad faltante	Evita imputación silenciosa

La versión 1 del contrato tenía 162 características; la versión 2 agrega los doce agregados de escena de las bases companion más el indicador de edad faltante. Los conteos se estandarizan con estadísticos de entrenamiento 2021–2022 y la edad media se imputa con la mediana de entrenamiento acompañada de su indicador. El contrato se congeló antes de la evaluación de referencia de la versión 2.

8.1. Disponibilidad y alcance

Fecha, hora, ubicación y vía pueden conocerse al despacho o geocodificarse; zona, clima, geometría y los agregados de vehículos y personas provienen de la caracterización inicial del evento; la clase se conoce después de la notificación. En cambio, fallecidos, lesionados, daños, gravedad por persona, dosajes y causas de investigación se excluyen. Esta auditoría respalda la afirmación precisa: el modelo prioriza registros posteriores al evento, no previene siniestros antes de que ocurran.

9. Modelo neuronal

9.1. Búsqueda cerrada y reproducible

Se definieron tres arquitecturas regularizadas y tres semillas antes de consultar el periodo de referencia 2024–2025. Cada corrida usó el mismo entrenamiento 2021–2022 y validación 2023, con entropía cruzada binaria, pesos de clase, Adam, reducción de tasa de aprendizaje y parada temprana por PR-AUC. La configuración se eligió por mediana de PR-AUC entre semillas; F1 mediana y menor dispersión actuaron como desempates. La misma búsqueda se ejecutó íntegra para la versión 2 con las 175 características.

Tabla 5: Robustez de configuraciones en validación 2023 (contrato v2 de 175 características).

Configuración	PR-AUC mediana	F1 mediana	IQR PR-AUC
MLP_32_16: 32–16	0.4806	0.5093	0.0058
MLP_64_32: 64–32	0.4682	0.5154	0.0047
MLP_32: 32	0.4656	0.5118	0.0080




Figura 16: PR-AUC de validación por configuración y semilla. MLP_32_16 presenta la mayor mediana; la variación entre semillas se conserva como evidencia, no se oculta. Nótese que la arquitectura ganadora de la versión 1 (MLP_64_32) deja de serlo con el contrato v2: la regla predeclarada decide, no la preferencia.

9.2. Arquitectura congelada

La MLP canónica es MLP_32_16 con semilla 314: entrada de 175 variables, capas densas de 32 y 16 neuronas con ReLU, *dropout* 0.25, L2 de 1×10^{-4} , Adam con 1×10^{-3} y lote 64. El modelo final conserva exactamente el hash del artefacto seleccionado; materializar `models/final/` no reentrena ni vuelve a buscar pesos.

9.3. Comparadores y política de umbral

El clasificador constante por prevalencia, la regresión logística balanceada y el Random Forest balanceado se entrenaron con las mismas particiones; los dos modelos aprendidos recibieron las mismas 175 variables. Para cada modelo, el umbral se escogió solo en validación con la misma regla: máximo F1; empates por *recall*, precisión y mayor umbral. Para la MLP cruda se obtuvo 0.80.

9.4. Calibración Platt OOF

Sobre los scores de validación 2023 se generaron predicciones OOF con cinco particiones estratificadas. En esa selección, Platt obtuvo Brier OOF 0.0652 (ECE 0.0086) y quedó seleccionado frente a la isotónica. El umbral calibrado 0.30 se eligió sobre probabilidades OOF calibradas. Estos valores pertenecen exclusivamente a validación; el Brier 0.0683 informado en resultados corresponde a la referencia histórica 2024–2025 después de ajustar Platt con toda la validación. El procedimiento separa selección y referencia, y evita usar las etiquetas 2024–2025 para elegir el calibrador [7].

9.5. Artefactos canónicos

El directorio `models/final/` contiene:

- `model.keras`, `scaler.joblib` y `encoders.joblib`;
- `feature_list.json` y `feature_schema.json`;
- `calibrator.joblib` y `thresholds.json`;
- `calibration_selection.json` y `manifest.json`.

Los hashes permiten demostrar que la aplicación ejecuta el mismo stack que sustenta el informe. La versión del bundle es `canonical-2.0.0`; la versión 1 permanece íntegra en la historia de Git.

10. Resultados

10.1. Estatus de la evaluación

Los 2 232 registros de 2024–2025 contienen 222 casos multifatales (prevalencia 0.0995). Sus etiquetas ya fueron observadas por la versión 1; en consecuencia, los resultados de la versión 2 constituyen la **segunda evaluación predeclarada** sobre esa referencia histórica y se divulgan como tal. Todo el diseño de la versión 2 (contrato de 175 características, grilla, semillas, reglas de selección, calibración y umbrales) se congeló usando exclusivamente 2021–2023, antes de volver a consultar la referencia; después de observarla no se modificó nada.

10.2. MLP cruda y calibrada

Tabla 6: Métricas canónicas e intervalos bootstrap al 95 % (1 000 remuestreos).

Métrica	Score crudo, $t = 0.80$	Platt, $t = 0.30$
F1 multifatal	0.4957 [0.4413, 0.5470]	0.5058 [0.4512, 0.5566]
Precisión multifatal	0.4715 [0.4106, 0.5323]	0.4452 [0.3879, 0.5000]
<i>Recall</i> multifatal	0.5225 [0.4561, 0.5872]	0.5856 [0.5194, 0.6489]
PR-AUC	0.4416 [0.3785, 0.5124]	0.4416 [0.3785, 0.5124]
ROC-AUC	0.8841 [0.8613, 0.9055]	0.8841 [0.8613, 0.9055]
Brier	0.1081	0.0683 [0.0609, 0.0756]
ECE, 10 bins	0.1044	0.0169 [0.0115, 0.0297]

La calibración transforma la escala, no el orden: PR-AUC y ROC-AUC son idénticos. Su aporte aparece donde corresponde, en Brier y ECE. El Brier calibrado 0.0683 mejora con claridad al predictor constante de prevalencia, cuyo Brier es aproximadamente $0.0995(1 - 0.0995) = 0.0896$.

Con el umbral calibrado, la matriz contiene 1 848 verdaderos negativos, 162 falsos positivos, 92 falsos negativos y 130 verdaderos positivos. El modelo identifica el 58.6 % de los multifatales y el 44.5 % de sus alertas son verdaderas: 4.5 veces la prevalencia base.

10.3. Comparación entre versiones: el techo informacional, demostrado

La versión 1 usaba únicamente el registro de siniestros (162 características). La versión 2 agrega los agregados de escena de las bases companion de vehículos y personas. Todo lo demás —particiones, reglas de selección, calibración OOF, política de umbral— es idéntico. La Tabla 7 muestra el efecto.

Tabla 7: Versión 1 vs. versión 2 sobre la misma referencia 2024–2025 (escala calibrada).

	Versión 1	Versión 2	Cambio
Características	162	175	+12 agregados de escena
Arquitectura seleccionada	MLP_64_32	MLP_32_16	regla predeclarada, se
PR-AUC	0.2249	0.4416	×1.96 (prevalencia
ROC-AUC	0.7482	0.8841	+0.136
F1 multifatal	0.2958	0.5058	+0.210
Precisión	0.2359	0.4452	alertas verdaderas: de 1 de
<i>Recall</i>	0.3964	0.5856	FN: de 134 a 1
Brier / ECE	0.0831 / 0.0085	0.0683 / 0.0169	ambas escalas calibradas
Grupo SHAP dominante	clase del siniestro	personas involucradas (43.7 %)	la variable nueva d

Esta comparación es el hallazgo central del proyecto: la versión 1 diagnosticó un techo informacional (empate estadístico con la regresión logística, discriminación moderada); la versión 2 lo puso a prueba incorporando la variable mecánica faltante —cuántas personas y qué vehículos estaban involucrados— y la discriminación prácticamente se duplicó. El salto no proviene de más capas ni de más épocas: proviene de mejor información, incorporada con las mismas reglas anti-fuga.

10.4. Comparación honesta con líneas base

Tabla 8: Comparación en la misma referencia temporal y con umbrales seleccionados solo en validación (contrato v2 compartido).

Modelo / escala	F1	Precisión	Recall	PR-AUC	ROC-AUC
MLP cruda	0.4957	0.4715	0.5225	0.4416	0.8841
MLP Platt	0.5058	0.4452	0.5856	0.4416	0.8841
Constante por prevalencia	0.1809	0.0995	1.0000	0.0995	0.5000
Regresión logística	0.4896	0.4230	0.5811	0.4334	0.8580
Random Forest	0.4943	0.4300	0.5811	0.4704	0.8937

Para cuantificar las diferencias se ejecutó un **bootstrap pareado** sobre las predicciones congeladas (2 000 remuestreos de registros, semilla 42, IC percentil; los dos baselines se reajustan con la receta exacta publicada y el script aborta si no reproducen las métricas del bundle). La Tabla 9 resume el resultado.

Tabla 9: Bootstrap pareado de la MLP contra cada baseline sobre la referencia 2024–2025 (`final_paired_bootstrap_2024_2025.csv`). Δ = MLP – baseline, escala cruda con umbrales de validación.

Baseline	Métrica	Δ	IC 95 % de Δ	$P(\Delta > 0)$	Significativa
Logística	PR-AUC	+0.0082	[−0.0184, +0.0362]	0.717	No
Logística	ROC-AUC	+0.0261	[+0.0122, +0.0417]	1.000	Sí
Logística	F1	+0.0062	[−0.0311, +0.0419]	0.623	No
Random Forest	PR-AUC	−0.0288	[−0.0727, +0.0138]	0.089	No
Random Forest	ROC-AUC	−0.0096	[−0.0234, +0.0028]	0.072	No
Random Forest	F1	+0.0015	[−0.0378, +0.0390]	0.522	No

La lectura honesta tiene dos caras. Contra la regresión logística, la red ahora muestra una ventaja **estadísticamente significativa** en ROC-AUC: con las variables de escena, la no linealidad (interacciones entre composición vehicular, personas y contexto) aporta capacidad que el modelo lineal no captura. Contra el Random Forest, el bosque presenta mejor ranking nominal y la diferencia no es significativa en ninguna métrica: en tabulares medianos los ensambles de árboles siguen siendo competidores de primer nivel, y este informe lo reporta en lugar de ocultarlo. La consigna del curso —una red neuronal correctamente construida y evaluada— se cumple con una red que ya no es meramente equivalente al baseline lineal.

Evidencia histórica 2024-2025: comparación honesta




Figura 17: Comparación de PR-AUC, ROC-AUC y F1 entre la MLP definitiva y las líneas base en la referencia histórica.

10.5. Análisis de errores

Los 92 falsos negativos calibrados son el principal límite restante. Varios quedan apenas por debajo del umbral crudo: los primeros ejemplos (Apurímac, Cajamarca, febrero–marzo 2024) tienen scores 0.746–0.756 frente al corte 0.80. Esto demuestra que el umbral convierte diferencias pequeñas en decisiones distintas y que debe mostrarse la probabilidad, no solo la etiqueta. Los 162 falsos positivos implican carga de revisión, pero la precisión de 0.445 la vuelve manejable frente a la versión 1 (0.236). Las variables aún ausentes —velocidad, uso de cinturón/casco, antigüedad del vehículo, exposición— fijan el techo actual.

10.6. Explicabilidad global

La explicación canónica usa Gradient SHAP sobre la sigmoide cruda. El fondo contiene 256 registros de entrenamiento 2021–2022; se explican 512 registros de validación 2023 con 200 muestras SHAP y semilla 20260709. No se cargaron etiquetas ni datos 2024–2025. Las 175 variables procesadas se sumaron en 20 grupos interpretables.




Figura 18: Importancia Gradient SHAP por grupo interpretable en validación 2023. El signo resume la contribución media respecto del fondo, no un efecto causal.

Tabla 10: Cinco grupos con mayor importancia SHAP global (contrato v2).

Grupo	Features agrupadas	Participación	Dirección media
Personas involucradas	4	43.75 %	Aumenta score crudo
Vehículos involucrados	7	7.68 %	Reduce score crudo
Clase del siniestro	6	6.62 %	Reduce score crudo
Red vial × clase	30	6.04 %	Reduce score crudo
Departamento / región natural	29	4.97 %	Aumenta score crudo

El grupo de personas involucradas domina la explicación con el 43.75 % de la importancia: exactamente la variable cuya ausencia diagnosticó la versión 1. Las direcciones medias no significan que toda categoría de un grupo actúe igual, ni autorizan afirmaciones causales: SHAP describe asociaciones del modelo congelado y de la muestra de validación. No se generaron explicaciones locales para casos individuales.

11. Interfaz gráfica

11.1. Arquitectura de información

La interfaz Streamlit es un consumidor de solo lectura. No entrena, calibra, reescribe tablas ni modifica artefactos. Al iniciar, carga `models/final/manifest.json`, verifica hashes y comprueba que modelo, esquema y lista coincidan en 175 entradas.

Tabla 11: Flujo de información de la interfaz canónica.

Componente	Flujo	Responsabilidad
Formulario validado	→	Campos requeridos vacíos, opcionales como NO INFORMADO y caso demo explícito
app_inference	→	Valida periodo 2021–2025, código vial, par geográfico Perú–departamento y contrato de entrada
Bundle canónico	→	Verifica hashes; calcula score crudo y probabilidad Platt sin escribir archivos
Umbrales separados	→	0.30 para decisión visible calibrada; 0.80 solo para diagnóstico crudo
Presentación	→	Prioridad, contexto histórico, evidencia e incertidumbre con trazabilidad

11.2. Cinco páginas funcionales y enlazables

La navegación se sincroniza con el parámetro `?section=`; por ello cada página posee una URL compartible y el estado de navegación no queda oculto en pestañas internas.

1. **Panorama:** propósito en lenguaje llano, funcionamiento en tres pasos y tres demostraciones sobre la referencia 2024–2025: la serie mensual de tasa observada vs. probabilidad media predicha, la multifatalidad real por quintil de score (que crece monotónicamente con el score del modelo) y una comparación interactiva predicho vs. observado por categoría (clase, zona, clima, red vial, tipo de vía o departamento) con seguimiento mensual de la categoría elegida; todo con soporte mínimo de 30 e intervalos de Wilson.
2. **Estimar:** inicia sin valores plausibles precargados, ofrece *Cargar caso de demostración*, exige fecha, hora, clase, departamento y coordenadas, y muestra un gauge Platt. La ubicación puede seleccionarse con un clic sobre un mapa OpenStreetMap (Folium/Leaflet) acotado al Perú con los límites departamentales superpuestos; el clic completa los campos numéricos de latitud y longitud (la entrada canónica validada) y deduce el departamento mediante búsqueda point-in-polygon sobre los mismos polígonos versionados de la validación. Los campos de escena (zona, tipo de vía, clima) no se deducen del mapa: describen cómo el ONSV registró el siniestro y la interfaz lo declara. En la versión 2 el formulario agrega la sección de vehículos y personas involucradas (totales requeridos, desgloses por tipo, servicio interprovincial/público, conductores fugados y edad media opcional), con validación de coherencia (los desgloses no superan los totales) y sin ingresar ningún desenlace por persona.
3. **Explorar datos:** gráficos Plotly responsivos del target, serie mensual, tasas por clase y condiciones, mapa de puntos y matriz mes×hora. No reutiliza capturas EDA estáticas.
4. **Patrones regionales:** mapa, ranking y tabla departamental con intervalos de Wilson. Las tasas con soporte menor de 30 se enmascaran en lugar de presentarse como estimaciones estables.
5. **Evidencia del modelo:** comparación MLP/logística/Random Forest, confiabilidad, matriz de confusión, curvas PR/ROC y Gradient SHAP canónico. La matriz y las curvas incluyen tablas descargables como alternativa accesible.

11.3. Validación de entradas

La fecha se restringe al periodo cubierto por la evidencia, del 1 de enero de 2021 al 31 de diciembre de 2025. Un algoritmo geométrico puro sobre el GeoJSON versionado admite polígonos, multipolígonos y puntos de frontera; exige que las coordenadas pertenezcan al Perú y al departamento seleccionado. El código vial se busca entre los códigos persistidos y admite un código nuevo con formato oficial, mostrando que su frecuencia canónica será cero. Los campos de escena opcionales comienzan en NO INFORMADO. El subgrupo histórico coincidente se presenta únicamente con $n \geq 30$.

11.4. Decisión y contexto en escalas distintas

La decisión pública se calcula únicamente con la probabilidad Platt y el umbral 0.30. El score sigmoide y el umbral 0.80 aparecen en un panel separado para auditoría. Las tasas históricas incluyen soporte e intervalo de Wilson; son comparadores descriptivos y no se superponen conceptualmente con una probabilidad individual.

11.5. Validación funcional

`src/block_g_app_check.py` ejecuta comprobaciones de manifiesto, alineación de 175 variables, finitud, separación de escalas, ausencia de escrituras y latencia en caliente. Además, `streamlit.testing.AppTest` recorre las cinco URLs, verifica campos vacíos, carga demo explícita, resultado válido, coherencia geográfica, limpieza de estado obsoleto y alternativas tabulares. Las pruebas unitarias cubren fechas fuera de dominio, coordenadas interiores, exteriores, fronterizas y departamentalmente incoherentes, códigos viales conocidos y nuevos, separación de umbrales y soporte $n = 29/30$.

El gate `check_release.py` unifica pruebas directas, AppTest, hashes, paridad de 2232 inferencias, lectura segura de explicabilidad, escaneo de notebooks e imports, referencias obsoletas, vigencia del PDF y estado de Git. El modo local informa artefactos aún no versionados; el modo estricto los convierte en fallo de entrega.

No se incluyen capturas de pantalla de una sesión no verificable. La tabla de flujo y el código probado constituyen evidencia reproducible de la arquitectura; la apariencia interactiva se inspecciona ejecutando la aplicación localmente.

12. Discusión

12.1. El techo era informacional, y se demostró

La versión 1 cerró con un diagnóstico incómodo: discriminación moderada (PR-AUC 0.2249) y empate estadístico con la regresión logística. Dos explicaciones eran posibles: un problema intrínsecamente difícil o información insuficiente. La versión 2 arbitró entre ambas incorporando los agregados de escena de las bases companion del ONSV —cuántas personas y qué vehículos estaban involucrados— con las mismas particiones y reglas. El resultado (PR-AUC 0.4416, ROC-AUC 0.8841) respalda la segunda explicación: el límite no estaba en la arquitectura ni en el entrenamiento, sino en las variables. Este arbitraje empírico, y no una métrica aislada, es la contribución metodológica central del proyecto.

12.2. Segunda evaluación sobre la referencia: divulgación

Las etiquetas 2024–2025 ya habían sido observadas al evaluar la versión 1. La versión 2 se diseñó y congeló usando solo 2021–2023, pero su evaluación constituye una segunda consulta a la misma referencia y se declara como tal. El riesgo de sobreajuste por selección es acotado —no se tomó ninguna decisión con esas etiquetas— pero no es cero, y la magnitud del salto (que duplica el ranking) excede con holgura lo que podría atribuirse a esa multiplicidad. La validación definitiva de la versión 2 requiere, igual que siempre, un periodo futuro no observado.

12.3. Red neuronal frente a modelos tabulares

Con el contrato v2, la MLP supera a la regresión logística con significación estadística en ROC-AUC ($\Delta=+0.026$, IC 95 % $[+0.012, +0.042]$, bootstrap pareado): las interacciones entre composición vehicular, personas involucradas y contexto aportan no linealidad real que el modelo lineal no captura. Frente al Random Forest, el bosque muestra mejor ranking nominal (PR-AUC 0.470 vs. 0.442) sin significación en ninguna métrica. La conclusión profesional es matizada: la red ya no es un requisito académico empatado con un baseline lineal, pero tampoco domina a los ensambles de árboles, que en tabulares medianos siguen siendo el estándar de facto. Reportar ambos hechos es parte del rigor.

12.4. Calibración no es discriminación

Platt reduce Brier de 0.1081 a 0.0683 y ECE de 0.1044 a 0.0169, pero PR-AUC y ROC-AUC permanecen iguales: calibrar corrige la escala, no el orden. El umbral calibrado 0.30 proviene exclusivamente de validación OOF 2023 y no fue reajustado a la referencia.

12.5. Errores y utilidad real

Con 130 verdaderos positivos, 92 falsos negativos y 162 falsos positivos, el sistema identifica el 58.6 % de los multifatales con una precisión de 0.445 (4.5 veces la prevalencia). Como herramienta de priorización posterior a la notificación, revisar las alertas del modelo concentra casi la mitad de aciertos donde antes había uno de cada diez. Sigue sin ser una regla autónoma: un tercio de los multifatales queda fuera al umbral canónico, y los casos cercanos al corte muestran que la etiqueta binaria oculta información; por eso la interfaz siempre muestra la probabilidad.

12.6. Sesgos y variables ausentes

El registro ONSV proviene de partes administrativos, 2025 es preliminar y puede existir subregistro o cambios de codificación territorial. El conteo de involucrados podría registrarse con mayor completitud en siniestros graves (sesgo de registro que se declara, no se corrige). Aún faltan velocidad estimada, uso de cinturón/casco, antigüedad del vehículo y exposición vial; con la escena ya incorporada, esas variables fijan el próximo techo.

12.7. Alcance posterior al hecho

La clase del evento y los agregados de escena se conocen después de notificar el siniestro. El modelo no predice qué vía tendrá un accidente ni la probabilidad de fatalidad de

un viaje, y no debe extrapolarse a periodos futuros sin validación temporal nueva.

12.8. Lectura correcta de SHAP

El grupo de personas involucradas concentra el 43.75 % de la importancia global, seguido por vehículos involucrados y clase del siniestro. Esto describe cómo el modelo distribuye su score en 512 casos de validación respecto de 256 casos de fondo; coincide con el mecanismo causal plausible (más ocupantes, mayor techo de víctimas), pero SHAP por sí solo no establece causalidad ni recomienda intervenciones. La ausencia deliberada de explicaciones locales evita narrativas individuales no validadas.

13. Conclusiones

13.1. Cumplimiento de objetivos

- **EDA:** se caracterizaron 9 104 siniestros fatales y el desbalance multifatal, con hallazgos temporales, territoriales y de condiciones registradas.
- **Características:** se construyó un contrato de 175 variables de notificación inicial, incluidos doce agregados de escena de las bases companion de vehículos y personas, sin columnas de resultado o investigación posterior.
- **Modelo:** la búsqueda predeclarada (tres arquitecturas, tres semillas) seleccionó una MLP 32–16 regularizada con semilla 314; el periodo 2024–2025 no participó en ninguna decisión.
- **Evaluación:** la MLP calibrada obtuvo PR-AUC 0.4416 [0.3785–0.5124], ROC-AUC 0.8841 [0.8613–0.9055] y F1 0.5058, con ventaja estadísticamente significativa sobre la regresión logística en ROC-AUC y empate estadístico con el Random Forest. La comparación $v1 \rightarrow v2$ (PR-AUC 0.2249 $\rightarrow$ 0.4416) demuestra empíricamente que el techo previo era informacional.
- **Interpretabilidad:** Gradient SHAP se ejecutó únicamente con entrenamiento y validación, agrupando 175 features en 20 grupos; el grupo de personas involucradas domina con 43.75 %, coherente con la mejora observada.
- **Interfaz:** la app de cinco secciones consume un stack canónico de solo lectura con hashes, incluye selector de ubicación OpenStreetMap con deducción de departamento, formulario de escena sin desenlaces, y demostraciones interactivas del modelo contra la realidad observada.

13.2. Conclusión general

El proyecto entrega dos cosas a la vez: un sistema auditable y una demostración de método. La versión 1 construyó el andamiaje —corte cronológico, anti-fuga verificada por máquina, calibración OOF, comparación pareada, gate reproducible— y diagnosticó con honestidad su límite: empate con un modelo lineal por falta de información mecánica. La versión 2 usó ese diagnóstico para buscar la información faltante en las bases oficiales enlazables, y el salto de desempeño (ranking casi duplicado, precisión de 0.24 a 0.45, recall

de 0.40 a 0.59, probabilidades calibradas con ECE 0.017) valida tanto la hipótesis como el procedimiento. La red, además, ya aporta no linealidad medible sobre la logística.

Las limitaciones se declaran sin maquillaje: la evaluación v2 es la segunda consulta a la referencia 2024–2025 y se divulga como tal; el Random Forest compite de igual a igual en ranking; un tercio de los multifatales sigue fuera al umbral canónico; y el registro hereda los sesgos del parte policial. La siguiente evaluación válida exige un periodo futuro no observado, y el siguiente salto de desempeño, variables de velocidad, protección y exposición. El proyecto entrega lo comprometido y declara lo no comprometido.

14. Anexos

14.1. A1. Fuente y diccionario

La base ONSV conserva encabezados descriptivos en la hoja SINIESTROS. El mapeo a nombres canónicos está en `src/block_b_dataset_audit.py`; la auditoría agregada está en `report/tables/tab00_audit_summary_block_b.json`.

14.2. A2. Artefactos definitivos

- Bundle de inferencia y manifiesto: `models/final/`.
- Protocolo: `report/tables/final_model_protocol.md`.
- Métricas, probabilidades, confusión, errores e intervalos: tablas de referencia final.
- Selección y robustez: tablas de selección y `models/final/model_selection.json`.
- Explicabilidad: tablas y figura de importancia global.

14.3. A3. Configuración congelada

```
1 canonical = {  
2     "config_id": "MLP_32_16",  
3     "hidden_units": [32, 16],  
4     "dropout": 0.25,  
5     "l2": 1e-4,  
6     "learning_rate": 1e-3,  
7     "batch_size": 64,  
8     "seed": 314,  
9     "feature_count": 175,  
10    "raw_threshold": 0.80,  
11    "calibrated_threshold": 0.30,  
12    "calibration": "platt",  
13 }
```

14.4. A4. Protocolo cronológico

```
1 train = data[data.FECHA.dt.year.isin([2021, 2022])]  
2 selection = data[data.FECHA.dt.year.eq(2023)]  
3 reference = data[data.FECHA.dt.year.isin([2024, 2025])]
```

```

4
5 # Fit preprocessing and weights: train only.
6 # Select architecture, seed, calibration and thresholds: selection only.
7 # Reference 2024-2025: reporting only; no further tuning.

```

14.5. A5. Decisiones metodológicas

Tabla 12: Controles del modelo definitivo.

Etapa	Decisión	Riesgo controlado	Evidencia
Protocolo	Separar 2021–22, 2023 y 2024–25 por rol	Fuga y optimismo por mezcla cronológica	Protocolo final
Selección	Comparar 3 arquitecturas $\times$ 3 semillas; congelar MLP_32_16, semilla 314	Selección oportunista	Registro de selección
Versión 2	Incorporar bases companion (vehículos/personas) con desenlaces vetados; segunda evaluación divulgada	Fuga desde tablas enlazadas y multiplicidad silenciosa	Auditoría del join y Tabla 7
Calibración	Elegir Platt mediante Brier OOF de 5 folds en 2023	Ajustar y evaluar calibrador en los mismos casos	Registro de calibración
Referencia	Tratar 2024–25 como periodo ya observado	Reutilizarlo para nuevos ajustes	Métricas finales
SHAP	Gradient SHAP solo con entrenamiento y selección	Interpretación contaminada por la referencia	Procedencia SHAP
Interfaz	Bundle verificado, solo lectura, decisión en escala calibrada	Divergencia informe/aplicación	Manifiesto canónico

14.6. A6. Reproducción y verificación

```

1 # Rebuild evidence without retraining the MLP
2 .venv/bin/python src/final_model_bundle.py
3 .venv/bin/python src/final_evaluation_figures.py
4 .venv/bin/python src/final_explainability.py
5
6 # Contracts and GUI
7 .venv/bin/python tests/test_model_protocol.py
8 .venv/bin/python tests/test_final_model_bundle.py
9 .venv/bin/python tests/test_final_explainability.py
10 .venv/bin/python tests/test_app_inference.py
11 .venv/bin/python src/block_g_app_check.py
12
13 # Interface
14 streamlit run app/streamlit_app.py
15
16 # Report
17 cd report && latexmk -pdf -interaction=nonstopmode main.tex

```

Las versiones exactas usadas para el bundle constan en el manifiesto. La reproducción no autoriza reoptimizar el modelo con la referencia 2024–2025.

Referencias

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [2] Google Brain Team. Tensorflow: Large-scale machine learning on heterogeneous systems. <https://www.tensorflow.org/>, 2024.
- [3] Keras Team. Keras 3 documentation. <https://keras.io/>, 2024.
- [4] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [5] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, pages 4765–4774, 2017.
- [6] Observatorio Nacional de Seguridad Vial (ONSV). Siniestros de tránsito fatales 2021-2025 (preliminar). <https://www.onsv.gob.pe/datosabiertos>, 2026. Publicado el 2026-02-27; detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional, 2021–2025 (preliminar); verificado localmente el 2026-07-09.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, et al. scikit-learn: Machine learning in python. <https://scikit-learn.org/>, 2024.
- [8] World Health Organization. Road traffic injuries. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>, 2023.