

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para priorización posterior a la notificación (ONSV 2021–2025)

Rendo

Yimmy

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una red neuronal para priorizar, después de la notificación, siniestros viales ya fatales que dejaron dos o más fallecidos. La fuente oficial ONSV 2021–2025 contiene 9 104 registros útiles y una prevalencia multifatal de 10.19 %. El protocolo canónico bloquea la mezcla cronológica: entrenamiento en 2021–2022 (4 872 registros), selección y calibración exclusivamente en 2023 (2 000), y evaluación de referencia en 2024–2025 (2 232). Este último periodo ya fue observado y, por tanto, se presenta como referencia histórica congelada, no como un nuevo conjunto de prueba.

La MLP definitiva es la configuración MLP_64_32 (capas 64–32, ReLU, *dropout* 0.35, regularización L2, semilla 314) sobre 162 características de contexto y notificación inicial. La calibración Platt y el umbral calibrado 0.20 se eligieron con predicciones *out-of-fold* de cinco particiones sobre validación 2023; la salida sigmoide cruda conserva su umbral diagnóstico 0.65. En la referencia 2024–2025, la escala calibrada obtuvo F1 multifatal 0.2958, precisión 0.2359, *recall* 0.3964, PR-AUC 0.2249, ROC-AUC 0.7482, Brier 0.0831 y ECE 0.0085. La calibración mejora Brier y ECE, pero no modifica PR-AUC ni ROC-AUC porque no cambia el orden de los casos. La regresión logística mantiene mayor F1 (0.3183); por ello no se afirma superioridad universal ni estadística de la red.

La explicabilidad usa exclusivamente Gradient SHAP en validación 2023, con 256 registros de fondo de entrenamiento, 512 registros explicados y 17 grupos interpretables. La interfaz Streamlit consume un *bundle* de solo lectura con hashes verificados, separa las escalas cruda y calibrada, valida fecha y ubicación Perú–departamento, y presenta gráficos interactivos con soporte, intervalos de Wilson y alternativas tabulares. El sistema constituye una demostración académica reproducible de clasificación de multifatalidad dentro del universo ONSV de siniestros fatales notificados.

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta

decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica desde 2021 una base a nivel de registro de todos los siniestros fatales del país, con variables de contexto pre-impacto que los registros administrativos anteriores no incluían: zona rural/urbana, red vial, condición climática, característica de la vía (recta, curva, intersección), perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?* La consigna del curso pide una red neuronal para predicción o clasificación con un dataset de la región o a nivel nacional, acompañada de análisis exploratorio, preprocesamiento, ingeniería de características, una interfaz gráfica y un informe. En rigor técnico, el problema abordado es de **clasificación binaria** multifatal/letalidad-simple: la salida es una categoría discreta, y al clasificarla el modelo también produce una probabilidad de siniestro multifatal, lo que cubre ambos términos de la consigna con precisión.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, con al menos ocho hallazgos interpretados.
- **OE2.** Construir al menos doce características derivadas de las variables pre-impacto del registro, cada una justificada.
- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier` (clase mayoritaria), regresión logística y *random forest*. El MLP debe superar claramente al `DummyClassifier`; si no supera a la regresión logística o al *random forest*, se reporta y discute honestamente.
- **OE4.** Identificar los cinco factores de mayor influencia en la alta letalidad mediante SHAP.

- **OE5.** Desplegar una interfaz gráfica en Streamlit que reutilice el pipeline de entrenamiento sin discrepancias.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello se fijaron las métricas antes de ver los datos, como hace un profesional:

- Selección de arquitectura: **mayor mediana de PR-AUC en validación 2023 entre semillas**; desempates por mayor F1 mediana y, después, menor IQR de PR-AUC. Esta regla se fija antes de consultar 2024–2025.
- Métricas de reporte obligatorio: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* solo como referencia.
- Se prohíbe argumentar calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Selección de umbral: máximo F1 en validación, con desempates predeclarados por *recall*, precisión y mayor umbral; no se ajusta después de observar 2024–2025.

3. Marco teórico

3.1. Seguridad vial y alcance condicional

La severidad vial es multifactorial: interactúan infraestructura, condiciones ambientales, vehículo, conductor y respuesta posterior. La base ONSV utilizada registra exclusivamente siniestros con al menos un fallecido; por ello, el modelo no estima ocurrencia ni fatalidad general. Su pregunta es condicional: *dado un siniestro ya fatal y notificado, ¿el registro pertenece a la clase multifatal?* Esta restricción evita mezclar universos incompatibles y define un uso de priorización posterior a la notificación [6, 8].

3.2. Perceptrón multicapa

Una neurona calcula $a = f(Wx + b)$. Un perceptrón multicapa (MLP) encadena capas densas y aprende relaciones no lineales mediante retropropagación [1]. Para las dos capas ocultas del modelo canónico:

$$\hat{y} = \sigma(W_3 f(W_2 f(W_1 x + b_1) + b_2) + b_3),$$

donde f es ReLU y σ es sigmoide. La salida sigmoide es un *score* crudo; no debe llamarse probabilidad operacional hasta evaluar su calibración.

La pérdida es entropía cruzada binaria ponderada:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N [w_1 y_i \log \hat{y}_i + w_0 (1 - y_i) \log (1 - \hat{y}_i)].$$

Se usó Adam con tasa inicial 5×10^{-4} , lotes de 64, pesos de clase, *dropout* 0.35, regularización L2 de 3×10^{-4} y parada temprana por PR-AUC de validación [4].

3.3. Evaluación bajo desbalance

La clase multifatal representa alrededor del 10 %, por lo que la exactitud aislada es insuficiente. Se reportan precisión, *recall*, F1, PR-AUC, ROC-AUC, matriz de confusión e intervalos bootstrap. PR-AUC debe leerse contra la prevalencia: un clasificador sin capacidad de ordenamiento obtiene aproximadamente la tasa positiva.

El umbral transforma scores en clases. La política canónica maximiza F1 en validación y desempata por *recall*, precisión y mayor umbral. La salida cruda y la calibrada pertenecen a escalas distintas: el umbral 0.65 solo corresponde al score sigmoide, mientras que 0.20 solo corresponde a la probabilidad Platt.

3.4. Calibración probabilística

La calibración pregunta si, entre casos con probabilidad predicha cercana a p , la frecuencia observada también se aproxima a p . Se evalúa con Brier, ECE y curva de confiabilidad. Platt aplica una regresión logística al score; isotónica aprende una función monótona por tramos. Ambos métodos se compararon con predicciones *out-of-fold* de cinco particiones exclusivamente en validación 2023, siguiendo implementaciones reproducibles de scikit-learn [7]. La calibración puede mejorar Brier y ECE, pero, si conserva el orden, no cambia PR-AUC ni ROC-AUC.

3.5. Control de fuga y reproducibilidad

Se aplicaron tres barreras:

1. Las columnas de resultado (fallecidos, lesionados y vehículos dañados), causa post-investigación y señales con faltantes dependientes del periodo no entran al modelo.
2. Escalador, codificadores y frecuencias de vía se ajustan solo con 2021–2022. Arquitectura, semilla, calibración y umbrales se seleccionan solo con 2023.
3. Los resultados 2024–2025 ya fueron observados; quedan congelados como referencia histórica y no autorizan nuevos ajustes.

Semillas, versiones, hashes, esquema y artefactos se registran en el manifiesto canónico `manifest.json`.

3.6. Interpretabilidad con Gradient SHAP

SHAP distribuye el cambio del score entre las variables respecto de un fondo [5]. Se aplicó `shap.GradientExplainer` al score crudo de la MLP con 256 registros de fondo de entrenamiento 2021–2022 y 512 registros explicados de validación 2023. Las 162 características procesadas se agregaron en 17 grupos interpretables. La contribución firmada media no es un efecto monotónico, una recomendación de intervención ni evidencia causal.




Figura 1: Arquitectura canónica MLP_64_32. La salida cruda se calibra después con Platt; la calibración no cambia los pesos.

4. Metodología

4.1. Diseño experimental definitivo

El proyecto sigue CRISP-DM con una separación cronológica estricta. Este corte es el mecanismo definitivo para medir deriva entre periodos y bloquear el uso de información futura.

Tabla 1: Particiones y usos permitidos del protocolo canónico.

Partición	Periodo	n	Positivos	Uso autorizado
Entrenamiento	2021–2022	4 872	510	Ajuste de preprocesamiento y pesos
Validación	2023	2 000	196	Arquitectura, semilla, umbrales y calibración OOF
Referencia histórica	2024–2025	2 232	222	Informe final; sin selección ni reajuste

4.2. Flujo reproducible

`base_limpia.parquet` $\xrightarrow{\text{corte cronológico}}$ {2021–22, 2023, 2024–25}
 $\xrightarrow{\text{fit solo 2021–22}}$ 162 features procesadas
 $\xrightarrow{\text{selección 2023}}$ MLP_64_32, seed 314, $t=0.65$
 $\xrightarrow{\text{5-fold OOF 2023}}$ Platt + umbral calibrado 0.20
 $\xrightarrow{\text{congelar}}$ `models/final/`
 $\xrightarrow{\text{referencia 2024–25}}$ métricas, IC y errores.

4.3. Selección del modelo

Se compararon tres configuraciones MLP y tres semillas (42, 314 y 2718). La configuración se eligió por mediana de PR-AUC en validación, luego mediana de F1 y finalmente menor rango intercuartílico de PR-AUC. La semilla 314 quedó asociada al artefacto seleccionado. Los mismos datos y la misma política de umbral se aplicaron a regresión logística balanceada y Random Forest balanceado para evitar comparaciones ventajosas.

4.4. Calibración y umbrales

Platt e isotónica se compararon mediante Brier OOF de cinco particiones estratificadas dentro de 2023 [7]. Se seleccionó Platt por menor Brier OOF; el umbral calibrado 0.20 maximizó F1 sobre esas probabilidades OOF. El umbral crudo 0.65 proviene de la política predeclarada sobre scores de validación. Las escalas no se mezclan y la interfaz toma decisiones visibles solo en la escala calibrada.

4.5. Evaluación e incertidumbre

Se reportan dos vistas del mismo modelo congelado: score crudo y probabilidad Platt. Para las métricas de referencia se calcularon 1000 remuestreos bootstrap al 95 %. La evaluación incluye comparación con prevalencia, regresión logística y Random Forest; no se realizan pruebas o ajustes posteriores que reclasifiquen 2024–2025 como un nuevo periodo no observado.

4.6. Explicabilidad separada de la referencia

Gradient SHAP se ejecutó sin cargar etiquetas ni datos de 2024–2025 [5]. El fondo procede de entrenamiento y la muestra explicada de validación. Esta separación evita que la interpretación se convierta en una vía indirecta de ajuste a la referencia.

4.7. Implementación

La implementación usa Python 3.12, TensorFlow 2.19, scikit-learn 1.9, pandas 3.0, NumPy 2.1, SHAP 0.52, Streamlit y Plotly [2, 3, 7]. `models/final/manifest.json` fija versiones, hashes, particiones, arquitectura, calibrador y umbrales; el cargador de inferencia rechaza artefactos alterados.

5. Dataset

5.1. Fuente oficial

Se utilizó la base *SINIESTROS DE TRANSITO FATALES 2021–2025 (PRELIMINAR)*, publicada el 2026-02-27 por el Observatorio Nacional de Seguridad Vial (ONSV) en su portal de datos abiertos:

<https://www.onsv.gob.pe/datosabiertos>

El portal describe el recurso como: “Detalle de siniestros de tránsito con consecuencias fatales, ocurridos a nivel nacional, 2021–2025 (preliminar)”, autor ONSV. El archivo original se mantiene en `data/raw/BBDD_ONSV_SINIESTROS_FATALES_2021-2025.xlsx` (hoja SINIESTROS, encabezado en la fila 5). La fecha de descarga y verificación local fue el 2026-07-09. Es un dato abierto del Estado peruano, lo que permite libre reuso con atribución. El ONSV declara la información de 2025 como preliminar.

5.2. Adecuación de la fuente

La base ONSV aporta fecha, hora, localización, clase notificada, clima, geometría, superficie y clasificación vial. Estas variables permiten estudiar asociaciones de multifatalidad sin mezclar fuentes con criterios de registro incompatibles. Su límite es igualmente claro: al contener solo siniestros fatales, obliga a formular un objetivo condicional de alta letalidad y no una predicción de mortalidad general.

5.3. Diccionario de datos base

La Tabla 2 resume las variables del registro y su rol en el proyecto.

Tabla 2: Variables del registro ONSV y su rol en el proyecto.

Columna	Rol	Justificación
FECHA, HORA	Característica (derivar)	Estacionalidad, nocturnidad, fatiga
DEPARTAMENTO	Característica categórica	Geografía del riesgo
ZONA	Característica categórica	Ruralidad: velocidades y respuesta médica
RED VIAL	Característica categórica	Nacional/departamental/provincial/urbana
TIPO DE VÍA	Característica categórica	Carretera, avenida, calle, vía expresa
COD CARRETERA	Característica (derivar)	Familias de vías y frecuencia
COORDENADAS	Característica numérica	Señal espacial continua
CONDICIÓN CLIMÁTICA	Característica categórica	Visibilidad y adherencia
CARACTERÍSTICAS DE VÍA	Característica categórica	Recta, curva, intersección, estructura
PERFIL LONGITUDINAL	Característica categórica	Plana vs. inclinada
SUPERFICIE DE CALZADA	Característica categórica	Pavimentada, afirmado, trocha
CLASE SINIESTRO	Característica categórica	Mecánica del evento
CANTIDAD DE FALLECIDOS	Solo target	Prohibida como entrada
CANTIDAD DE LESIONADOS	Excluida	Resultado posterior (fuga)
CANTIDAD VEHÍCULOS DAÑADOS	Excluida	Resultado posterior (fuga)
CAUSA (factor y específica)	Excluida	Se determina en la investigación posterior
SEÑALES vertical/horizontal	Excluida	78 % de faltantes concentrados por periodo

5.4. Variable objetivo

Se construyó el target binario condicional al universo de siniestros fatales:

$$y = \begin{cases} 1, & \text{si FALLECIDOS} \geq 2 \quad (\text{"Alta Letalidad"}) \\ 0, & \text{si FALLECIDOS} = 1 \end{cases}$$

La prohibición de `LESIONADOS`, `VEHICULOS_DANADOS` y las columnas de causa como entradas se declara explícitamente como decisión metodológica en la Sección 7: los conteos se levantan después del siniestro (fuga directa del resultado) y la causa se codifica al cierre de la investigación (el 49 % figura “en proceso de investigación”).

5.5. Auditoría inicial

La auditoría (Bloque B) verificó y registró:

- Formato: Excel (`.xlsx`), hoja `SINIESTROS`, encabezado en fila 5, 27 columnas.
- Número de filas de datos: 9 106.
- Fechas inválidas eliminadas: 2. Duplicados por código de siniestro: 0.
- N final útil: 9 104.
- Casos multifatales: 928 (10.19 %); letalidad simple: 8 176.
- Rango temporal: 2021-01-01 a 2025-12-30 (2025 parcial, 678 registros).
- Coordenadas fuera del territorio peruano anuladas: 1 registro.

El protocolo usa un corte cronológico 2021–2022 / 2023 / 2024–2025. Como la clase multifatal representa 10.19 %, se usan pesos de clase sin SMOTE: sintetizar combinaciones categóricas y geográficas habría introducido casos difíciles de justificar. Tabla 3 resume la auditoría de fuente.

Tabla 3: Resumen de la auditoría del dataset (Bloque B).

Indicador	Valor
Filas de datos originales	9 106
Fechas inválidas eliminadas	2
Duplicados por código	0
Filas útiles finales	9 104
Casos multifatales (2+ fallecidos)	928
Porcentaje de clase multifatal	10.19 %
Rango temporal	2021–2025 (2025 parcial)
Máximo de fallecidos en un siniestro	33

6. Análisis exploratorio de datos

Se ejecutó el análisis exploratorio sobre `base_limpia.parquet`: cada figura se guardó numerada en `report/figures/` (150 dpi, títulos y ejes en español) y cada figura tiene 2–4 líneas de interpretación escrita. Se generaron 14 figuras y un conjunto de hallazgos numerados H1–H11 que alimentaron las decisiones de ingeniería de características.

6.1. Distribución del objetivo y desbalance




Figura 2: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con F1, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales




Figura 3: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 4: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).



Figura 5: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.




Figura 6: Siniestros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro



Figura 7: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 8: Tasa multifatal por clase. DESPISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 9: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).



Figura 10: Top-15 departamentos por tasa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto




Figura 11: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1 032 casos (H7).




Figura 12: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables aportan contexto inicial relevante para el modelo.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía




Figura 13: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.




Figura 14: Porcentaje de faltantes por columna. Las señales viales alcanzan 77.9 % (H10) y por eso se excluyen del modelo; el resto admite imputación simple con *flags*.




Figura 15: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Se redactaron once hallazgos en prosa, cada uno con referencia a su figura. Los más relevantes para el modelado:

- **H1**: la clase multifatal representa 10.2 % de los siniestros fatales (figura 2), confirma desbalance y justifica las métricas.
- **H3**: la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 4 y 5).
- **H5**: CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 7 y 8).
- **H6**: LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCABELICA lidera la tasa multifatal con 28.0 % (figuras 9 y 10).
- **H8**: zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 12). Las condiciones pre-impacto separan el riesgo.
- **H11**: el scatter geográfico (figura 15) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

7.1. Contrato anti-fuga

El target es `target_multifatal=1` cuando `FALLECIDOS ≥ 2`. Por ser resultado directo, `FALLECIDOS` no entra a X . También se excluyen `LESIONADOS`, `VEHICULOS_DANADOS`, causas post-investigación y señalización con faltantes dependientes del periodo. La clase del siniestro sí está disponible después de la notificación; esto limita el uso a priorización posterior al hecho y descarta cualquier interpretación preventiva.

7.2. Corte cronológico

Las fechas determinan tres bloques sin solapamiento: 2021–2022 para entrenamiento, 2023 para validación y calibración, y 2024–2025 para referencia histórica. El escalador, las categorías, el mapa de frecuencias de vía y cualquier imputación se ajustan únicamente con entrenamiento. Los transformadores no vuelven a ajustarse al procesar periodos posteriores.

7.3. Limpieza y codificación

Las categorías se normalizan a vocabularios cerrados con una categoría explícita `DESCONOCIDO`. Los códigos de carretera no vistos reciben frecuencia cero. Latitud y longitud se convierten a numérico; el *bundle* final exige el par completo para inferencia y la interfaz no inventa ubicaciones. Las continuas se estandarizan con estadísticos 2021–2022; las variables cíclicas permanecen en $[-1, 1]$ y las categóricas se codifican *one-hot*.

7.4. Contrato persistido

`models/final/` contiene `feature_list.json`, `feature_schema.json`, escalador, codificadores, modelo, calibrador, umbrales y manifiesto. El manifiesto registra hashes SHA-256 y el cargador de inferencia los verifica antes de predecir. El vector final tiene exactamente 162 columnas y el orden es parte del contrato.

7.5. Pruebas de frontera

Las pruebas automatizadas verifican que:

- las particiones temporales no se solapen;
- validación, no la referencia, seleccione umbrales y calibración;
- el modelo, el esquema y la lista tengan 162 entradas en el mismo orden;
- las escalas cruda y calibrada conserven umbrales distintos;
- el par de coordenadas sea obligatorio en la inferencia final;
- una entrada inválida elimine cualquier resultado previo de la interfaz.

Los casos de demostración prueban ejecución, no desempeño.

8. Ingeniería de características

Se construyeron 162 características a partir de información disponible al registrar inicialmente un siniestro ya fatal. No se agregaron variables externas inventadas ni proxies del desenlace.

Tabla 4: Familias principales del contrato canónico.

Familia	Transformación	Ejemplos	Justificación
Temporal	Cíclica + indicadores	mes, día semanal, hora, nocturnidad, fin de semana	Respetar proximidad circular y faltantes
Geográfica	Escalado + <i>one-hot</i>	latitud, longitud, departamento, región natural	Contexto territorial sin usar el resultado
Vía	Frecuencia + categorías	código, prefijo, red, tipo, zona	Maneja cardinalidad y códigos nuevos
Escena inicial	Categorías cerradas	clase, clima, geometría, perfil, superficie	Disponible después de la notificación
Interacciones	Productos predeclarados	noche×rural, lluvia×curva, tipo×zona, red×clase	Permite relaciones no aditivas defendibles
Faltantes	Indicadores explícitos	hora faltante, coordenadas faltantes	Evita imputación silenciosa

La expansión principal del contrato proviene de ciclos cronológicos, región natural e interacciones estructuradas. El modelo final incluye, entre otras, 18 combinaciones tipo de vía×zona y 30 combinaciones red vial×clase. La selección no se hizo mirando 2024–2025: el contrato se congeló antes de reportar ese periodo.

8.1. Disponibilidad y alcance

Fecha, hora, ubicación y vía pueden conocerse al despacho o geocodificarse; zona, clima y geometría pueden provenir del registro inicial; la clase del evento se conoce después de la notificación. En cambio, fallecidos, lesionados, daños y causas de investigación se excluyen. Esta auditoría respalda la afirmación precisa: el modelo prioriza registros posteriores al evento, no previene siniestros antes de que ocurran.

9. Modelo neuronal

9.1. Búsqueda cerrada y reproducible

Se definieron tres arquitecturas regularizadas y tres semillas antes de consultar el periodo de referencia 2024–2025. Cada corrida usó el mismo entrenamiento 2021–2022 y validación 2023. La configuración se eligió por mediana de PR-AUC entre semillas; F1 mediana y menor dispersión actuaron como desempates.

Tabla 5: Robustez de configuraciones en validación 2023.

Configuración	PR-AUC mediana	F1 mediana	IQR PR-AUC
MLP_64_32: 64–32	0.2538	0.3295	0.0108
MLP_32_16: 32–16	0.2471	0.3437	0.0097
MLP_32: 32	0.2397	0.3323	0.0020




Figura 16: PR-AUC de validación por configuración y semilla. MLP_64_32 presenta la mayor mediana; la variación entre semillas se conserva como evidencia, no se oculta.

9.2. Arquitectura congelada

La MLP canónica es MLP_64_32 con semilla 314: entrada de 162 variables, capas densas de 64 y 32 neuronas con ReLU, *dropout* 0.35, L2 de 3×10^{-4} , Adam con 5×10^{-4} y lote 64. Se entrenó con pesos de clase y parada temprana por PR-AUC. El modelo final conserva exactamente el hash del artefacto modelo seleccionado; materializar `models/final/` no reentrena ni vuelve a buscar pesos.

9.3. Comparadores y política de umbral

El clasificador constante por prevalencia, la regresión logística balanceada y el Random Forest balanceado se entrenaron con las mismas particiones; los dos modelos aprendidos recibieron las mismas 162 variables. Para cada modelo, el umbral se escogió solo en validación con la misma regla: máximo F1; empates por *recall*, precisión y mayor umbral. Para la MLP cruda se obtuvo 0.65.

9.4. Calibración Platt OOF

Sobre los scores de validación 2023 se generaron predicciones OOF con cinco particiones estratificadas. En esa selección, Platt obtuvo Brier OOF 0.0804987 frente a 0.0808757 de isotónica y quedó seleccionado. El umbral 0.20 se eligió sobre probabilidades OOF calibradas. Estos valores pertenecen exclusivamente a validación; el Brier 0.0831 informado en resultados corresponde a la referencia histórica 2024–2025 después de ajustar Platt con toda la validación. El procedimiento separa selección y referencia, y evita usar las etiquetas 2024–2025 para elegir el calibrador [7].

9.5. Artefactos canónicos

El directorio `models/final/` contiene:

- `model.keras`, `scaler.joblib` y `encoders.joblib`;
- `feature_list.json` y `feature_schema.json`;
- `calibrator.joblib` y `thresholds.json`;
- `calibration_selection.json` y `manifest.json`.

Los hashes permiten demostrar que la aplicación ejecuta el mismo stack que sustenta el informe.

10. Resultados

10.1. Estatus de la evaluación

Los 2 232 registros de 2024–2025 contienen 222 casos multifatales (prevalencia 0.0995). Sus etiquetas ya fueron observadas; en consecuencia, los resultados son una **referencia histórica definitiva** y no un periodo nuevo. Arquitectura, pesos, calibrador y umbrales no se modificaron después de observarlo.

10.2. MLP cruda y calibrada

Tabla 6: Métricas canónicas e intervalos bootstrap al 95 % (1 000 remuestreos).

Métrica	Score crudo, $t = 0.65$	Platt, $t = 0.20$
F1 multifatal	0.3030 [0.2512, 0.3480]	0.2958 [0.2446, 0.3405]
Precisión multifatal	0.2346 [0.1896, 0.2753]	0.2359 [0.1898, 0.2791]
<i>Recall</i> multifatal	0.4279 [0.3592, 0.4933]	0.3964 [0.3318, 0.4619]
PR-AUC	0.2249 [0.1865, 0.2722]	0.2249 [0.1865, 0.2722]
ROC-AUC	0.7482 [0.7138, 0.7776]	0.7482 [0.7138, 0.7776]
Brier	0.1817 [0.1736, 0.1902]	0.0831 [0.0739, 0.0912]
ECE, 10 bins	0.2623 [0.2484, 0.2763]	0.0085 [0.0048, 0.0221]

La calibración transforma la escala, no el orden: PR-AUC y ROC-AUC son idénticos. Su aporte aparece donde corresponde, en Brier y ECE. El Brier calibrado 0.0831 mejora al predictor constante de prevalencia, cuyo Brier es aproximadamente $0.0995(1 - 0.0995) = 0.0896$.

Evidencia histórica 2024-2025: comparación honesta




Figura 17: Comparación de PR-AUC, ROC-AUC y F1 entre la MLP definitiva y las líneas base en la referencia histórica. La MLP lidera el ranking; la regresión logística conserva el mayor F1.

Con el umbral calibrado, la matriz contiene 1 725 verdaderos negativos, 285 falsos positivos, 134 falsos negativos y 88 verdaderos positivos. El modelo identifica 39.6 % de los multifatales y solo 23.6 % de las alertas son verdaderas. Por ello sirve como apoyo de priorización, no como regla autónoma.

10.3. Comparación honesta con líneas base

Tabla 7: Comparación en la misma referencia temporal y con umbrales seleccionados solo en validación.

Modelo / escala	F1	Precisión	Recall	PR-AUC	ROC-AUC
MLP cruda	0.3030	0.2346	0.4279	0.2249	0.7482
MLP Platt	0.2958	0.2359	0.3964	0.2249	0.7482
Constante por prevalencia	0.1809	0.0995	1.0000	0.0995	0.5000
Regresión logística	0.3183	0.2161	0.6036	0.2054	0.7395
Random Forest	0.2545	0.2569	0.2523	0.2179	0.7439

La MLP tiene PR-AUC y ROC-AUC nominalmente mayores en esta muestra fija; la logística conserva mayor F1 y *recall*. Para cuantificar esa diferencia se ejecutó un **bootstrap pareado** sobre las predicciones congeladas de la referencia (2000 remuestreos de registros, semilla 42, IC percentil; diagnóstico posterior que no altera ninguna decisión de selección). La Tabla 8 resume el resultado: ninguna diferencia es significativa al 5 %. La lectura defendible es simétrica: no hay evidencia de superioridad de la red sobre la logística, pero tampoco de lo contrario; en ranking (PR-AUC), el 95.8 % de los remuestreos favorece a la MLP, una tendencia consistente que no alcanza significación. La MLP aprende señal por encima de la prevalencia y su ranking cronológico es competitivo, pero el techo informacional sigue siendo bajo.

Tabla 8: Bootstrap pareado MLP vs. regresión logística sobre la referencia 2024–2025 (`final_paired_bootstrap_2024_2025.csv`). Δ = MLP – logística; umbrales crudos seleccionados en validación (0.65 y 0.60).

Métrica	MLP	Logística	Δ	IC 95 % de Δ	$P(\Delta > 0)$
PR-AUC	0.2249	0.2054	+0.0194	[−0.0032, +0.0433]	0.958
ROC-AUC	0.7482	0.7395	+0.0087	[−0.0030, +0.0209]	0.925
F1 multifatal	0.3030	0.3183	−0.0153	[−0.0504, +0.0173]	0.185

10.4. Análisis de errores

Los falsos negativos calibrados (134) son el principal límite para un sistema de priorización. Varios casos quedan apenas por debajo de 0.20; por ejemplo, los primeros registros de Cusco y Arequipa tienen probabilidades 0.1998 y 0.1994. Esto demuestra que el umbral convierte diferencias pequeñas en decisiones distintas y que debe mostrarse la probabilidad, no solo una etiqueta. Los 285 falsos positivos implican carga de revisión: alrededor de tres de cada cuatro alertas no son multifatales. Sin ocupantes, velocidad, tipo de vehículo, cinturón/casco y exposición vial, el contexto disponible no permite resolver esos casos con certeza.

10.5. Explicabilidad global

La explicación canónica usa Gradient SHAP sobre la sigmoide cruda. El fondo contiene 256 registros de entrenamiento 2021–2022; se explican 512 registros de validación 2023 con

200 muestras SHAP y semilla 20260709. No se cargaron etiquetas ni datos 2024–2025. Las 162 variables procesadas se sumaron en 17 grupos.




Figura 18: Importancia Gradient SHAP por grupo interpretable en validación 2023. El signo resume la contribución media respecto del fondo, no un efecto causal.

Tabla 9: Cinco grupos con mayor importancia SHAP global.

Grupo	Features agrupadas	Participación	Dirección media
Clase del siniestro	6	19.01 %	Reduce score crudo
Red vial × clase	30	13.73 %	Reduce score crudo
Tipo de vía × zona	18	10.90 %	Aumenta score crudo
Zona	3	8.53 %	Reduce score crudo
Red vial	5	7.35 %	Reduce score crudo

Las direcciones medias no significan que toda categoría de un grupo actúe igual. Tampoco autorizan afirmaciones del tipo “cambiar la vía causa una reducción de riesgo”: SHAP describe asociaciones del modelo congelado y de la muestra de validación. No se generaron explicaciones locales para casos individuales.

11. Interfaz gráfica

11.1. Arquitectura de información

La interfaz Streamlit es un consumidor de solo lectura. No entrena, calibra, reescribe tablas ni modifica artefactos. Al iniciar, carga `models/final/manifest.json`, verifica hashes y comprueba que modelo, esquema y lista coincidan en 162 entradas.

Tabla 10: Flujo de información de la interfaz canónica.

Componente	Flujo	Responsabilidad
Formulario validado	→	Campos requeridos vacíos, opcionales como NO INFORMADO y caso demo explícito
app_inference	→	Valida periodo 2021–2025, código vial, par geográfico Perú–departamento y contrato de entrada
Bundle canónico	→	Verifica hashes; calcula score crudo y probabilidad Platt sin escribir archivos
Umbrales separados	→	0.20 para decisión visible calibrada; 0.65 solo para diagnóstico crudo
Presentación	→	Prioridad, contexto histórico, evidencia e incertidumbre con trazabilidad

11.2. Cinco páginas funcionales y enlazables

La navegación se sincroniza con el parámetro `?section=`; por ello cada página posee una URL compartible y el estado de navegación no queda oculto en pestañas internas.

1. **Panorama:** target académico, 162 features, prevalencia y particiones temporales.
2. **Estimar:** inicia sin valores plausibles precargados, ofrece *Cargar caso de demostración*, exige fecha, hora, clase, departamento y coordenadas, y muestra un gauge Platt.
3. **Explorar datos:** gráficos Plotly responsivos del target, serie mensual, tasas por clase y condiciones, mapa de puntos y matriz mes×hora. No reutiliza capturas EDA estáticas.
4. **Patrones regionales:** mapa, ranking y tabla departamental con intervalos de Wilson. Las tasas con soporte menor de 30 se enmascaran en lugar de presentarse como estimaciones estables.
5. **Evidencia del modelo:** comparación MLP/logística/Random Forest, confiabilidad, matriz de confusión, curvas PR/ROC y Gradient SHAP canónico. La matriz y las curvas incluyen tablas descargables como alternativa accesible.

11.3. Validación de entradas

La fecha se restringe al periodo cubierto por la evidencia, del 1 de enero de 2021 al 31 de diciembre de 2025. Un algoritmo geométrico puro sobre el GeoJSON versionado admite polígonos, multipolígonos y puntos de frontera; exige que las coordenadas pertenezcan al Perú y al departamento seleccionado. El código vial se busca entre los códigos persistidos y admite un código nuevo con formato oficial, mostrando que su frecuencia canónica será cero. Los campos de escena opcionales comienzan en NO INFORMADO. El subgrupo histórico coincidente se presenta únicamente con $n \geq 30$.

11.4. Decisión y contexto en escalas distintas

La decisión pública se calcula únicamente con la probabilidad Platt y el umbral 0.20. El score sigmoide y el umbral 0.65 aparecen en un panel separado para auditoría. Las

tasas históricas incluyen soporte e intervalo de Wilson; son comparadores descriptivos y no se superponen conceptualmente con una probabilidad individual.

11.5. Validación funcional

`src/block_g_app_check.py` ejecuta comprobaciones de manifiesto, alineación de 162 variables, finitud, separación de escalas, ausencia de escrituras y latencia en caliente. Además, `streamlit.testing.AppTest` recorre las cinco URLs, verifica campos vacíos, carga demo explícita, resultado válido, coherencia geográfica, limpieza de estado obsoleto y alternativas tabulares. Las pruebas unitarias cubren fechas fuera de dominio, coordenadas interiores, exteriores, fronterizas y departamentalmente incoherentes, códigos viales conocidos y nuevos, separación de umbrales y soporte $n = 29/30$.

El gate `check_release.py` unifica pruebas directas, AppTest, hashes, paridad de 2232 inferencias, lectura segura de explicabilidad, escaneo de notebooks e imports, referencias obsoletas, vigencia del PDF y estado de Git. El modo local informa artefactos aún no versionados; el modo estricto los convierte en fallo de entrega.

No se incluyen capturas de pantalla de una sesión no verificable. La tabla de flujo y el código probado constituyen evidencia reproducible de la arquitectura; la apariencia interactiva se inspecciona ejecutando la aplicación localmente.

12. Discusión

12.1. Qué mejoró realmente

El modelo definitivo no se sostiene por añadir capas sin control, sino por la validez del experimento: corte cronológico, búsqueda multisemilla, regularización, comparadores bajo la misma política, calibración OOF, hashes y pruebas de fuga. La discriminación es moderada (PR-AUC 0.2249 frente a prevalencia 0.0995; ROC-AUC 0.7482), por lo que existe señal, pero no una separación fuerte.

12.2. Red neuronal frente a modelos tabulares

La MLP alcanza el mejor PR-AUC y ROC-AUC nominal de la comparación fija, mientras la regresión logística obtiene mejor F1 y *recall* al umbral seleccionado. Esto es compatible con datasets tabulares medianos: la no linealidad puede mejorar el orden sin dominar todos los puntos operativos. Sin una prueba pareada predeclarada no corresponde afirmar superioridad estadística. El valor académico está en demostrar un experimento neuronal correcto y auditable, no en ocultar que un modelo lineal sigue siendo competitivo.

12.3. Calibración no es discriminación

Platt reduce Brier de 0.1817 a 0.0831 y ECE de 0.2623 a 0.0085, pero PR-AUC y ROC-AUC permanecen iguales. Esta distinción es central: calibrar hace interpretable la escala probabilística; no crea información ni corrige errores de ranking. El F1 calibrado ligeramente menor tampoco es contradicción: el umbral 0.20 proviene exclusivamente de validación OOF y no fue reajustado a 2024–2025.

12.4. Errores y utilidad real

Con 88 verdaderos positivos, 134 falsos negativos y 285 falsos positivos, la app no debe automatizar recursos, sanciones o responsabilidades. Su uso defendible es ordenar revisiones posteriores a la notificación y comunicar incertidumbre. Los casos cercanos al umbral evidencian que una etiqueta binaria oculta información; por eso la interfaz muestra probabilidad, umbral y referencias con intervalos.

12.5. Sesgos y variables ausentes

El registro ONSV proviene de partes administrativos, 2025 es preliminar y puede existir subregistro o cambio de codificación territorial. Además faltan ocupantes, velocidad estimada, tipo y antigüedad del vehículo, uso de cinturón/casco y exposición vial. Estas variables tienen relación mecánica directa con la multifatalidad y probablemente fijan el techo actual. Incorporarlas exige una fuente enlazable y disponible al momento de uso; no deben inventarse ni imputarse desde el desenlace.

12.6. Alcance posterior al hecho

La clase del evento y parte de la escena se conocen después de notificar el siniestro. En consecuencia, el modelo no predice qué vía tendrá un accidente, ni la probabilidad de fatalidad de un viaje. También queda prohibido extrapolar resultados a periodos futuros sin validación temporal nueva. Cuando exista un nuevo periodo realmente no observado, debe evaluarse una sola vez con el bundle actual antes de considerar cualquier actualización.

12.7. Lectura correcta de SHAP

Los grupos clase, red vial, tipo de vía×zona y zona concentran la importancia global. Esto describe cómo el modelo distribuye su score en 512 casos de validación respecto de 256 casos de fondo. Los signos medios pueden ocultar categorías con direcciones opuestas; no son efectos causales ni recomendaciones de intervención. La ausencia deliberada de explicaciones locales evita presentar narrativas individuales no validadas.

13. Conclusiones

13.1. Cumplimiento de objetivos

- **EDA:** se caracterizaron 9 104 siniestros fatales y el desbalance multifatal, con hallazgos temporales, territoriales y de condiciones registradas.
- **Características:** se construyó un contrato de 162 variables pre-impacto y de notificación inicial, sin columnas de resultado o investigación posterior.
- **Modelo:** se seleccionó una MLP 64–32 regularizada mediante selección cronológica y tres semillas; el periodo 2024–2025 no participó en selección.
- **Evaluación:** la MLP calibrada obtuvo PR-AUC 0.2249, ROC-AUC 0.7482 y F1 0.2958. La regresión logística obtuvo mayor F1 (0.3183), por lo que no se sostiene superioridad universal de la red.

- **Interpretabilidad:** Gradient SHAP se ejecutó únicamente con entrenamiento y validación, agrupando 162 features en 17 grupos y declarando límites no causales.
- **Interfaz:** la app de cinco secciones enlazables consume un stack canónico de solo lectura, verifica hashes, separa escalas, valida el dominio temporal y geográfico, y comunica soporte e incertidumbre con alternativas tabulares.

13.2. Conclusión general

El resultado definitivo es un sistema académico profesional y auditable para priorización posterior a la notificación de siniestros ya fatales. Su fortaleza principal no es una métrica espectacular, sino la coherencia entre pregunta, disponibilidad de variables, separación cronológica, calibración OOF, comparación honesta, trazabilidad y pruebas. La calibración Platt convierte un score crudo mal calibrado en una probabilidad con Brier 0.0831 y ECE 0.0085, sin atribuirse mejoras de ranking inexistentes.

El modelo conserva limitaciones importantes: identifica menos de la mitad de los multi-fatales al umbral canónico, genera numerosas falsas alertas y carece de variables mecánicas decisivas. Por ello no debe usarse de forma autónoma. La siguiente evaluación válida requiere un periodo futuro no observado o una fuente peruana enlazable con ocupantes, vehículos y exposición; no corresponde seguir ajustando sobre 2024–2025.

14. Anexos

14.1. A1. Fuente y diccionario

La base ONSV conserva encabezados descriptivos en la hoja SINIESTROS. El mapeo a nombres canónicos está en `src/block_b_dataset_audit.py`; la auditoría agregada está en `report/tables/tab00_audit_summary_block_b.json`.

14.2. A2. Artefactos definitivos

- Bundle de inferencia y manifiesto: `models/final/`.
- Protocolo: `report/tables/final_model_protocol.md`.
- Métricas, probabilidades, confusión, errores e intervalos: tablas de referencia final.
- Selección y robustez: tablas de selección y `models/final/model_selection.json`.
- Explicabilidad: tablas y figura de importancia global.

14.3. A3. Configuración congelada

```

1 canonical = {
2     "config_id": "MLP_64_32",
3     "hidden_units": [64, 32],
4     "dropout": 0.35,
5     "l2": 3e-4,
6     "learning_rate": 5e-4,
7     "batch_size": 64,
```

```

8     "seed": 314,
9     "raw_threshold": 0.65,
10    "calibrated_threshold": 0.20,
11    "calibration": "platt",
12 }

```

14.4. A4. Protocolo cronológico

```

1 train = data[data.FECHA.dt.year.isin([2021, 2022])]
2 selection = data[data.FECHA.dt.year.eq(2023)]
3 reference = data[data.FECHA.dt.year.isin([2024, 2025])]
4
5 # Fit preprocessing and weights: train only.
6 # Select architecture, seed, calibration and thresholds: selection only.
7 # Reference 2024-2025: reporting only; no further tuning.

```

14.5. A5. Decisiones metodológicas

Tabla 11: Controles del modelo definitivo.

Etapas	Decisión	Riesgo controlado	Evidencia
Protocolo	Separar 2021–22, 2023 y 2024–25 por rol	Fuga y optimismo por mezcla cronológica	Protocolo final
Selección	Comparar 3 arquitecturas $\times$ 3 semillas; congelar MLP_64_32, semilla 314	Selección oportunista	Registro de selección
Calibración	Elegir Platt mediante Brier OOF de 5 folds en 2023	Ajustar y evaluar calibrador en los mismos casos	Registro de calibración
Referencia	Tratar 2024–25 como periodo ya observado	Reutilizarlo para nuevos ajustes	Métricas finales
SHAP	Gradient SHAP solo con entrenamiento y selección	Interpretación contaminada por la referencia	Procedencia SHAP
Interfaz	Bundle verificado, solo lectura, decisión en escala calibrada	Divergencia informe/aplicación	Manifiesto canónico

14.6. A6. Reproducción y verificación

```

1 # Rebuild evidence without retraining the MLP
2 .venv/bin/python src/final_model_bundle.py
3 .venv/bin/python src/final_evaluation_figures.py
4 .venv/bin/python src/final_explainability.py
5
6 # Contracts and GUI
7 .venv/bin/python tests/test_model_protocol.py
8 .venv/bin/python tests/test_final_model_bundle.py
9 .venv/bin/python tests/test_final_explainability.py

```

```
10 .venv/bin/python tests/test_app_inference.py
11 .venv/bin/python src/block_g_app_check.py
12
13 # Interface
14 streamlit run app/streamlit_app.py
15
16 # Report
17 cd report && latexmk -pdf -interaction=nonstopmode main.tex
```

Las versiones exactas usadas para el bundle constan en el manifiesto. La reproducción no autoriza reoptimizar el modelo con la referencia 2024–2025.

Referencias

- [1] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016.
- [2] Google Brain Team. Tensorflow: Large-scale machine learning on heterogeneous systems. <https://www.tensorflow.org/>, 2024.
- [3] Keras Team. Keras 3 documentation. <https://keras.io/>, 2024.
- [4] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.
- [5] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems*, pages 4765–4774, 2017.
- [6] Observatorio Nacional de Seguridad Vial (ONSV). Siniestros de transito fatales 2021-2025 (preliminar). <https://www.onsv.gob.pe/datosabiertos>, 2026. Publicado el 2026-02-27; detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional, 2021–2025 (preliminar); verificado localmente el 2026-07-09.
- [7] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, et al. scikit-learn: Machine learning in python. <https://scikit-learn.org/>, 2024.
- [8] World Health Organization. Road traffic injuries. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>, 2023.