

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para predicción de siniestros multifatales (ONSV 2021–2025)

Rendo

Yimmy

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una red neuronal de clasificación binaria para predecir la alta letalidad (dos o más fallecidos) de los siniestros viales fatales del Perú, usando la base oficial del Observatorio Nacional de Seguridad Vial (ONSV) 2021–2025 (9 104 siniestros fatales útiles, 10.2 % de casos multifatales). Se ejecutó un pipeline completo: análisis exploratorio, preprocesamiento anti-fuga, ingeniería de 116 características pre-impacto (zona, red vial, clima, curvatura, perfil, superficie, coordenadas y derivadas temporales), entrenamiento de un perceptrón multicapa comparado contra tres líneas base, calibración del umbral de decisión en validación y calibración probabilística post-hoc. El modelo final alcanzó ROC-AUC de 0.7474 y recall-multifatal de 0.8849 en el conjunto de prueba, con intervalos de confianza bootstrap al 95 %. El análisis SHAP identificó la clase de siniestro (atropello, despiste, choque) y la zona rural/urbana como los factores de mayor influencia, coherentes con el análisis exploratorio (tasa multifatal rural 15.1 % vs. urbana 3.6 %). La calibración isotónica redujo el Brier de 0.2139 a 0.0872, por lo que la interfaz gráfica en Streamlit muestra probabilidades calibradas reales. Se reportan con honestidad las limitaciones: la regresión logística compite de cerca con la red en F1, el registro 2025 es preliminar y el modelo es una estimación académica de factores de riesgo, no un predictor operacional.

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica desde 2021 una base a nivel de registro de todos los siniestros fatales del país, con variables de contexto pre-impacto que los registros administrativos anteriores no incluían: zona rural/urbana, red vial, condición climática, característica de la vía (recta, curva, intersección), perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?* La consigna del curso pide una red neuronal para predicción o clasificación con un dataset de la región o a nivel nacional, acompañada de análisis exploratorio, preprocesamiento, ingeniería de características, una interfaz gráfica y un informe. En rigor técnico, el problema abordado es de **clasificación binaria** multifatal/letalidad-simple: la salida es una categoría discreta, y al clasificarla el modelo también produce una probabilidad de siniestro multifatal, lo que cubre ambos términos de la consigna con precisión.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, con al menos ocho hallazgos interpretados.
- **OE2.** Construir al menos doce características derivadas de las variables pre-impacto del registro, cada una justificada.
- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier` (clase mayoritaria), regresión logística y *random forest*. El MLP debe superar claramente al `DummyClassifier`; si no supera a la regresión logística o al *random forest*, se reporta y discute honestamente.
- **OE4.** Identificar los cinco factores de mayor influencia en la alta letalidad mediante SHAP.
- **OE5.** Desplegar una interfaz gráfica en Streamlit que reutilice el pipeline de entrenamiento sin discrepancias.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello se fijaron las métricas antes de ver los datos, como hace un profesional:

- Métrica primaria de selección de modelo: **F1-score de la clase multifatal**.
- Métricas de reporte obligatorio: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* solo como referencia.
- Se prohíbe argumentar calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Costo asimétrico: el falso negativo (subestimar un siniestro que dejó múltiples víctimas) es más costoso que el falso positivo, por lo que la calibración del umbral privilegia el *recall*-multifatal.

3. Marco teórico

3.1. Seguridad vial

La siniestralidad vial se modela como un fenómeno multifactorial donde interactúan el entorno (infraestructura, hora, clima), el vehículo y el conductor. Los registros policiales capturan variables posteriores al hecho (modalidad del accidente, ubicación, hora, víctimas). La literatura coincide en que la severidad de un accidente depende tanto de la mecánica del impacto (atropello, choque, despiste, volcadura) como de factores temporales (nocturnidad, fatiga) y territoriales (tramos peligrosos). Este trabajo no reemplaza esa literatura: la usa como motivación para justificar qué variables derivar [1, 2].

3.2. Redes neuronales

3.2.1. Neurona artificial y perceptrón multicapa

Una neurona artificial calcula una combinación lineal de sus entradas con un sesgo y la pasa por una función de activación:

$$a = f(Wx + b)$$

Un perceptrón multicapa (*MLP*, por sus siglas en inglés) es una red *feed-forward* densa: capas de neuronas totalmente conectadas, donde la salida de una capa es la entrada de la siguiente. Para datos tabulares, el MLP es el estándar, y es la arquitectura usada en este proyecto.

3.2.2. Activaciones

Se utilizaron dos funciones de activación:

- **ReLU** (*rectified linear unit*), $\max(0, x)$, en las capas ocultas: evita el desvanecimiento del gradiente y es barata de calcular.
- **Sigmoide**, $\sigma(z) = \frac{1}{1+e^{-z}}$, que comprime la salida al intervalo $(0, 1)$ y se interpreta como una probabilidad. Se reservó para la capa de salida, porque la tarea es clasificación binaria.

3.2.3. Función de pérdida y backpropagation

La red se entrenó minimizando la **entropía cruzada binaria** (*binary cross-entropy*), la pérdida correcta para clasificación binaria con salida sigmoide. Con pesos de clase w_1 para la clase multifatal y w_0 para la clase de letalidad simple:

$$\mathcal{L}(y, \hat{y}) = -\frac{1}{N} \sum_{i=1}^N [w_1 y_i \log \hat{y}_i + w_0 (1 - y_i) \log(1 - \hat{y}_i)]$$

El descenso de gradiente y la retropropagación (*backpropagation*) calculan, mediante la regla de la cadena, el gradiente de la pérdida respecto a cada peso y los actualizan en dirección contraria. La notación de la salida del MLP de dos capas usado en algunos rundowns del informe es $\hat{y} = \sigma(W_2 f(W_1 x + b_1) + b_2)$.

3.2.4. Optimizador Adam

Se usó el optimizador *Adam*, una variante del descenso de gradiente con momento y tasa de aprendizaje adaptativa por parámetro. La tasa inicial fue 1×10^{-3} .

3.2.5. Época, *batch* y parada temprana

Una época es una pasada completa por el conjunto de entrenamiento; un *batch* es el subconjunto usado en una actualización de pesos. Se usó *batch size* 32, hasta 200 épocas, con *early stopping* (*patience* 15, restaurando los mejores pesos) monitoreando el PR-AUC de validación. Esto detiene el entrenamiento cuando la métrica de validación deja de mejorar.

3.2.6. Sobreajuste y regularización

El sobreajuste (*overfitting*) ocurre cuando la red memoriza el entrenamiento y falla en datos nuevos; se detecta cuando el *val_loss* sube mientras el *train_loss* baja. El riesgo es alto aquí por el tamaño modesto del dataset. Para controlarlo se usaron tres mecanismos:

- **Dropout** (0.3–0.5 entre capas ocultas), que apaga neuronas al azar en entrenamiento y obliga a representaciones redundantes.
- **Batch normalization**, que normaliza activaciones por *batch* y estabiliza el entrenamiento, ubicada tras la primera capa densa.
- **Early stopping**, descrito arriba.

3.2.7. Escalado y codificación

Las redes convergen mal con características en escalas dispares, por lo que las continuas se escalaron con **StandardScaler** ajustado solo en entrenamiento. Las categóricas se codificaron con *One-Hot* (baja cardinalidad) y *frequency encoding* (alta cardinalidad, como el código de vía).

3.3. Clasificación vs. regresión

La consigna del curso admite “predicción o clasificación”. En rigor técnico:

- En **clasificación** la salida es una categoría discreta (multifatal/letalidad simple); la red termina en una neurona con activación sigmoide y se entrena con entropía cruzada.
- En **regresión** la salida es un número continuo; la red termina en una neurona lineal y se entrena con MSE/MAE.

Se eligió clasificación binaria porque: el conteo de fallecidos dentro de los siniestros fatales tiene una distribución muy sesgada (89.8 % con exactamente un fallecido, con una cola larga que llega hasta 33), la pregunta útil de seguridad vial es “¿alta letalidad o no?”, y la clasificación permite la batería completa de evaluación estándar (matriz de confusión, F1, curvas ROC/PR). Al clasificar, el modelo también produce una probabilidad de siniestro multifatal, cubriendo ambos términos de la consigna con precisión técnica.

3.4. Métricas bajo desbalance

Con la clase multifatal minoritaria, la *accuracy* es engañosa. Se utilizaron:

- **Matriz de confusión:** TP/TN/FP/FN.
- **Precision:** $P = \frac{TP}{TP+FP}$.
- **Recall:** $R = \frac{TP}{TP+FN}$.
- **F1:** media armónica $F1 = 2 \frac{P \cdot R}{P+R}$.
- **Curva ROC y ROC-AUC:** TPR vs. FPR variando el umbral.
- **Curva Precision-Recall y PR-AUC:** la métrica de monitoreo principal porque es la correcta bajo desbalance.

3.5. Costo asimétrico y umbral de decisión

La sigmoide entrega una probabilidad cruda; clasificar exige un corte. No se asumió 0.5: el umbral se calibró en validación privilegiando *recall*-multifatal. La justificación es la asimetría de costos en este dominio:

- **Falso positivo** (el modelo dice “alta letalidad” y el siniestro dejó una sola víctima): se sobreestima el riesgo de un escenario; recursos de fiscalización mal asignados. *Costo moderado*.
- **Falso negativo** (el modelo dice “letalidad simple” y el siniestro dejó múltiples víctimas): se subestima un escenario de alta letalidad; no se prioriza un contexto peligroso. **Costo alto**.

3.6. Calibración del umbral vs. calibración probabilística

Es importante distinguir dos conceptos que se confunden con facilidad:

- La **calibración del umbral** decide desde qué probabilidad se etiqueta como ALTA LETALIDAD. Se realizó en el conjunto de validación.
- La **calibración probabilística** diagnostica si las probabilidades predichas se parecen a frecuencias reales observadas. Primero se evaluó la sigmoide cruda con *Brier score* y curva de calibración; luego se ajustó un calibrador post-hoc usando solo validación y se diagnosticó sobre el test congelado.

3.7. Fuga de datos

La fuga de datos (*data leakage*) ocurre cuando información del objetivo o del futuro se cuela en las entradas. En este proyecto se aplicaron dos guardias:

1. Las columnas de resultado (**FALLECIDOS**, **LESIONADOS**, **VEHICULOS_DANADOS**) y las de causa post-investigación se prohibieron como entradas porque describen el desenlace del siniestro, no su contexto previo. Usarlas produciría un modelo trivial e indefendible.
2. Todo *fit* de preprocesamiento (escalado, codificación, imputación, frecuencias de vía) se ajustó solo en el conjunto de entrenamiento, aplicando luego a validación y prueba.

3.8. Reproducibilidad

La reproducibilidad garantiza que los mismos datos más el mismo código produzcan los mismos resultados. Se fijaron semillas en `numpy`, `tensorflow`, `random` y `PYTHONHASHSEED`; las versiones de las librerías se congelaron en `requirements.txt` y los congelados por plataforma en `requirements-macos.txt` y `requirements-windows.txt`. Aun así, macOS (ARM) y Windows (x86) pueden producir diferencias numéricas mínimas por implementaciones BLAS distintas, por lo que el modelo canónico se entrenó una sola vez en la máquina del integrante con macOS y el artefacto `.keras` se versionó en Git.

3.9. Interpretabilidad con SHAP

SHAP (*SHapley Additive exPlanations*) cuantifica la contribución marginal de cada característica a cada predicción, apoyándose en valores de Shapley de la teoría de juegos. Se utilizó para identificar el top-5 de factores de riesgo globales y para contrastar la interpretabilidad del modelo con los hallazgos del análisis exploratorio.



Figura 1: Arquitectura del MLP seleccionado (corrida R5, una capa oculta de 32 neuronas). La capa de salida sigmoide produce la probabilidad de siniestro multifatal.

4. Metodología

4.1. Marco de trabajo

El proceso se organizó siguiendo el ciclo CRISP-DM, adaptado a la naturaleza de un trabajo académico de dos días. La correspondencia fase $\leftrightarrow$ bloque del proyecto se muestra en la tabla 1.

Tabla 1: Correspondencia entre fases CRISP-DM y bloques de ejecución del proyecto.

Fase CRISP-DM	Bloque	Entregable principal
Comprensión del negocio y de los datos	A, B	Repositorio, auditoría, <code>base_limpia.parquet</code>
Análisis exploratorio	C	<code>fig01–fig13</code> y <code>fig23</code> , hallazgos H1–H11
Preparación de datos	D	116 características, escalado, codificación, <code>demo_ca</code>
Modelado	E	<code>letalidad_nn.keras</code> , <code>threshold.json</code> , <code>tab04</code>
Evaluación	F	<code>tab03</code> , <code>tab05</code> , <code>fig16–fig22</code> , top-5 SHAP, bootstrap
Despliegue	G	App Streamlit, checklist <code>tab09</code>

4.2. Pipeline

El flujo completo, reproducible de punta a punta, es:

`data/raw/` $\xrightarrow{\text{Bloque B}}$ `base_limpia.parquet` $\xrightarrow{\text{Bloque D}}$ $X_{\text{train}}, X_{\text{val}}, X_{\text{test}}$ $\xrightarrow{\text{Bloque E}}$ `letalidad_nn.keras` $\xrightarrow{\text{Bloque G}}$ `App Streamlit`

4.3. Herramientas y versiones

- Python 3.12.13 en macOS (ARM); idéntica versión en Windows.
- TensorFlow ≥ 2.18 , “<2.20” (con Keras 3 integrado, formato `.keras`).
- scikit-learn ≥ 1.6 (líneas base, métricas, `StandardScaler`, `compute_class_weight`).
- imbalanced-learn ≥ 0.13 (SMOTE, solo si aplica C4).
- shap ≥ 0.46 , interpretabilidad.
- pandas ≥ 2.2 , numpy ≥ 2.0 , pyarrow, matplotlib ≥ 3.9 , seaborn ≥ 0.13 , plotly ≥ 5.24 .
- streamlit ≥ 1.40 , interfaz gráfica web local.
- holidays, feriados del Perú; joblib, persistencia.

Los congelados exactos por plataforma se incluyen en los anexos A6 y A7.

4.4. Semillas y reproducibilidad

Al inicio de todo notebook y script se fijaron las semillas:

```
1 import os, random, numpy as np, tensorflow as tf
2 SEED = 42
3 os.environ["PYTHONHASHSEED"] = str(SEED)
4 random.seed(SEED); np.random.seed(SEED); tf.random.set_seed(SEED)
```

El modelo canónico se entrenó una sola vez en la máquina macOS del integrante Rendo. Los artefactos `letalidad_nn.keras`, `scaler.pkl`, `encoders.pkl`, `feature_list.json` y `threshold.json` se versionaron en Git y los consumió el otro integrante, sin re-entrenar. Las cifras de este informe provienen exclusivamente de ese artefacto.

4.5. Separación de subconjuntos

Para no confundir “probar la interfaz” con “evaluar el modelo”, se manejaron cuatro conceptos distintos: entrenamiento (ajustar pesos y *fits*), validación (elegir hiperparámetros, *early stopping* y calibrar el umbral), prueba final (evaluación única e intocable) y casos de demostración (probar la inferencia de la interfaz, jamás medir desempeño). Los casos de demostración se construyeron desde validación y casos sintéticos controlados, nunca desde la prueba final.

5. Dataset

5.1. Fuente oficial

Se utilizó la base *SINIESTROS DE TRANSITO FATALES 2021–2025 (PRELIMINAR)*, publicada el 2026-02-27 por el Observatorio Nacional de Seguridad Vial (ONSV) en su portal de datos abiertos:

<https://www.onsv.gob.pe/datosabiertos>

El portal describe el recurso como: “Detalle de siniestros de tránsito con consecuencias fatales, ocurridos a nivel nacional, 2021–2025 (preliminar)”, autor ONSV. El archivo original se mantiene en `data/raw/BBDD_ONSV_SINIESTROS_FATALES_2021-2025.xlsx` (hoja SINIESTROS, encabezado en la fila 5). La fecha de descarga y verificación local fue el 2026-07-09. Es un dato abierto del Estado peruano, lo que permite libre reuso con atribución. El ONSV declara la información de 2025 como preliminar.

5.2. Por qué se cambió la fuente

La primera iteración del proyecto usó el registro Sutran 2020–2021 de accidentes en carreteras, que permite construir el target mortal/no-mortal pero solo ofrece seis variables base (fecha, hora, departamento, vía, kilómetro y modalidad), sin ninguna condición del entorno. La evaluación crítica de esa iteración mostró un techo informacional: la red empataba con la regresión logística porque no había señal suficiente que aprender. La base ONSV aporta las variables pre-impacto que la literatura reconoce como determinantes (clima, geometría y superficie de la vía, ruralidad, red vial, coordenadas), al costo de restringir el universo a siniestros fatales. Se aceptó ese costo reformulando el problema hacia la alta letalidad, en lugar de mezclar fuentes con criterios de registro incompatibles.

5.3. Diccionario de datos base

La Tabla 2 resume las variables del registro y su rol en el proyecto.

Tabla 2: Variables del registro ONSV y su rol en el proyecto.

Columna	Rol	Justificación
FECHA, HORA	Característica (derivar)	Estacionalidad, nocturnidad, fatiga
DEPARTAMENTO	Característica categórica	Geografía del riesgo
ZONA	Característica categórica	Ruralidad: velocidades y respuesta méd
RED VIAL	Característica categórica	Nacional/departamental/provincial/urb
TIPO DE VÍA	Característica categórica	Carretera, avenida, calle, vía expresa
COD CARRETERA	Característica (derivar)	Familias de vías y frecuencia
COORDENADAS	Característica numérica	Señal espacial continua
CONDICIÓN CLIMÁTICA	Característica categórica	Visibilidad y adherencia
CARACTERÍSTICAS DE VÍA	Característica categórica	Recta, curva, intersección, estructura
PERFIL LONGITUDINAL	Característica categórica	Plana vs. inclinada
SUPERFICIE DE CALZADA	Característica categórica	Pavimentada, afirmado, trocha
CLASE SINIESTRO	Característica categórica	Mecánica del evento
CANTIDAD DE FALLECIDOS	Solo target	Prohibida como entrada
CANTIDAD DE LESIONADOS	Excluida	Resultado posterior (fuga)
CANTIDAD VEHÍCULOS DAÑADOS	Excluida	Resultado posterior (fuga)
CAUSA (factor y específica)	Excluida	Se determina en la investigación posteri
SEÑALES vertical/horizontal	Excluida	78 % de faltantes concentrados por peri

5.4. Variable objetivo

Se construyó el target binario condicional al universo de siniestros fatales:

$$y = 1 \iff \text{FALLECIDOS} \geq 2 \quad (\text{“ALTA LETALIDAD”}), \quad y = 0 \iff \text{FALLECIDOS} = 1$$

La prohibición de LESIONADOS, VEHICULOS_DANADOS y las columnas de causa como entradas se declara explícitamente como decisión metodológica en la Sección 7: los conteos se levantan después del siniestro (fuga directa del resultado) y la causa se codifica al cierre de la investigación (el 49 % figura “en proceso de investigación”).

5.5. Auditoría inicial

La auditoría (Bloque B) verificó y registró:

- Formato: Excel (.xlsx), hoja SINIESTROS, encabezado en fila 5, 27 columnas.
- Número de filas de datos: 9 106.
- Fechas inválidas eliminadas: 2. Duplicados por código de siniestro: 0.
- N final útil: 9 104.
- Casos multifatales: 928 (10.19 %); letalidad simple: 8 176.
- Rango temporal: 2021-01-01 a 2025-12-30 (2025 parcial, 678 registros).
- Coordenadas fuera del territorio peruano anuladas: 1 registro.

Como $3\,000 \leq N < 10\,000$ se aplicó la contingencia C2 (arquitectura A, *split* 70/15/15). Como el porcentaje de clase multifatal se ubica entre 5 % y 25 %, se aplicó C5: `class_weight` sin SMOTE. Tabla 3 resume la auditoría.

Tabla 3: Resumen de la auditoría del dataset (Bloque B).

Indicador	Valor
Filas de datos originales	9 106
Fechas inválidas eliminadas	2
Duplicados por código	0
Filas útiles finales	9 104
Casos multifatales (2+ fallecidos)	928
Porcentaje de clase multifatal	10.19 %
Rango temporal	2021–2025 (2025 parcial)
Máximo de fallecidos en un siniestro	33

6. Análisis exploratorio de datos

Se ejecutó el análisis exploratorio sobre `base_limpia.parquet`: cada figura se guardó numerada en `report/figures/` (150 dpi, títulos y ejes en español) y cada figura tiene 2–4 líneas de interpretación escrita. Se generaron 14 figuras y un conjunto de hallazgos numerados H1–H11 que alimentaron las decisiones de ingeniería de características.

6.1. Distribución del objetivo y desbalance




Figura 2: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con F1, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales




Figura 3: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 4: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).



Figura 5: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.




Figura 6: Siniestros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro




Figura 7: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 8: Tasa multifatal por clase. DESPISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 9: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).




Figura 10: Top-15 departamentos por tasa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto




Figura 11: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1032 casos (H7).




Figura 12: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables pre-impacto no existían en la fuente anterior y son el aporte central del cambio de dataset.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía





Figura 13: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.






Figura 15: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Se redactaron once hallazgos en prosa, cada uno con referencia a su figura. Los más relevantes para el modelado:

- **H1:** la clase multifatal representa 10.2 % de los siniestros fatales (figura 2), confirma desbalance y justifica las métricas.
- **H3:** la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 4 y 5).
- **H5:** CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 7 y 8).
- **H6:** LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCABELICA lidera la tasa multifatal con 28.0 % (figuras 9 y 10).
- **H8:** zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 12). Las condiciones pre-impacto separan el riesgo.
- **H11:** el scatter geográfico (figura 15) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

7.1. Orden inviolable: primero *split*, después todo *fit*

Este es el segundo guardián anti-fuga del proyecto, junto con la exclusión de las columnas de resultado. Cualquier estadístico usado para transformar (mediana, frecuencias, medias, escalado) se calcula solo con el conjunto de entrenamiento, y se aplica luego a validación y prueba.

7.2. Regla anti-fuga: exclusión de columnas de resultado

Cuatro grupos de columnas se prohibieron como entradas:

- FALLECIDOS define el target: usarla sería fuga total.
- LESIONADOS y VEHICULOS_DANADOS se cuentan después del siniestro y correlacionan directamente con la clase (media de afectados: 1.4 en letalidad simple vs. 5.0 en multifatales). Usarlas produciría métricas infladas y un modelo indefendible.
- CAUSA_FACTOR y CAUSA_ESPECIFICA se determinan en la investigación posterior: el 49 % de los registros figura “en proceso de investigación”. Para un modelo predictivo, la causa no se conoce en el momento del evento.
- Las señales vertical y horizontal tienen 77.9 % de faltantes concentrados por periodo de registro, lo que introduciría una correlación espuria con el año.

Estas exclusiones se declaran como decisión metodológica explícita: de las 116 características finales, ninguna deriva de esas columnas. La prueba del contrato de preprocesamiento lo verifica automáticamente.

7.3. Limpieza antes del *split*

Antes del *split* se aplicaron transformaciones determinísticas que no usan estadísticos del dataset:

- Normalización de texto (`str.strip().str.upper()`) y conversión de los tokens SIN INFO, NO CORRESPONDE, SIN CLASIFICAR y vacíos a NaN.
- Parseo de FECHA con `dayfirst=True, errors=coerce` (2 filas inválidas eliminadas).
- Parseo de HORA en formato HH:MM $\rightarrow$ `hora_entera` $\in [0, 23]$.
- Sanidad de coordenadas: valores fuera del recuadro territorial del Perú ($[-18, 4, 0, 1]$ lat, $[-81, 4, -68, 6]$ lon) anulados (1 registro).
- Deduplicación por CODIGO_SINIESTRO (0 duplicados).

7.4. *Split* estratificado y reproducible

```
1 from sklearn.model_selection import train_test_split
2 X_temp, X_test, y_temp, y_test = train_test_split(
3     X, y, test_size=0.15, stratify=y, random_state=SEED)
4 X_train, X_val, y_train, y_val = train_test_split(
5     X_temp, y_temp, test_size=0.1765, stratify=y_temp, random_state=SEED
6 )
# resultado: 70 % train / 15 % val / 15 % test
```

Resultado: 6372 / 1366 / 1366 filas. El porcentaje de clase multifatal es 10.20 % en *train* y 10.18 % en *val* y *test*: la estratificación es prácticamente exacta.

7.5. Imputaciones y *flags* de faltantes

Las filas con HORA nula usan `hora_sin = hora_cos = 0` junto con `hora_faltante = 1`, para que la red aprenda del faltante en lugar de recibir una mentira imputada. Las coordenadas faltantes se imputan con la mediana calculada solo en *train* y se añade el *flag* `coord_faltante`. Las categóricas nulas se mapean a la categoría cerrada DESCONOCIDO.

7.6. Escalado y codificación

- Las continuas (LATITUD, LONGITUD, `via_freq`, `anio`) se escalan con `StandardScaler` ajustado solo en *train*.
- Las cíclicas (`hora_sin`, `hora_cos`) ya están en $[-1, 1]$ y no se escalan.
- DEPARTAMENTO $\rightarrow$ *One-Hot* (25 columnas).
- COD CARRETERA $\rightarrow$ prefijo alfabético (*One-Hot*) más *frequency encoding* del código completo calculado en *train*; códigos no vistos se mapean a `via_freq = 0`.
- CLASE, ZONA, RED_VIAL, TIPO_VIA, CLIMA, CARACTERISTICA_VIA, PERFIL_VIA y SUPERFICIE $\rightarrow$ normalización a categorías cerradas + *One-Hot* (detalle en la Sección 8).

7.7. Persistencia del contrato

El orden final de las 116 características se congela en `models/feature_list.json`: el orden de columnas es contrato, no convención. Los transformadores se persisten en `models/scaler.pkl` y `models/encoders.pkl` con `joblib.dump`. La interfaz gráfica consume estos artefactos, por lo que no puede divergir del pipeline de entrenamiento.

7.8. Casos de demostración, separados de la prueba final

Se creó `data/processed/demo_cases.csv` con cinco casos controlados contruidos desde validación, nunca desde el test final: (1) caso diurno de referencia con letalidad simple, (2) mismo caso en horario nocturno, (3) mismo caso en curva con lluvia, (4) código de carretera no visto PE-999X (debe mapear `via_freq = 0` sin romperse), (5) departamento PUNO en zona rural. Sirven para probar coherencia de la interfaz, no para medir desempeño.

7.9. Prueba del contrato de preprocesamiento

La prueba en `tests/test_preprocessing_contract.py` verifica que `preparar_entrada()`:

- Devuelve exactamente 116 columnas, en el orden de `feature_list.json`.
- No genera NaN.
- Acepta un código de carretera no visto y produce `via_freq = 0`.
- Activa `coord_faltante` ante coordenadas nulas y normaliza las categorías compuestas (p.ej. ATROPELLO FUGA $\rightarrow$ ATROPELLO).

Esta prueba es la garantía de que la inferencia de la GUI y el entrenamiento comparten exactamente el mismo preprocesamiento.

8. Ingeniería de características

Se construyeron 116 características finales a partir de las variables pre-impacto del registro. Cada una justificada por una señal observada en el análisis exploratorio o por una razón técnica de las redes neuronales. La Tabla 4 muestra las derivadas más relevantes (el listado completo está en el Anexo y en `tab02_feature_contract.csv`).

8.1. Características temporales (de FECHA)

- `anio`: captura la deriva del registro 2021–2025; se escala como continua.
- `mes` (1–12): estacionalidad.
- `dia_semana` (0–6) y `fin_de_semana` (booleano): patrones por día de semana (H4).
- `feriado` (booleano, usando `holidays.country_holidays("PE")`).
- `quincena` (booleano, días 14–16 y 29–2): *proxy* de pago y viajes.

8.2. Características horarias (de hora_entera)

- **Codificación cíclica:** $\text{hora_sin} = \sin(2\pi \text{ h}/24)$ y $\text{hora_cos} = \cos(2\pi \text{ h}/24)$. Para la red, 23 y 0 deben ser vecinos; con la hora cruda distan 23 unidades, lo que rompe la continuidad cíclica del día.
- `nocturno` (booleano, 20:00–05:59): nocturnidad y fatiga.
- `franja` (MADRUGADA 0–5, MAÑANA 6–11, TARDE 12–17, NOCHE 18–23).
- Filas con `hora_entera` nula: $\text{hora_sin} = \text{hora_cos} = 0 + \text{hora_faltante} = 1$.

8.3. Características geográficas

- *One-Hot* de DEPARTAMENTO (25 columnas).
- `region_natural` (COSTA / SIERRA / SELVA / DESCONOCIDO): mapeo fijo departamento → región, escrito explícitamente en `src/features.py`.
- `LATITUD` y `LONGITUD`: señal espacial continua estandarizada, con imputación por mediana de *train* y *flag coord_faltante*. Es la primera vez que el proyecto dispone de geolocalización exacta (H11).

8.4. Características de vía

- `via_prefijo`: parte alfabética del código de carretera (p.ej. PE, LM, CU) → *One-Hot*. Representa familias de vías.
- `via_freq`: frecuencia relativa del código completo, calculada solo en *train*; códigos no vistos se mapean a 0.
- `red_vial_*`: NACIONAL / DEPARTAMENTAL / PROVINCIAL / URBANO / DESCONOCIDO.
- `tipo_via_*`: CARRETERA / AVENIDA / CALLE / EXPRESA / OTRO / DESCONOCIDO (agrupa calle, jirón, pasaje y alameda en CALLE; vía expresa y autopista en EXPRESA).

8.5. Características de condiciones pre-impacto (nuevas en esta fuente)

Estas variables son el aporte central del cambio de dataset (H8):

- `zona_*`: RURAL / URBANA / DESCONOCIDO. La ruralidad cuadruplica la tasa multifatal.
- `clima_*`: DESPEJADO / NUBLADO / LLUVIOSO / NIEBLA / OTRO / DESCONOCIDO (agrupa soleado en despejado; granizo y nieve en lluvioso).
- `caracteristica_*`: RECTO / CURVA / INTERSECCION / ESTRUCTURA / OTRO / DESCONOCIDO (agrupa sinuosa en curva; óvalo en intersección; puente, túnel y pase a desnivel en estructura).
- `perfil_*`: PLANA / INCLINADA / DESCONOCIDO.
- `superficie_*`: PAVIMENTADA / AFIRMADO / TROCHA / DESCONOCIDO (agrupa asfaltada, concreto, adoquinado y empedrado en pavimentada; cascajo/ripio en trocha).

8.6. Característica de clase de siniestro

CLASE se normaliza a seis categorías cerradas: ATROPELLO (incluye atropello con fuga), CHOQUE (incluye choque con fuga y con objeto fijo), DESPISTE (incluye despiste y volcadura combinados), VOLCADURA, ESPECIAL (caída de pasajero, ferroviario, incendio) y DESCONOCIDO. La mecánica del evento impacta directamente la letalidad (figura 8, H5).

8.7. Resumen de características principales

Tabla 4: Características derivadas principales (listado completo de 116 en el Anexo).

Característica	Origen	Tipo	Justificación
mes, dia_semana, fin_de_semana	FECHA	temporal derivada	Estacionalidad y patrones por día (H2, H4)
feriado, quincena	FECHA	booleana	Feriados PE y proxy de pago / viajes
hora_sin, hora_cos	HORA	cíclica	23 y 0 son vecinos; preserva continuidad
nocturno, franja	HORA	booleana / categórica	Nocturnidad, fatiga, visibilidad (H3)
hora_faltante, coord_faltante	HORA, coordenadas	booleana	El modelo aprende del faltante sin mentirle
departamento_*, region_*	DEPARTAMENTO	<i>one-hot</i>	Geografía del riesgo (H6)
LATITUD, LONGITUD	coordenadas	numérica escalada	Señal espacial continua (H11)
via_prefijo_*, via_freq	COD CARRETERA	derivada	Familias y frecuencia de vías (H7)
red_vial_*, tipo_via_*	registro vial	<i>one-hot</i>	Jerarquía y tipo de la vía
zona_*	ZONA	<i>one-hot</i>	Ruralidad: 15.1 % vs. 3.6 % (H8)
clima_*	CONDICIÓN CLIMÁTICA	<i>one-hot</i>	Lluvia: 17.6 % vs. 9.8 % (H8)
caracteristica_*, perfil_*, superficie_*	geometría de vía	<i>one-hot</i>	Curvatura, pendiente y calzada (H8)
clase_*	CLASE SINIESTRO	<i>one-hot</i>	Mecánica del evento, predictor dominante (H5)

El total de características finales es de 116, muy por encima del mínimo de 12 exigido en OE2. La verificación automática del contrato confirma que ninguna deriva de FALLECIDOS, LESIONADOS, VEHICULOS_DANADOS ni de las columnas de causa.

9. Modelo

9.1. Líneas base

Antes de entrenar la red neuronal se evaluaron tres líneas base con el conjunto de validación. Sin punto de comparación, ninguna métrica de la red significa nada.

- **Baseline 0:** `DummyClassifier (strategy="most_frequent")`. El modelo tonto que siempre predice la clase mayoritaria. Demuestra por qué la *accuracy* engaña: alcanza *accuracy* de 0.90 aunque el *recall*-multifatal sea 0.

- **Baseline 1: Regresión logística** (`class_weight="balanced"`, `max_iter=1000`, `solver="liblinear"`).
- **Baseline 2: *Random Forest*** (`n_estimators=300`, `class_weight="balanced"`, `random_state=SEED`).

9.2. Arquitectura según N

Como $3000 \leq N < 10\,000$, se aplicó la contingencia C2: Arquitectura A. Tras la búsqueda de hiperparámetros, la corrida ganadora (R5) resultó en una sola capa oculta de 32 neuronas, por lo que la arquitectura final es:

```

1 model = keras.Sequential([
2     layers.Input(shape=(n_features,)), # 116 características
3     layers.Dense(32, activation="relu"),
4     layers.BatchNormalization(),
5     layers.Dropout(0.4),
6     layers.Dense(1, activation="sigmoid"),
7 ])

```

9.3. Compilación y pesos de clase

```

1 model.compile(optimizer=keras.optimizers.Adam(1e-3),
2               loss="binary_crossentropy",
3               metrics=[keras.metrics.AUC(curve="PR", name="pr_auc"),
4                       keras.metrics.Recall(name="recall"),
5                       keras.metrics.Precision(name="precision")])
6
7 from sklearn.utils.class_weight import compute_class_weight
8 w = compute_class_weight("balanced", classes=np.array([0,1]), y=y_train)
9 class_weight = {0: w[0], 1: w[1]}

```

La pérdida utilizada es la entropía cruzada binaria (ecuación de Sección 3). El peso de clase w_1 aumenta el peso de los casos multifatales en la pérdida para compensar el desbalance.

9.4. Entrenamiento

```

1 callbacks = [
2     keras.callbacks.EarlyStopping(monitor="val_pr_auc", mode="max",
3                                   patience=15, restore_best_weights=True),
4     keras.callbacks.ModelCheckpoint("models/letalidad_nn.keras",
5                                     monitor="val_pr_auc", mode="max",
6                                     save_best_only=True),
7     keras.callbacks.ReduceLROnPlateau(monitor="val_loss", factor=0.5,
8                                       patience=5, min_lr=1e-5),
9 ]
10 history = model.fit(X_train, y_train, validation_data=(X_val, y_val),
11                    epochs=200, batch_size=32, class_weight=class_weight,
12                    callbacks=callbacks, verbose=2)

```

Se monitorea el PR-AUC en validación porque es la métrica correcta bajo desbalance. *Early stopping* conserva los mejores pesos. El guardado es en formato `.keras` de Keras 3.




Figura 16: Curvas de pérdida y PR-AUC de entrenamiento vs. validación de la corrida ganadora (R5, detenida en la época 22).

9.5. Búsqueda de hiperparámetros: *grid* cerrado de 6 corridas

El *grid* se definió antes de entrenar: exactamente seis corridas, ni una más ni una menos. La selección fue por mayor F1-multifatal en validación (desempate: PR-AUC). Tabla 5 resume las seis corridas.

Tabla 5: Resultado del *grid* cerrado de 6 corridas en validación (umbral 0.5). Selección por F1-multifatal (desempate: PR-AUC).

Corrida	Ocultas	Dropout	LR / <i>batch</i>	F1-multifatal val	PR-AUC val
R1 (base)	32–16	0.4–0.3	1e-3 / 32	0.2895	0.2301
R2 (LR 1e-4)	32–16	0.4–0.3	1e-4 / 32	0.2603	0.2181
R3 (+0.1 dropout)	32–16	0.5–0.4	1e-3 / 32	0.2754	0.2365
R4 (mitad neuronas)	16–8	0.4–0.3	1e-3 / 32	0.2883	0.2312
R5 (1 capa)	32	0.4	1e-3 / 32	0.2929	0.2247
R6 (<i>batch</i> 64)	32–16	0.4–0.3	1e-3 / 64	0.2481	0.2366

La mejor corrida fue R5: una sola capa oculta de 32 neuronas, F1-multifatal en validación de 0.2929. El sobreajuste se controló con *batch normalization*, *dropout* 0.4 y *early stopping* en la época 22.

9.6. Calibración del umbral de decisión en validación

Se barrió el umbral de 0.05 a 0.95 en pasos de 0.05 sobre el conjunto de validación. La regla de selección, definida antes de entrenar, privilegia el costo asimétrico: **máximo *recall*-multifatal entre los umbrales cuyo F1 conserve al menos el 90 % del mejor F1 de validación.** Tabla 6 (extracto) y la figura 17 muestran el intercambio.




Figura 17: Barrido de umbral en validación. F1, *precision* y *recall* de la clase multifatal vs. umbral. El umbral seleccionado (0.35) maximiza el *recall* (0.9209) conservando un F1 dentro del 90 % del mejor.

Tabla 6: Extracto del barrido de umbral en validación (tabla completa en `tab_umbral_validacion.csv`).

Umbral	F1-multifatal	Precision-multifatal	Recall-multifatal
0.05	0.1903	0.1051	1.0000
0.20	0.2271	0.1287	0.9640
0.35	0.2744	0.1612	0.9209
0.40	0.2808	0.1669	0.8849
0.50	0.2929	0.1797	0.7914
0.65	0.3039	0.2126	0.5324
0.80	0.2143	0.2824	0.1727
0.95	0.0000	0.0000	0.0000

Decisión sobre umbral. El mejor F1 de validación fue 0.3039 (umbral 0.65), pero con *recall* de solo 0.53: la mitad de los siniestros multifatales pasaría desapercibida. Bajo la regla de costo asimétrico, el umbral 0.35 conserva un F1 de 0.2744 ($\geq 90\%$ del mejor) y eleva el *recall* a 0.9209. Se seleccionó 0.35, aceptando explícitamente una precisión baja (0.1612) a cambio de no perder eventos de alta letalidad. Cambiar el umbral después de ver el test habría sido metodológicamente incorrecto; las implicancias operacionales se discuten en la Sección 12.

9.7. Persistencia del modelo y artefactos

Los artefactos canónicos versionados en Git son:

- `models/letalidad_nn.keras`: el modelo final (corrida R5).

- `models/threshold.json`: el umbral calibrado (0.35) y su regla de selección.
- `models/calibrator.pkl`: el calibrador isotónico post-hoc (ajustado en validación).
- `models/scaler.pkl` y `models/encoders.pkl`: escalador, codificadores, mapa de frecuencias de vía y categorías cerradas.
- `models/feature_list.json`: lista ordenada de 116 características (contrato para la GUI).

El modelo se entrenó una sola vez (en macOS) y lo consume el otro integrante, sin re-entrenar, para que las cifras del informe sean únicas e indiscutibles. Al cierre del Bloque E, el conjunto de prueba final permaneció **intacto**: no se evaluó ni una sola vez todavía.

10. Resultados

10.1. Evaluación única en el conjunto de prueba

La regla absoluta del Bloque F es que el test se usa exactamente una vez. Si se evalúa dos veces “para ver”, deja de ser test. La evaluación que sigue es esa única vez, con el umbral 0.35 congelado desde validación.

10.1.1. Matriz de confusión y reporte de clasificación




Figura 18: Matriz de confusión en el conjunto de prueba. El modelo produce solo 16 falsos negativos sobre 139 siniestros multifatales del test (recall 0.8849), a costa de 634 falsos positivos: el intercambio elegido por la regla de costo asimétrico.

Tabla 7: Reporte de clasificación en el conjunto de prueba (tab05).

Clase / Métrica	Precision	Recall	F1-score
Letalidad simple	0.9737	0.4833	0.6460
Multifatal	0.1625	0.8849	0.2746
<i>Accuracy</i>	—	—	0.5242
Promedio macro	0.5681	0.6841	0.4603
Promedio ponderado	0.8912	0.5242	0.6082

La *accuracy* de 0.52 es una consecuencia directa y esperada del umbral orientado a *recall*: el modelo prefiere alarmar de más antes que perder un evento multifatal. La precisión de la clase de letalidad simple (0.9737) muestra que cuando el modelo descarta un caso, casi siempre acierta.

10.1.2. Curvas ROC y Precision-Recall




Figura 19: Curva ROC (ROC-AUC = 0.7474). La discriminación mejora claramente sobre la iteración anterior del proyecto (0.6840 con la fuente Sutran).




Figura 20: Curva Precision-Recall (PR-AUC = 0.2038, prevalencia 0.1018): el doble de la línea base aleatoria.

10.1.3. Comparación con las líneas base

Tabla 8: Comparación contra líneas base en el conjunto de prueba (**tab03**). Las líneas base usan umbral 0.5; el MLP usa su umbral calibrado en validación (0.35).

Modelo	F1-multifatal	Recall	Precision	PR-AUC	ROC-AUC	Accuracy
DummyClassifier	0.0000	0.0000	0.0000	0.1018	0.5000	0.8982
Regresión logística	0.3081	0.7626	0.1931	0.2160	0.7512	0.6515
Random Forest	0.1776	0.1367	0.2533	0.1973	0.7361	0.8712
MLP (umbral 0.35)	0.2746	0.8849	0.1625	0.2038	0.7474	0.5242

La lectura honesta de esta tabla es triple. Primero, el MLP supera con claridad al DummyClassifier, cumpliendo el requisito mínimo. Segundo, **la regresión logística obtiene el mejor F1 (0.3081) y el mejor ROC-AUC (0.7512)**: en datos tabulares de este tamaño, los modelos lineales compiten de igual a igual con las redes, y este trabajo lo reporta en lugar de ocultarlo. Tercero, el MLP entrega el mayor *recall*-multifatal (0.8849 vs. 0.7626), que es exactamente la métrica que la regla de costo asimétrico privilegia; parte de esa diferencia proviene del umbral calibrado (0.35 vs. 0.5). El *Random Forest* alcanza la mayor *accuracy* porque casi no predice la clase multifatal (recall 0.1367): es el ejemplo perfecto de por qué la *accuracy* engaña bajo desbalance.

10.2. Lectura de errores en el dominio

Un **falso negativo** aquí significa subestimar un siniestro que dejó dos o más fallecidos. El modelo produjo 16 falsos negativos sobre 139 siniestros multifatales del test. El costo de ese *recall* alto es la precisión: de cada seis alertas, aproximadamente una corresponde a un evento realmente multifatal. Para un uso de priorización (qué combinaciones de vía, zona y condiciones vigilar), ese intercambio es razonable; para cualquier uso operacional directo, no lo sería. Los cinco falsos negativos de mayor probabilidad quedan listados en `tab05_false_negatives_examples.csv` para discusión cualitativa.

10.3. Interpretabilidad con SHAP




Figura 21: Summary plot SHAP (beeswarm) global. Las características más influyentes son la clase de siniestro y la zona rural/urbana.

Figura 22: Importancia media SHAP por característica. Refuerza el orden del top-5.

10.3.1. Top-5 factores de riesgo (cierra OE4)

Tabla 9: Top-5 factores según la importancia media SHAP (`tab08_shap_top5.csv`).

Característica	Importancia media SHAP
clase_atropello	0.0819
zona_rural	0.0521
clase_despiste	0.0462
clase_choque	0.0418
zona_urbana	0.0385

10.4. Coherencia EDA ↔ SHAP

La coherencia entre el análisis exploratorio y SHAP es una de las lecturas más informativas para un jurado:

- El EDA anticipaba que la clase de siniestro sería dominante (H5, DESPISTE con 17.7 % de tasa multifatal). SHAP lo confirma: tres de las cinco características más influyentes son clases de siniestro. El signo de `clase_atropello` es negativo para la alta letalidad (los atropellos suelen dejar una sola víctima), mientras que despiste empuja hacia arriba.
- El EDA anticipaba que la ruralidad era la señal estructural más fuerte (H8, 15.1 % vs. 3.6 %). SHAP ubica `zona_rural` en el 2.º lugar y `zona_urbana` en el 5.º, validando el cambio de fuente de datos: la red aprendió exactamente la variable que la fuente anterior no tenía.
- Las variables temporales, dominantes en la iteración anterior del proyecto, ceden protagonismo ante las variables de contexto. Esto sugiere que la señal temporal era, en parte, un *proxy* débil del contexto que ahora se observa directamente.

10.5. Prueba funcional con casos de la interfaz

Los casos de demostración (tab09, Tabla 10) se ejecutaron sobre el modelo final. **No son una métrica:** solo prueban que la inferencia de la interfaz funciona y que los casos de control se comportan de forma coherente con el EDA.

Tabla 10: Predicciones del modelo sobre los casos de demostración (tab09_gui_demo_predictions.csv). Sigmoides cruda / score calibrado; umbral crudo 0.35.

Caso	Cruda / calibrada	Clasificación	Observación
demo_01 caso base (rural, PE-3N)	0.652 / 0.144	ALTA LETALIDAD	Carretera nacional rural: riesgo estructural ya elevado
demo_02 nocturno	0.659 / 0.199	ALTA LETALIDAD	Sube frente al caso base (H3)
demo_03 curva + lluvia	0.757 / 0.199	ALTA LETALIDAD	El mayor incremento crudo, coherente con H8
demo_04 código no visto	0.657 / 0.199	ALTA LETALIDAD	No se rompe; mapea <code>via_freq = 0</code>
demo_05 Puno rural	0.634 / 0.144	ALTA LETALIDAD	El encoding geográfico acepta PUNO

Los cinco casos comparten el contexto de carretera nacional en zona rural, el perfil de mayor riesgo estructural; por eso el umbral orientado a *recall* los clasifica a todos como alta letalidad. Los movimientos relativos son los esperados: la curva con lluvia produce el mayor incremento de la sigmoide (0.652 → 0.757, H8) y el score calibrado traduce esos valores crudos a probabilidades realistas (14–20 %, contra una prevalencia global de 10.2 %).

10.6. Calibración post-hoc e incertidumbre




Figura 23: Diagnóstico inicial de calibración de la salida sigmoide cruda. El Brier 0.2139 muestra que la sigmoide sobreestima sistemáticamente el riesgo observado.




Figura 24: Calibración post-hoc ajustada en validación y diagnosticada sobre el test congelado. El score calibrado reduce el Brier a 0.0872.

Para corregir la interpretación de la salida sigmoide, se ajustó un calibrador post-hoc usando solamente el conjunto de validación. Se compararon Platt e isotónica por *Brier score* de validación y se seleccionó **isotonic**. El test se mantuvo como diagnóstico congelado: no se usó para elegir el calibrador.

En test, la salida sigmoide cruda obtuvo Brier 0.2139 y ECE 0.3154; el score calibrado obtuvo Brier 0.0872 y ECE 0.0161. Por eso, la GUI deja de presentar la salida como “probabilidad operacional” y la muestra como **score calibrado de riesgo multifatal**.

Además, se calcularon intervalos de confianza bootstrap al 95 % sobre las predicciones congeladas del test: F1-multifatal 0.2746 [0.2383, 0.3130], recall-multifatal 0.8849 [0.8322, 0.9323] y PR-AUC 0.2038 [0.1661, 0.2602]. Estos intervalos evitan vender el resultado como un punto exacto: muestran la incertidumbre real de un test pequeño y desbalanceado.

Tabla 11: Intervalos de confianza bootstrap al 95 % (1000 remuestreos) sobre las predicciones congeladas del test (`tab12_bootstrap_ci_test.csv`).

Métrica	Estimación	IC 95 % inferior	IC 95 % superior
F1-multifatal	0.2746	0.2383	0.3130
Recall-multifatal	0.8849	0.8322	0.9323
Precision-multifatal	0.1625	0.1381	0.1898
PR-AUC	0.2038	0.1661	0.2602
ROC-AUC	0.7474	0.7114	0.7832
Brier (crudo)	0.2139	0.2024	0.2246
Brier (calibrado)	0.0872	0.0765	0.0986

Con solo 139 positivos en el test, los intervalos son anchos: el trabajo los reporta para no vender los resultados como puntos exactos. Nótese que el Brier calibrado (0.0872 [0.0765,

0.0986]) es mejor que el de un predictor constante de la tasa base ($0,102 \times 0,898 = 0,0916$): las probabilidades calibradas aportan información real, no solo cosmética.

11. Interfaz gráfica

11.1. Arquitectura de la app

La interfaz se construyó en **Streamlit** (web local con `streamlit run`), confirmada como aceptable por el docente. Se organizó en cuatro pestañas con `st.tabs`, todas operativas en macOS y Windows. El código vive en `app/streamlit_app.py`.

11.2. Contrato de preprocesamiento compartido

La regla metodológica más importante del Bloque G es que **la interfaz nunca recodifica a mano**. Toda transformación de entrada pasa por la función compartida `preparar_entrada()` en `src/preprocessing.py`, importada tanto por el pipeline de entrenamiento como por la app. Misma función = imposible divergir. La función consume `models/feature_list.json`, `models/scaler.pkl` y `models/encoders.pkl`, lo que garantiza que el vector de entrada tenga exactamente las 116 columnas en el orden correcto.

11.3. Pestañas

11.3.1. Pestaña 1: Predicción de alta letalidad

Formulario con *selectbox* para departamento, zona, red vial, tipo de vía, clase de siniestro, clima, característica de vía, perfil y superficie; *date_input* para fecha, *text_input* para hora y para el código de carretera (opcional). La inferencia muestra:

- Un medidor tipo *gauge* (Plotly) con la **probabilidad calibrada de 2+ fallecidos** (0–100 %). Gracias a la calibración isotónica (Brier 0.0872 en test), esta lectura sí es una probabilidad real y no solo un score.
- Una etiqueta grande ALTA LETALIDAD / LETALIDAD SIMPLE según el umbral crudo de `threshold.json`; la clasificación y la probabilidad calibrada se muestran separadas para no mezclar decisión con comunicación de riesgo, y la nota al pie indica el valor crudo usado para clasificar.
- Una gráfica comparativa entre la probabilidad calibrada del modelo y tasas multifatales históricas observadas (global, clase, zona, clima, departamento, hora y casos similares). Esa gráfica no pretende ser comprobación individual del caso manual: solo da contexto empírico.
- Una nota de alcance: “Es una estimación académica; no reemplaza evaluación vial profesional.”

11.3.2. Pestaña 2: Análisis exploratorio

Muestra las figuras clave del Bloque C: distribución del target, serie mensual, tasa multifatal por clase, tasas por condiciones pre-impacto (zona, clima, característica, superficie), mapa mes $\times$ hora y el scatter geográfico de siniestros. Incluye el expander con los hallazgos H1–H11.

11.3.3. Pestaña 3: Letalidad por departamento

Ranking interactivo por departamento (barras y tabla ordenable) con número de siniestros fatales y tasa multifatal, filtrado a departamentos con al menos 30 casos. Además, con el GeoJSON departamental versionado en `data/geo/`, se activa el mapa coroplético del Perú coloreado por tasa multifatal.

11.3.4. Pestaña 4: Sobre el modelo

Métricas del test (F1, recall, PR-AUC, ROC-AUC), definición del problema condicional, umbral, método de calibración, contrato de preprocesamiento, fuente de datos y top-5 SHAP. Cierra con créditos del equipo.

11.4. Pruebas funcionales

El checklist del Bloque G (`tab09_gui_checklist.csv`) verificó siete condiciones, todas superadas:

- Los cinco casos de demostración predicen sin error.
- El caso típico responde en menos de 2 segundos (0.16 s).
- Cambiar solo la hora a nocturna modifica la probabilidad de forma coherente (`demo_02`: sigmoide 0.652 $\rightarrow$ 0.659; score calibrado 0.144 $\rightarrow$ 0.199).
- Un código de carretera no visto no rompe la app y mapea `via_freq = 0` (`demo_04`).
- El caso de Puno rural confirma el encoding geográfico (`demo_05`).
- La comparación histórica entrega al menos cuatro tasas de contexto (entregó 8).
- El calibrador post-hoc está disponible y activo (isotónico).

Adicionalmente, la app completa se verificó de punta a punta en un navegador local: las cuatro pestañas cargan sin excepciones y el mapa coroplético renderiza los 25 departamentos.

11.5. Naturaleza de solo lectura

La GUI es de solo lectura: consume los artefactos versionados (`letalidad_nn.keras`, `calibrator.pkl`, `scaler.pkl`, `encoders.pkl`, `threshold.json`) y no reentrena nada. Esta separación entrenamiento/inferencia garantiza que lo que se defiende ante el jurado es exactamente lo que corre la aplicación, y permite ejecutarla cualquier cantidad de veces sin alterar los resultados del informe.

12. Discusión

12.1. El cambio de fuente y su efecto

La primera iteración del proyecto (Sutran 2020–2021, mortal/no-mortal) alcanzó ROC-AUC de 0.6840 con seis variables base y una red que empataba estadísticamente con la regresión logística. El diagnóstico fue un techo informacional: no había señal de contexto

que aprender. El cambio a la base ONSV — con zona, clima, geometría de vía, superficie y coordenadas — elevó el ROC-AUC a 0.7474 y produjo un top-5 SHAP dominado precisamente por las variables nuevas (`zona_rural`, `zona_urbana`) y por la mecánica del siniestro. La hipótesis del techo informacional se confirmó empíricamente: al agregar información pre-impacto real, la discriminación mejoró.

12.2. Comparación MLP vs. líneas base: lectura honesta

La regresión logística obtiene el mejor F1 (0.3081 vs. 0.2746) y el mejor ROC-AUC (0.7512 vs. 0.7474) en test. La diferencia es pequeña y los intervalos bootstrap se traslapan ampliamente: es un empate estadístico con ventaja nominal de la logística. Esto no invalida el trabajo — el requisito del curso es entrenar y evaluar correctamente una red neuronal, y la literatura reconoce que en tabulares pequeños los modelos lineales compiten de igual a igual — pero sí obliga a decirlo sin maquillaje: **con estos datos, la no-linealidad de la red aporta poco sobre un modelo lineal bien regularizado**. El aporte del MLP en este proyecto es el *recall*-multifatal (0.8849 vs. 0.7626), en parte atribuible a su umbral calibrado por la regla de costo asimétrico. El *Random Forest* maximiza *accuracy* ignorando la clase minoritaria (recall 0.1367): el ejemplo de libro de por qué la *accuracy* engaña.

12.3. Costo asimétrico y elección del umbral

La regla del proyecto privilegia el *recall*-multifatal porque el falso negativo (subestimar un evento con múltiples víctimas) es el error más costoso. El umbral 0.35, elegido en validación con la regla “máximo recall con $F1 \geq 90\%$ del mejor”, produce en test 16 falsos negativos sobre 139 positivos, al costo de una precisión de 0.16 y una *accuracy* de 0.52. Ese intercambio es defendible para priorización de vigilancia (qué combinaciones de vía, zona y condiciones observar), pero no para decisiones operativas caso a caso. La política de umbral óptima depende de costos externos al modelo y debería definirse con el usuario final antes de evaluar un nuevo *holdout*; se propone como trabajo futuro.

12.4. Calibración probabilística

La salida sigmoide cruda estaba mal calibrada (Brier 0.2139, ECE 0.3154 en test): peor que un predictor constante de la tasa base (Brier 0.0916). Para corregir la lectura pública sin reentrenar la red ni tocar el test, se ajustó calibración isotónica con validación. En el test congelado, el score calibrado alcanza Brier 0.0872 y ECE 0.0161 — ahora sí mejor que el predictor de tasa base, con intervalo bootstrap [0.0765, 0.0986]. Por eso la GUI presenta la probabilidad calibrada en el gauge y conserva el umbral sobre la salida cruda solo para la clasificación binaria.

12.5. Sesgo de registro y datos preliminares

La base proviene de los registros del ONSV contruidos sobre partes policiales. Refleja lo que se reportó, no necesariamente lo que ocurrió: hay subregistro potencial, inconsistencias de codificación entre regiones y el propio ONSV declara 2025 como preliminar (678 registros, año incompleto). Las columnas de señalización vial (78 % de faltantes concentrados por periodo) muestran que el instrumento de registro cambió en el tiempo; por eso se excluyeron. El modelo hereda estos sesgos y no puede corregirlos.

12.6. Variables ausentes

Aún faltan variables determinantes de la letalidad múltiple: número de ocupantes del vehículo (el determinante mecánico directo: un bus volcado no equivale a un auto), velocidad estimada, tipo y antigüedad del vehículo, y uso de cinturón o casco. La base de vehículos del ONSV (unible por código de siniestro) permitiría incorporar parte de esta información y es la extensión natural del trabajo. Sin ella, el modelo razona por el contexto del evento (ruralidad, mecánica, clima, geometría), que es exactamente lo que confirma SHAP.

12.7. Encuadre condicional y validez externa

El modelo responde una pregunta condicional: *dado que ocurre un siniestro fatal*, cuán probable es que sea multifatal. No estima la probabilidad de que ocurra un siniestro ni la mortalidad general de una vía. Su generalización a periodos posteriores o a cambios en la fiscalización no está garantizada. La interfaz declara este alcance.

12.8. Coherencia EDA $\leftrightarrow$ SHAP

La principal fortaleza interpretativa del trabajo es la coherencia entre lo que el EDA anticipaba y lo que la red aprendió. El EDA anticipaba que la ruralidad era la separación estructural más fuerte (H8): SHAP ubica las dos variables de zona en el top-5. El EDA anticipaba que la clase de siniestro dominaría (H5): SHAP ubica tres clases en el top-5. Esto sugiere que el modelo no aprende ruido: sus contribuciones conectan con el dominio y con la literatura de seguridad vial.

13. Conclusiones

13.1. Conclusión sobre OE1 (EDA)

Cumplido. Se caracterizó la siniestralidad fatal nacional con 14 figuras interpretadas y once hallazgos numerados H1–H11, con al menos tres hallazgos fuertes: la separación estructural rural/urbana en la tasa multifatal (H8, 15.1 % vs. 3.6 %), la dominancia de la clase de siniestro en la letalidad (H5) y la divergencia entre el ranking por volumen y por tasa multifatal territorial (H6, Lima vs. Huancavelica).

13.2. Conclusión sobre OE2 (características)

Cumplido con holgura. Se construyeron 116 características derivadas de las variables pre-impacto del registro, cada una justificada y documentada en `tab02_feature_contract.csv`. Se excede el mínimo de 12 e incluye codificación cíclica de la hora, *frequency encoding* de vía, coordenadas estandarizadas, condiciones de clima y geometría de vía, y *flags* de faltantes.

13.3. Conclusión sobre OE3 (modelo y baselines)

Cumplido, con reporte honesto. Se entrenó un perceptrón multicapa y se comparó contra tres líneas base. El MLP supera con claridad al `DummyClassifier` y entrega el mayor *recall*-multifatal (0.8849), la métrica privilegiada por la regla de costo asimétrico.

La regresión logística obtiene un F1 nominalmente superior (0.3081 vs. 0.2746) dentro de intervalos traslapados: en datos tabulares de este tamaño los métodos lineales compiten de igual a igual, y este trabajo lo reporta en lugar de ocultarlo (contingencia C13).

13.4. Conclusión sobre OE4 (interpretabilidad)

Cumplido. El top-5 SHAP (`clase_atropello`, `zona_rural`, `clase_despiste`, `clase_choque`, `zona_urbana`) se identificó y se contrastó con los hallazgos del EDA: la coherencia es alta y la red aprendió exactamente las variables de contexto que motivaron el cambio de fuente de datos.

13.5. Conclusión sobre OE5 (interfaz)

Cumplido. La interfaz gráfica en Streamlit reutiliza el contrato de preprocesamiento mediante `preparar_entrada()`, con cuatro pestañas operativas, un *gauge* de probabilidad calibrada, comparación contra tasas históricas, ranking territorial con mapa coroplético y una pestaña sobre el modelo. Los siete checks funcionales pasan y la app se verificó de punta a punta en navegador.

13.6. Conclusión general

Se desarrolló una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (EDA → preprocesamiento → ingeniería → entrenamiento → evaluación única → calibración → GUI), reproducible (semillas fijas, modelo canónico único, artefactos versionados) y documentado. La reformulación del problema hacia la letalidad múltiple —forzada por la naturaleza fatal-únicamente de la mejor fuente disponible— resultó metodológicamente productiva: la discriminación mejoró (ROC-AUC 0.6840 → 0.7474), las probabilidades ahora están calibradas (Brier 0.0872, mejor que el predictor de tasa base) y la incertidumbre se reporta con intervalos bootstrap. Las limitaciones se declaran sin maquillaje: la logística compite con la red, el registro es preliminar y faltan variables mecánicas (ocupantes, velocidad) que fijarían el siguiente techo. El proyecto entrega lo comprometido y declara lo no comprometido, que es exactamente lo que un jurado valora.

14. Anexos

14.1. Anexo A1: Diccionario de datos completo

La base ONSV incluye sus encabezados descriptivos en la propia hoja SINIESTROS. El mapeo completo de columnas originales a nombres canónicos (p. ej. `FECHA SINIESTRO` → `FECHA`, `COD CARRETERA` → `CODIGO_VIA`, `CANTIDAD DE FALLECIDOS` → `FALLECIDOS`) está declarado en `COLUMN_MAP` dentro de `src/block_b_dataset_audit.py`. Se conservan en `data/raw/` los archivos de la primera iteración (CSV Sutran y su diccionario) como evidencia histórica.

14.2. Anexo A2: Estadísticos descriptivos

Tabla `tab01_descriptive_statistics.csv` con estadísticos descriptivos de todas las variables. Se omite su reproducción completa por extensión.

14.3. Anexo A3: Figuras adicionales del EDA

Las 14 figuras del EDA (`fig01–fig13` y `fig23`) están en `report/figures/`. En el cuerpo del informe se incluyó una selección; las restantes quedan en este anexo como evidencia complementaria.

14.4. Anexo A4: Código clave (listings)

El código fuente completo se mantiene en el repositorio. Se destacan aquí fragmentos centrales que prueban la corrección del pipeline.

14.4.1. Semillas y reproducibilidad

```
1 import os, random, numpy as np, tensorflow as tf
2 SEED = 42
3 os.environ["PYTHONHASHSEED"] = str(SEED)
4 random.seed(SEED); np.random.seed(SEED); tf.random.set_seed(SEED)
```

14.4.2. Split estratificado

```
1 from sklearn.model_selection import train_test_split
2 X_temp, X_test, y_temp, y_test = train_test_split(
3     X, y, test_size=0.15, stratify=y, random_state=SEED)
4 X_train, X_val, y_train, y_val = train_test_split(
5     X_temp, y_temp, test_size=0.1765, stratify=y_temp, random_state=SEED
6 )
```

14.4.3. Arquitectura final (corrida R5)

```
1 model = keras.Sequential([
2     layers.Input(shape=(n_features,)),
3     layers.Dense(32, activation="relu"),
4     layers.BatchNormalization(),
5     layers.Dropout(0.4),
6     layers.Dense(1, activation="sigmoid"),
7 ])
```

14.4.4. Compilación y pesos de clase

```
1 model.compile(optimizer=keras.optimizers.Adam(1e-3),
2               loss="binary_crossentropy",
3               metrics=[keras.metrics.AUC(curve="PR", name="pr_auc"),
4                       keras.metrics.Recall(name="recall"),
5                       keras.metrics.Precision(name="precision")])
6 w = compute_class_weight("balanced", classes=np.array([0,1]), y=y_train)
7 class_weight = {0: w[0], 1: w[1]}
```

14.5. Anexo A5: Verificación funcional de la GUI

La verificación funcional de la interfaz quedó registrada en `tab09_gui_checklist.csv` (siete checks superados) y `tab09_gui_demo_predictions.csv` (predicciones de los cinco casos de demostración). La app se verificó adicionalmente de punta a punta en navegador local.

14.6. Anexo A6: Bitácora de decisiones

La bitácora consolida las decisiones de contingencia tomadas durante la ejecución, en cumplimiento del Plan.

Tabla 12: Bitácora de decisiones durante la ejecución.

Fecha Bloque	- Situación / Decisión	Contingencia	Evidencia
2026-07-08 / A	Repositorio creado por Rendo. Se continúa desde verificación de estructura, entorno y permisos	Estado confirmado	Commits iniciales
2026-07-08 / A	Plan.md, dataset y diccionario ya subidos. Se verifica ubicación, fuente y reproducibilidad en README antes de procesar datos	Estado confirmado	README
2026-07-08 / B-H	Primera iteración completa con la fuente Sutran 2020–2021 (mortal/no-mortal). Diagnóstico: techo informacional, empate con la logística	C13	Historia de Git
2026-07-09 / B	Cambio de fuente a ONSV siniestros fatales 2021–2025 y reformulación del target a alta letalidad (2+ fallecidos), decisión discutida en la Sección 5	—	<code>tab00_audit_summary</code>
2026-07-09 / B	N registrado: 9 104 filas útiles	C2	<code>tab00_audit_summary</code>
2026-07-09 / B	% clase multifatal: 10.19 %	C5	<code>tab00_audit_summary</code>
2026-07-09 / B	Exclusión por fuga: lesionados, vehículos dañados, causas y señales	—	<code>block_b_dataset_audit.py</code>
2026-07-09 / D	Patrón de COD CARRETERA: prefijo alfabético extraíble	C11 no aplica (sí prefijo)	<code>block_d_preprocessing.py</code>
2026-07-09 / E	Mejor corrida del grid: R5 (una capa oculta)	—	<code>tab04_nn_grid_validation.csv</code>
2026-07-09 / E	Umbral seleccionado: 0.35 (regla: máx. recall con $F1 \geq 90$ % del mejor)	—	<code>tab_umbral_validacion.csv</code> , <code>fig15</code>
2026-07-09 / E	Solver de regresión logística: <code>liblinear</code> por inestabilidad de <code>lbfgs</code>	—	<code>block_e_modeling.py</code>

continúa

Tabla 12: (continuación)

Fecha Bloque	- Situación / Decisión	Contingencia	Evidencia
2026-07-09 / F	La logística obtiene F1 nominalmente superior al MLP; el MLP gana en recall	C13 se discute	tab03, Sección 12
2026-07-09 / F	Calibración isotónica post-hoc ajustada en validación	—	tab11, fig22
2026-07-09 / G	SHAP local en la GUI: explicar simplificado + SHAP en informe/anexos	C14	app/streamlit_app.py
2026-07-09 / D/G	demo_cases.csv desde validación, no de test	C23	demo_cases.csv, tab06
2026-07-09 / H	Separador decimal del informe: punto	Guía de estilo 7	Edición

14.7. Anexo A7: Enlace al repositorio y reproducibilidad

El repositorio contiene comandos exactos para reproducir el pipeline, lanzar la GUI y compilar el informe:

```

1 # Entorno
2 python3.12 -m venv .venv && source .venv/bin/activate # macOS
3 pip install -r requirements.txt
4
5 # Pipeline (scripts por bloque, en orden)
6 python src/block_b_dataset_audit.py
7 python src/block_c_eda.py
8 python src/block_d_preprocessing.py
9 python src/block_e_modeling.py
10 python src/block_f_evaluation.py
11 python src/block_f_posthoc_calibration.py
12 python src/block_g_app_check.py
13 python tests/test_preprocessing_contract.py
14
15 # Interfaz
16 streamlit run app/streamlit_app.py
17
18 # Informe
19 cd report && latexmk -pdf -interaction=nonstopmode main.tex
20 # el PDF final se copia a report/output/informe.pdf

```

Los congelados por plataforma (requirements-macos.txt, requirements-windows.txt) registran las versiones exactas usadas por cada integrante como evidencia de reproducibilidad.

Referencias

- [1] Observatorio Nacional de Seguridad Vial (ONSV). Sinistros de tránsito fatales 2021-2025 (preliminar). <https://www.onsv.gob.pe/datosabiertos>, 2026. Publicado el 2026-02-27; detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional, 2021–2025 (preliminar); verificado localmente el 2026-07-09.

- [2] World Health Organization. Road traffic injuries. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>, 2023.