

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para clasificación retrospectiva de multifatalidad (ONSV 2021–2025)

Rendo Alfonte Tarqui
Yimmy Yeyson Cuyo Zamata

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una única red neuronal para clasificar retrospectivamente siniestros viales ya fatales del Perú según hayan registrado un fallecido o dos o más. La fuente oficial ONSV 2021–2025 contiene 9 104 registros útiles y prevalencia multifatal de 10.19 %. Una auditoría estructural demostró que la tabla PERSONAS reconstruye el objetivo en 9 104 de 9 104 registros; por ello toda característica derivada de PERSONAS fue eliminada. Solo se conservaron agregados de VEHICULOS bajo alcance histórico retrospectivo.

El contrato final transforma 21 campos crudos en 169 características. La MLP es $169 \rightarrow 64 \rightarrow 32 \rightarrow 1$, con ReLU, *dropout* 0.35, L2 de 3×10^{-4} y 12 993 parámetros. La arquitectura se seleccionó con ajuste 2021 y selección 2022; el modelo se reajustó en 2021–2022 durante 14 épocas fijas; Platt y los umbrales se determinaron en 2023.

La referencia 2024–2025 ya había sido consultada y solo se usa de forma descriptiva. Allí, la escala calibrada obtuvo PR-AUC 0.3254 [IC 95 %: 0.2703–0.3871], ROC-AUC 0.7916 [0.7595–0.8227], F1 0.3989 [0.3523–0.4423], Brier 0.0777 y ECE 0.0133. Son resultados moderados, no una validación externa. El trabajo incorpora además diagnósticos rolling internos, curvas de aprendizaje comparables, estabilidad de la explicación SHAP, auditorías de capacidad y de representación, y cinco escenarios de demostración. El modelo es reproducible a partir de las fuentes oficiales verificadas, pero no existe una cohorte externa o prospectiva intacta.

Palabras clave: red neuronal; perceptrón multicapa; clasificación binaria desbalanceada; multifatalidad vial; validación temporal; calibración de probabilidades; fuga de información; seguridad vial; Perú.

Índice

1. Introducción	4
2. Objetivos	4
2.1. Objetivo general	4
2.2. Objetivos específicos	4
2.3. Métricas comprometidas antes de entrenar	5
3. Marco teórico	5
3.1. Clasificación binaria desbalanceada	5
3.2. Red neuronal multicapa	5
3.3. Calibración y decisión	5
3.4. Regularización y complejidad	6
3.5. Explicabilidad e incertidumbre	6
4. Metodología	6
4.1. Protocolo temporal	6
4.2. Diagnóstico rolling anidado	6
4.3. Técnicas aplicadas y técnicas descartadas	6
4.4. Incertidumbre	7
5. Dataset	7
5.1. Objetivo	8
5.2. Variables de entrada	8
5.3. Prueba de fuga PERSONAS	9
5.4. Disponibilidad	9
6. Análisis exploratorio de datos	9
6.1. Distribución del objetivo y desbalance	9
6.2. Patrones temporales	9
6.3. Clase de siniestro	11
6.4. Análisis territorial	11
6.5. Vías y condiciones pre-impacto	11
6.6. Patrones combinados, calidad de datos y geografía	12
6.7. Hallazgos H1–H11	13
7. Preprocesamiento	14
8. Ingeniería de características	14
9. Modelo neuronal	14
9.1. Arquitectura exacta	14
9.2. Entrenamiento y generalización	16
9.3. Una red, no dos	18
9.4. Ancho, profundidad y presupuesto de épocas	18
9.5. Curva de aprendizaje frente al tamaño de muestra	19
9.6. Representación de entrada: embeddings frente a codificación dispersa	20
9.7. Enriquecimiento del contrato VEHICULOS	21
9.8. Explicabilidad estable	22

10.Resultados	23
10.1. Referencia histórica ya consultada	23
10.2. Capacidad de ordenamiento	23
10.3. Calibración y estructura del error	23
10.4. Separabilidad y elección del umbral	24
10.5. Valor del ordenamiento y estabilidad por segmento	25
10.6. Baselines	26
10.7. Diagnósticos rolling	27
11.Interfaz gráfica	27
11.1. Panorama y arquitectura visible	27
11.2. Formulario de inferencia	28
11.3. Salida de la red	29
11.4. Evidencia y límites	30
12.Discusión	31
12.1. Por qué la red no supera a los métodos clásicos	32
13.Conclusiones	33
14.Trabajo futuro	34
14.1. Acumular periodos antes que cambiar el modelo	34
14.2. Cohorte prospectiva o externa	34
14.3. Ampliar el conjunto de variables antes que la arquitectura	34
14.4. Reducir la capacidad del artefacto entregado	35
14.5. Revisar el papel de la regularización	35
14.6. Comparación con equivalencia declarada	35
15.Anexos	35
15.1. Repositorio y estructura del proyecto	35
15.2. Configuración canónica	36
15.3. Artefactos de evidencia	36

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú y en el mundo [12]. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica una base a nivel de registro de los siniestros fatales del país [7], con variables de contexto como zona rural/urbana, red vial, condición climática, característica de la vía, perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?*

En rigor técnico, el problema abordado es de **clasificación binaria** entre letalidad simple y multifatalidad. La capa de salida de la red produce una probabilidad continua de multifatalidad, y la categoría estimada resulta de aplicar sobre esa probabilidad un umbral de decisión validado; ambos productos se reportan por separado a lo largo del informe, porque responden a preguntas distintas: cuán probable es el desenlace y qué clase se declara. El desarrollo abarca el ciclo completo de trabajo: análisis exploratorio, preprocesamiento, ingeniería de características, entrenamiento y selección de arquitectura, calibración, evaluación, explicabilidad e interfaz gráfica de consulta.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, interpretando cada hallazgo en función de su consecuencia para el modelado.
- **OE2.** Derivar el conjunto de características a partir de las variables pre-impacto del registro, justificando cada familia por su correspondencia con un hallazgo del análisis o con una restricción de disponibilidad.

- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier(strategy=prior)`, regresión logística y *random forest*. Si la MLP no supera a un método clásico, se reporta y discute honestamente.
- **OE4.** Identificar familias de variables asociadas al score mediante Gradient SHAP y comprobar la estabilidad de sus bandas de importancia.
- **OE5.** Desplegar una interfaz gráfica en Streamlit que consuma exactamente el bundle de inferencia canónico, con verificación de hashes y paridad.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello las métricas y las reglas de decisión se fijaron antes de entrenar:

- Selección de configuración completa: **mayor mediana de PR-AUC en selección 2022 entre semillas**; desempates por mayor F1 mediana y, después, menor IQR de PR-AUC. Cada configuración combina capas, dropout, L2 y tasa de aprendizaje.
- Métricas reportadas sin excepción: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* únicamente como referencia.
- No se argumenta calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Selección de umbral: máximo F1 en validación, con desempates predeclarados por *recall*, precisión y mayor umbral; no se ajusta después de observar 2024–2025.

3. Marco teórico

3.1. Clasificación binaria desbalanceada

La red estima un score $\hat{p} = \sigma(z)$ para la clase multifatal. La BCE guía el ajuste y los pesos de clase evitan que la clase positiva, cercana al 10 %, quede ignorada. PR-AUC es la métrica principal de ranking porque debe leerse contra la prevalencia; ROC-AUC se conserva como medida complementaria. F1, precisión y recall dependen del umbral.

3.2. Red neuronal multicapa

Cada capa Dense calcula $h = \text{ReLU}(Wx+b)$ y la salida aplica sigmoide [4]. Backpropagation obtiene gradientes de BCE más L2, y Adam actualiza pesos [5]. Dropout desactiva aleatoriamente unidades solo durante entrenamiento [11]. Early stopping y reducción de tasa controlan la trayectoria durante selección; no agregan capas ni parámetros [9].

La arquitectura concreta empleada en este trabajo, con sus anchos y su conteo de parámetros, se presenta en la sección 9.

3.3. Calibración y decisión

Platt aprende una regresión logística sobre el logit del score crudo. La calibración puede reducir Brier y ECE, pero una transformación monótona no mejora PR-AUC o ROC-AUC. El umbral crudo 0.65 y el calibrado 0.15 pertenecen a escalas distintas.

3.4. Regularización y complejidad

L2 penaliza magnitud de pesos; dropout reduce coadaptación; pesos de clase modifican el costo del desbalance; early stopping limita épocas; ReduceLROnPlateau refina el descenso. No son sinónimos ni una lista decorativa. La auditoría compara L2/dropout y alternativas de una o varias redes; solo se conservan técnicas ejecutadas y justificadas.

3.5. Explicabilidad e incertidumbre

Gradient SHAP describe cómo el modelo congelado distribuye su score respecto de un fondo [6]. Es asociación, no causalidad. La estabilidad se comprueba en tres muestras deterministas y se reporta por bandas. Los intervalos bootstrap de métricas son condicionales a predicciones congeladas y no constituyen intervalos individuales.

4. Metodología

4.1. Protocolo temporal

La arquitectura se seleccionó sin utilizar 2023 ni la referencia: fit 2021 y selección 2022. El número de épocas de la corrida seleccionada se fijó en 14; luego se reajustó una sola MLP con todo 2021–2022. En 2023 se compararon calibradores mediante predicciones OOF, se ajustó Platt y se fijaron los umbrales. Los 2 232 registros 2024–2025 se conservan como referencia histórica ya consultada. El cuadro 1 resume el tamaño, los positivos y el rol asignado a cada periodo; ningún periodo cumple dos roles.

Tabla 1: Roles cronológicos del artefacto final.

Periodo	n	Positivos	Rol
2021–2022	4 872	510	Reajuste final tras selección interna 2021/2022
2023	2 000	196	Calibración OOF y umbrales
2024–2025	2 232	222	Referencia histórica; sin ajustes

4.2. Diagnóstico rolling anidado

Se ejecutaron dos folds usando exclusivamente fechas anteriores a 2024. En cada fold, fit, selección, calibración y ventana outer son cronológicos y no se solapan. El primer outer corresponde a julio–diciembre de 2022 y el segundo a 2023. Los resultados son diagnósticos de variabilidad, no un test externo; los folds comparten historia y solo existen dos ventanas viables.

4.3. Técnicas aplicadas y técnicas descartadas

La búsqueda cerrada comparó tres configuraciones por tres semillas. El cuadro 2 declara qué se aplicó y qué no, con el motivo en cada caso, de modo que ninguna decisión quede como preferencia implícita. El criterio general fue admitir una técnica solo cuando resolvía un problema observado en este conjunto de datos, y no por ser habitual en la literatura.

Tabla 2: Inventario de técnicas. Las descartadas se documentan con el mismo detalle que las aplicadas.

Técnica	Uso	Motivo
Entropía cruzada binaria	Sí	Función de pérdida propia de la clasificación binaria probabilística.
Pesos de clase balanceados	Sí	La clase positiva es el 10 %; sin ponderación el gradiente queda dominado por la clase mayoritaria.
Adam	Sí	Convergencia estable con tasa inicial baja en un problema de gradiente ruidoso.
Regularización L2	Sí	Se conserva por parsimonia; la ablación muestra un efecto de 0.0044, inferior al ruido entre semillas.
<i>Dropout</i> 0.35	Sí	Mismo criterio que L2; su efecto medido es igualmente pequeño.
<i>Early stopping</i>	Sí	Determina el número de épocas durante la selección; es el control de ajuste efectivo.
ReduceLROnPlateau	Sí	Refina el descenso al estancarse la métrica de selección.
Calibración Platt	Sí	Corrige la escala de probabilidad: ECE de 0.2338 a 0.0133. Se eligió frente a isotónica por menor Brier OOF.
Regularización L1	No	No se busca selección de variables: el contrato ya está fijado por criterios de disponibilidad y fuga.
SMOTE y remuestreo [2]	No	Genera positivos sintéticos interpolando entre casos reales, lo que distorsiona la calibración; el desbalance ya se trata con pesos de clase, que no altera la distribución.
<i>Batch normalization</i>	No	Su beneficio se concentra en redes profundas; con dos capas ocultas y entradas ya estandarizadas no resuelve ningún problema observado.
<i>Stacking</i> y ensamblado	No	El bootstrap pareado del promedio de tres semillas frente a la red única incluye el cero en todas las métricas.
Aumento de capacidad	No	Nueve arquitecturas de 32 a 384 neuronas cubren un rango de desempeño (0.0179) equiparable al ruido entre semillas.
<i>Embeddings</i> de entidad	No	Alcanzan desempeño equivalente con menos parámetros, pero sin mejora medible; se documentan como auditoría.

4.4. Incertidumbre

Los IC bootstrap son percentiles por remuestreo de filas con pipeline y predicciones congeladas, sin reajuste. No incluyen incertidumbre de entrenamiento o selección, dependencia temporal/espacial, consulta repetida de la referencia, generalización externa/futura ni incertidumbre individual.

5. Dataset

La fuente es el catálogo oficial ONSV <https://www.onsv.gob.pe/datosabiertos>. Los archivos SINIESTROS, VEHICULOS, PERSONAS y el diccionario se declaran en `data/raw/source_manifest.json` con URL, tamaño, hojas y SHA-256. El pipeline verifica el conjunto exacto antes de leer; una fuente modificada, faltante o adicional detiene la ejecución. Los datos 2024–2025 son preliminares.

Tabla 3: Campos crudos del contrato de entrada. La columna “Nulo” indica si el campo admite ausencia, en cuyo caso el preprocesamiento asigna la categoría **DESCONOCIDO** o un indicador explícito de falta.

Campo	Tipo	Nulo	Contenido
<i>Registro SINIESTROS</i>			
FECHA	fecha	no	Fecha del siniestro; origen de mes, día de semana y feriado
HORA	texto	no	Hora del siniestro; origen de codificación cíclica y franja
DEPARTAMENTO	texto	no	Departamento; origen de la región natural
CODIGO_VIA	texto	sí	Código oficial de la vía; origen de prefijo y frecuencia
LATITUD	decimal	no	Latitud geográfica
LONGITUD	decimal	no	Longitud geográfica
CLASE	texto	no	Mecánica del siniestro: choque, atropello, despiste, volcadura
ZONA	texto	sí	Zona rural o urbana
RED_VIAL	texto	sí	Jerarquía: nacional, departamental, provincial, urbana
TIPO_VIA	texto	no	Carretera, avenida, calle, vía expresa
CLIMA	texto	sí	Condición climática registrada en la escena
CARACTERISTICA_VIA	texto	sí	Geometría: tramo recto, curva, intersección, estructura
PERFIL_VIA	texto	sí	Perfil longitudinal: plana o inclinada
SUPERFICIE	texto	sí	Superficie de calzada: pavimentada, afirmado, trocha
<i>Registro VEHICULOS (agregados por siniestro)</i>			
n_vehiculos	entero	no	Vehículos involucrados
n_bus	entero	no	Buses y minibuses
n_pesado_carga	entero	no	Vehículos pesados de carga
n_moto	entero	no	Motos, trimotos y bicicletas
n_no_identificado	entero	no	Vehículos sin identificación
n_interprovincial	entero	no	Unidades de servicio interprovincial
n_transporte_publico	entero	no	Transporte público urbano y taxis

5.1. Objetivo

El universo contiene solo siniestros fatales. Por tanto, $y = 1$ cuando $FALLECIDOS \geq 2$ y $y = 0$ cuando $FALLECIDOS = 1$. El modelo no estima la probabilidad de que cualquier accidente sea fatal.

5.2. Variables de entrada

El contrato de entrada persistido en `models/final/feature_schema.json` exige exactamente 21 campos crudos, listados en el cuadro 3. Catorce provienen del registro SINIESTROS y siete son agregados del registro acompañante VEHICULOS. Ese conjunto es el único admitido en inferencia: la aplicación rechaza un registro con campos faltantes, adicionales o de tipo incompatible.

Quedan deliberadamente fuera del contrato los campos que describen el desenlace (**FALLECIDOS**, **LESIONADOS**, **VEHICULOS_DANADOS**), las conclusiones de la investigación posterior (**CAUSA_FACTOR**, **CAUSA_ESPECIFICA**), los identificadores administrativos y las señales viales, cuya ausencia depende del periodo de registro.

5.3. Prueba de fuga PERSONAS

La auditoría por código comparó SINIESTROS con PERSONAS. El conteo `GRAVEDAD = FALLECIDO` coincide con `FALLECIDOS` y reconstruye el target en los 9 104 registros; además, el número de filas `PERSONAS` cubre necesariamente a los fallecidos. Excluir solamente `GRAVEDAD` era insuficiente. La decisión final excluye toda la fuente `PERSONAS` de los predictores; solo permanece como prueba de linaje.

5.4. Disponibilidad

Se conservan siete agregados `VEHICULOS`: total, buses, carga pesada, motos, no identificados, servicio interprovincial y transporte público. Los libros no incluyen timestamps por campo. Por ello su uso solo se defiende para clasificación histórica retrospectiva de registros consolidados, no para tiempo real o instante de notificación.

6. Análisis exploratorio de datos

El análisis exploratorio se ejecutó sobre `base_limpia.parquet` y produjo catorce figuras y once hallazgos numerados H1–H11. Cada hallazgo se interpreta en función de su consecuencia para la ingeniería de características, de modo que las decisiones de la sección 8 tengan respaldo empírico y no queden libradas a la intuición. Las figuras se regeneran de forma reproducible desde `src/block_c_edu.py`.

6.1. Distribución del objetivo y desbalance




Figura 1: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con $F1$, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales

La serie mensual de la figura 2 muestra que la frecuencia de siniestros fatales no es constante: el máximo se alcanza en junio de 2021 con 229 registros y la caída de 2024–2025 responde en parte al cierre preliminar del registro, no necesariamente a una mejora

real. Esa variación temporal es la que justifica derivar variables de calendario en lugar de tratar la fecha como un número.




Figura 2: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 3: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).




Figura 4: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.

La figura 5 repite ese contraste sobre el día de la semana: el volumen y la tasa multifatal no se mueven juntos, de modo que ambas señales aportan información distinta y se conservan como características separadas.




Figura 5: Siniestros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro




Figura 6: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 7: Tasa multifatal por clase. DESPISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 8: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).




Figura 9: Top-15 departamentos por tasa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto

La concentración por corredor vial de la figura 10 motiva tratar el código de vía por su frecuencia y su prefijo, y no como una etiqueta arbitraria: unas pocas rutas acumulan una fracción desproporcionada de los siniestros fatales.




Figura 10: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1032 casos (H7).




Figura 11: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables aportan contexto inicial relevante para el modelo.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía

Las dos últimas comprobaciones del análisis atienden a la interacción entre variables y a la calidad del registro. El mapa de calor de la figura 12 cruza mes y hora y revela concentraciones que ninguna de las dos variables explica por separado, lo que sostiene el uso de codificaciones cíclicas y de franja. La figura 13 cuantifica la ausencia de datos por columna y es la evidencia que motiva excluir las señales viales del contrato de entrada: su ausencia no es aleatoria, sino dependiente del periodo de registro.




Figura 12: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.




Figura 13: Porcentaje de faltantes por columna. Las señales viales alcanzan 77.9 % (H10) y por eso se excluyen del modelo; el resto admite imputación simple con *flags*.




Figura 14: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Los once hallazgos se documentan junto a la figura que los sustenta. Los más relevantes para el modelado son los siguientes:

- **H1:** la clase multifatal representa 10.2 % de los siniestros fatales (figura 1), confirma desbalance y justifica las métricas.
- **H3:** la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 3 y 4).
- **H5:** CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 6 y 7).
- **H6:** LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCAYELI lidera la tasa multifatal con 28.0 % (figuras 8 y 9).
- **H8:** zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 11). Las condiciones pre-impacto separan el riesgo.
- **H11:** el scatter geográfico (figura 14) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

El preprocesamiento se ajusta únicamente en la partición de fit correspondiente. Normaliza categorías, crea una categoría DESCONOCIDO, asigna frecuencia cero a códigos de vía no vistos, estandariza continuas y genera codificación *one-hot*. Mes, día semanal y hora se representan cíclicamente. Se incluyen interacciones predeclaradas de contexto vial.

El contrato persistido contiene 21 campos crudos y 169 columnas `float32` en orden fijo. Se excluyen fallecidos, lesionados, vehículos dañados, causas investigadas, identificadores y toda característica PERSONAS. El esquema, escalador, encoders, modelo, calibrador y umbrales se verifican por hash antes de inferencia.

Ajustar el preprocesador únicamente en la partición de fit es la salvaguarda que evita la fuga más común en series temporales: si la media de estandarización, la mediana de imputación o el mapa de frecuencias de vía se calcularan sobre todo el conjunto, cada partición posterior quedaría contaminada con información de su propio futuro. El desempeño resultante de este contrato se documenta en la sección 9.

8. Ingeniería de características

Las 169 columnas del contrato procesado se derivan de los 21 campos crudos del cuadro 3 y se agrupan en seis familias, detalladas en el cuadro 4. Ninguna característica se incorporó por conveniencia numérica: cada familia responde a un hallazgo del análisis exploratorio o a una restricción de disponibilidad.

Las variables categóricas se representan con codificación *one-hot* incluyendo una categoría DESCONOCIDO explícita, de modo que la ausencia se modela como información y no como un valor imputado en silencio. Las continuas se estandarizan con la media y la desviación de la partición de ajuste.

El cuadro 5 resume por qué cada fuente entra o no al contrato. No se inventaron variables externas. Un código de vía no observado conserva su prefijo si es válido y recibe frecuencia cero; la demostración sintética de la interfaz verifica esa sensibilidad sin atribución causal.

9. Modelo neuronal

9.1. Arquitectura exacta

La única red canónica es:

$$\begin{aligned} 169 &\rightarrow \text{Dense}(64, \text{ReLU}) \rightarrow \text{Dropout}(0.35) \\ &\rightarrow \text{Dense}(32, \text{ReLU}) \rightarrow \text{Dropout}(0.35) \rightarrow \text{Dense}(1, \sigma). \end{aligned}$$

Tiene dos capas ocultas, tres capas Dense entrenables y 12 993 parámetros: $(169 + 1)64 + (64 + 1)32 + (32 + 1)1$. La figura 15 representa esa topología: cada capa está totalmente conectada con la siguiente, de modo que el número de pesos entre dos capas es el producto de sus anchos, más un sesgo por neurona de destino.

La configuración MLP_64_32, semilla 42, usa L2 3×10^{-4} , Adam con tasa 5×10^{-4} y lote 64. La implementación reproducible usa TensorFlow/Keras [1, 3]. La arquitectura se elige por mediana PR-AUC entre tres semillas en la selección 2022; la corrida mediana

Tabla 4: Familias de características procesadas. La suma de la columna de conteo es 169, el ancho exacto que verifica el esquema antes de cada inferencia.

Familia	Columnas	Justificación
Tiempo cíclico y calendario	14	Mes, día de semana y hora se codifican como pares seno/coseno para que diciembre y enero, o domingo y lunes, no queden representados como extremos opuestos. Incluye franja horaria, indicador nocturno, fin de semana e indicador de hora ausente. Responde a H3 y H9.
Geografía	32	Latitud y longitud estandarizadas, indicador de coordenada ausente, departamento y región natural. El scatter geográfico (H11) muestra que los siniestros siguen corredores viales, señal que el departamento por sí solo no captura.
Vía: código, red y tipo	38	Frecuencia del código de vía calculada solo en la partición de ajuste, prefijo del código, red vial y tipo de vía. Responde a H7: unas pocas rutas concentran el volumen, pero el código no admite lectura ordinal.
Clase y condiciones registradas	28	Clase de siniestro, zona, clima, característica vial, perfil longitudinal y superficie. Responde a H5 y H8, los hallazgos con mayor separación de tasa multifatal.
Agregados VEHICULOS	7	Conteos por tipo de vehículo del registro consolidado, admitidos solo bajo alcance retrospectivo.
Interacciones predeclaradas	50	Noche×rural y lluvia×curva como indicadores binarios, más los cruces completos tipo de vía×zona y red vial×clase. Se declararon antes de entrenar para evitar la búsqueda posterior de interacciones favorables.
Total	169	

Tabla 5: Decisiones de disponibilidad por familia de origen.

Familia	Evidencia temporal	Decisión
SINIESTROS/ contexto	Sin timestamp por campo	Usar solo con alcance retrospectivo
VEHICULOS	Registro consolidado, sin timestamp	Incluir siete agregados con alcance restringido
PERSONAS	Cardinalidad y fallidos reconstruyen el target	Excluir toda la fuente de predictores
Resultados/ causas	Posteriores o directos	Excluir




Figura 15: Topología de la red canónica. Las tres capas Dense son de conexión total: los 169 valores de entrada alcanzan las 64 neuronas de la primera capa oculta, estas las 32 de la segunda, y estas la única neurona sigmoide de salida. Los puntos suspensivos indican las neuronas no dibujadas; el dropout no es una capa con parámetros, sino una desactivación aleatoria de salidas que opera únicamente durante el entrenamiento.

determina 14 épocas para el reajuste 2021–2022. El umbral crudo 0.65 y el calibrado 0.15 se validan y fijan en 2023.

La figura 16 justifica esa regla de decisión. Las nueve corridas de la búsqueda muestran que la dispersión entre semillas de una misma configuración es comparable a la distancia entre configuraciones: la mejor corrida individual pertenece a MLP_64_32, pero su peor corrida queda por debajo de la mediana de las otras dos. Elegir por el máximo habría premiado una semilla afortunada; por eso el criterio predeclarado usa la mediana y conserva la corrida mediana, no la extrema.

9.2. Entrenamiento y generalización

La figura 17 documenta el entrenamiento de la corrida seleccionada. Ambas series usan PR-AUC no ponderada, de modo que son directamente comparables; la curva de 2021 se calcula con *dropout* activo, mientras que la de 2022 se evalúa en modo inferencia, lo que explica que la serie de ajuste quede por debajo durante las primeras épocas. La época 14 es el máximo de PR-AUC en la partición de comparación y fija la duración del reajuste posterior en 2021–2022, sin *callbacks* de validación.

Para el modelo reajustado, la PR-AUC de entrenamiento es 0.4332 y la de la partición 2023 es 0.3367, con una brecha de 0.0965. El Brier aumenta solo 0.0036 entre ambas particiones: la red no está severamente sobreajustada, pero pierde capacidad de ordenamiento fuera del periodo de ajuste.




Figura 16: PR-AUC por configuración completa y semilla durante la selección. La regla usa la mediana; la dispersión impide elegir por una corrida afortunada.




Figura 17: Curvas de aprendizaje de la corrida seleccionada. La meseta de la serie de comparación a partir de la época 12 indica que épocas adicionales no aportan capacidad de generalización: el criterio de parada no se eligió a posteriori.




Figura 18: Auditoría 2023 de regularización y número de redes. El eje derecho muestra diferencias pareadas del ensemble respecto de la red única; los intervalos incluyen cero.

9.3. Una red, no dos

La auditoría comparó una MLP congelada, un promedio de tres semillas y una multirrama contexto/VEHICULOS. Los IC pareados del ensemble frente a la red única incluyen cero en todas las métricas reportadas. Sin evidencia concluyente y sin una nueva cohorte, una segunda red agregaría complejidad y otra decisión de selección. Se conserva una sola MLP.

La figura 18 reúne las dos preguntas de diseño en una misma validación de 2023. El panel izquierdo compara la configuración canónica contra sus ablaciones (solo L2, solo dropout, y sin ninguna de las dos): las cuatro variantes quedan muy por encima de la prevalencia, y sus diferencias son pequeñas frente a la dispersión entre semillas, de modo que la regularización se conserva por criterio de parsimonia y no porque produzca un salto de desempeño. El panel derecho muestra las diferencias pareadas del ensemble respecto de la red única; los tres intervalos cruzan el cero.

9.4. Ancho, profundidad y presupuesto de épocas

La búsqueda que fijó la arquitectura comparó tres configuraciones. Esa cifra es corta, y la objeción evidente es que un modelo con más neuronas, más capas o más épocas podría rendir mejor. La objeción se resolvió por medición: se amplió la grilla a nueve arquitecturas, de una a tres capas ocultas y de 32 a 384 neuronas totales, evaluadas sobre la misma superficie legítima de selección —ajuste en 2021 y comparación en 2022— con la misma regla predeclarada y las mismas tres semillas.

El cuadro 6 contiene el resultado central: la diferencia entre la mejor y la peor de las nueve arquitecturas es 0.0179, mientras que la dispersión entre semillas de la propia configuración canónica es 0.0162. **El rango completo del espacio de arquitecturas es del mismo orden que el ruido de una sola arquitectura.** Aumentar la capacidad no ayuda de forma monótona: la red de 256–128, con 76 545 parámetros, queda por debajo de una única capa de 64 neuronas que usa siete veces menos. Tampoco ayuda la profundidad: la mejor configuración tiene una sola capa oculta y las de tres capas ocupan posiciones intermedias. La superficie de respuesta es plana dentro del ruido.

El panel central de la figura 19 responde a la pregunta del presupuesto de épocas, y lo hace con la forma canónica del sobreajuste. La PR-AUC de entrenamiento crece de manera sostenida hasta 0.727 en la época 70, mientras que la de validación alcanza su

Tabla 6: Barrido de capacidad en la partición de selección de 2022. La columna IQR mide la dispersión entre semillas de cada configuración.

Arquitectura	Capas	Parámetros	PR-AUC mediana	IQR
64	1	10 945	0.3906	0.0123
128	1	21 889	0.3847	0.0043
128–64	2	30 081	0.3833	0.0108
128–64–32	3	32 129	0.3831	0.0103
64–32–16	3	13 505	0.3822	0.0064
256–128	2	76 545	0.3801	0.0046
32	1	5 473	0.3763	0.0035
64–32 (canónica)	2	12 993	0.3734	0.0162
32–16	2	5 985	0.3727	0.0030




Figura 19: Auditoría de capacidad. Izquierda: desempeño frente a número de parámetros en escala logarítmica. Centro: divergencia entre ajuste y validación al extender el reajuste. Derecha: curva de aprendizaje frente al número de registros de entrenamiento.

máximo en la época 22 con 0.3326 y a partir de ahí se deteriora hasta 0.3054. En la época 14 la validación vale 0.3282, apenas 0.0044 por debajo del máximo observado y dentro del rango entre semillas de esa misma época. Entrenar más no mejora el modelo: lo memoriza. El presupuesto fijo de épocas es, en consecuencia, el mecanismo de control efectivo del ajuste, y su valor canónico es conservador pero correcto.

9.5. Curva de aprendizaje frente al tamaño de muestra

Descartadas la capacidad y el presupuesto de épocas, queda por distinguir entre dos limitaciones que suelen confundirse: la del conjunto de variables y la del número de observaciones. El panel derecho de la figura 19 las separa, entrenando la configuración canónica sobre fracciones crecientes de la partición 2021–2022 y evaluando siempre en 2023.

La curva del cuadro 7 **no se ha estabilizado**: crece 0.0339 entre el 25 % y el 100 % de los datos, y el último tramo aporta todavía 0.0140, el mayor incremento parcial después del primero. Un modelo que hubiera agotado la información de sus variables mostraría una curva plana en el extremo derecho; esta sigue subiendo. La conclusión es que el modelo está limitado también por el tamaño de muestra, y no únicamente por el conjunto de variables disponible.

Esta observación matiza el diagnóstico y tiene una consecuencia práctica inmediata.

Tabla 7: Desempeño en la validación de 2023 según el número de registros de entrenamiento, con la configuración y el presupuesto de épocas canónicos.

Fracción	Registros	PR-AUC mediana	Rango entre semillas
25 %	1 218	0.2957	0.2251–0.3150
50 %	2 436	0.3106	0.3029–0.3251
75 %	3 654	0.3156	0.3103–0.3206
100 %	4 872	0.3296	0.3194–0.3356

Tabla 8: Contraste de representaciones bajo protocolo idéntico. La evaluación se realiza en la partición de validación de 2023; la referencia 2024–2025 no se abre en esta auditoría.

Representación	Entradas	Parámetros	PR-AUC	ROC-AUC	F1
One-hot canónica	169	12 993	0.3367	0.8151	0.3942
Embeddings de entidad	54	6 042	0.3181	0.8133	0.4000

Como la fuente publica un nuevo periodo cada año, el desempeño del modelo debería mejorar por acumulación de registros sin necesidad de modificar la arquitectura ni de incorporar fuentes externas. Es la vía de mejora más barata y más segura de las examinadas en este trabajo.

9.6. Representación de entrada: embeddings frente a codificación dispersa

El contrato canónico entrega a la red 169 columnas, de las cuales 153 son indicadores binarios y 48 son cruces categóricos calculados a mano. Esa representación merece un examen específico por dos razones. La primera es de diagnóstico: en la partición de ajuste, 50 de esas columnas se activan en menos de 30 registros y 18 permanecen siempre en cero, de modo que 1 152 pesos —el 8.9 % de la red— nunca reciben gradiente. La segunda es conceptual: entregar interacciones ya cruzadas en forma de indicadores equivale a resolver por adelantado la tarea que justifica el uso de una red, y a hacerlo en la forma más costosa en parámetros.

Se contrastó entonces una representación alternativa mediante *embeddings* de entidad: cada variable categórica se proyecta en un vector denso aprendido durante el entrenamiento, en lugar de expandirse en indicadores. El tronco (64–32–1), el optimizador, la tasa de aprendizaje, el tamaño de lote, las tres semillas, el protocolo temporal, la política de umbral y los vocabularios de categorías se mantuvieron idénticos; los cruces y las interacciones binarias construidas a mano se retiraron para que la red deba recuperarlas por sí misma. La única diferencia entre ambos modelos es, por tanto, la representación de la entrada, y el cuadro 8 resume el contraste.

El resultado, representado en la figura 20, es negativo respecto de la hipótesis de partida y positivo respecto de la comprensión del problema. Los tres intervalos del bootstrap pareado incluyen el cero: -0.0186 $[-0.0406; 0.0061]$ en PR-AUC, -0.0018 $[-0.0112; 0.0067]$ en ROC-AUC y $+0.0058$ $[-0.0175; 0.0305]$ en F1. Más revelador aún es que el orden se invierte según la partición: en la comparación interna de 2022 los *embeddings* superan a la codificación dispersa por mediana de PR-AUC (0.3960 frente a 0.3859), mientras que en 2023 quedan por debajo. Una diferencia que cambia de signo entre dos

Auditoría de representación: embeddings de entidad vs. one-hot · validación 2023




Figura 20: Auditoría de representación. Los dos modelos alcanzan discriminación estadísticamente indistinguible, pero la representación densa lo consigue con 54 entradas en lugar de 169 y 6 042 parámetros en lugar de 12 993, sin columnas muertas.

particiones contiguas no es una diferencia real, sino ruido de selección.

De aquí se desprenden dos conclusiones con consecuencias distintas. La primera es que **la representación no es el factor limitante**: si lo fuera, densificar la entrada habría producido una mejora sistemática, y no la produce. La segunda es que **el modelo canónico está sobredimensionado**: la misma información cabe en 6 042 parámetros y 54 dimensiones, menos de la mitad de la capacidad del artefacto entregado. El techo de desempeño lo fija el conjunto de variables disponible, no la manera de codificarlo; esta evidencia se retoma en la sección 12.

9.7. Enriquecimiento del contrato VEHICULOS

La sección anterior descarta la representación como factor limitante. Queda por examinar si el contrato desaprovecha información ya disponible. El libro VEHICULOS publica 25 columnas y el pipeline canónico consume tres, que colapsa en siete conteos. Entre las restantes hay atributos previos al impacto que son candidatos naturales a aproximar la ocupación y el estado del vehículo: qué transportaba la unidad, el ámbito territorial del servicio y la situación reglamentaria del seguro, la revisión técnica y la habilitación del operador.

Dos columnas se rechazaron antes de cualquier medición, por criterio y no por resultado: **SITUACIÓN VEHÍCULO** distingue al vehículo que se dio a la fuga, un hecho posterior al siniestro, y **TIPO SINIESTRO** reitera **CLASE**. Con las demás se construyeron diez agregados por siniestro que cuentan vehículos y nunca personas, de modo que están acotados por el número de unidades involucradas, magnitud que el contrato ya contiene.

La primera prueba fue de fuga, con el mismo criterio que excluyó a **PERSONAS**. Ningún agregado reproduce **FALLECIDOS** ni separa perfectamente el objetivo, y la correlación de rangos con el número de fallecidos no supera 0.068 en valor absoluto para ninguno de los diez. El contrato enriquecido es, por tanto, admisible. Pero esa misma prueba ya anticipa el resultado: una correlación de ese orden indica que las variables aportan muy poca información marginal sobre el desenlace.

El resultado, recogido en el cuadro 9, es que el enriquecimiento **no mejora y empeora levemente** la capacidad de ordenamiento: la diferencia pareada en PR-AUC es -0.0252 con IC 95 % $[-0.0505; -0.0007]$, nominalmente significativa y de signo negativo, mientras que ROC-AUC y F1 resultan indistinguibles. La explicación es coherente con el resto de

Tabla 9: Contrato canónico frente a contrato enriquecido, ambos entrenados bajo el mismo protocolo y evaluados en la validación de 2023.

Contrato	Entradas	PR-AUC	ROC-AUC	F1
Canónico	169	0.3282	0.8128	0.3915
Enriquecido con VEHICULOS	179	0.3029	0.8080	0.3937




Figura 21: Importancia global agrupada mediante Gradient SHAP. La magnitud resume asociación con el score congelado; el color no representa un efecto causal.

la evidencia. La señal de ocupación que se buscaba ya estaba capturada por los conteos de buses y de servicio interprovincial del contrato canónico, de modo que los nuevos agregados son en buena medida redundantes; además arrastran una ausencia masiva, pues el ámbito del servicio es desconocido en el 76 % de los registros de vehículos. Añadir diez dimensiones a un modelo que ya dispone de unos 25 parámetros por caso positivo agrega varianza sin aportar información.

9.8. Explicabilidad estable

Gradient SHAP usa fondo 2021–2022 y ejemplos 2023, sin etiquetas ni filas 2024–2025. Tres muestras/semillas deterministas producen correlación de rangos Spearman mínima 0.9897. Se reportan bandas de estabilidad; el orden exacto dentro de una banda no se interpreta como estable ni causal.

La figura 21 agrupa las 169 columnas por variable cruda de origen, de modo que una familia con muchas columnas *one-hot* no aparente importancia solo por su ancho. Los agregados de VEHICULOS concentran el 21.6 % de la importancia global con apenas siete columnas, seguidos por la clase de siniestro (12.2 % en seis columnas) y la interacción red vial×clase (11.7 %). El orden coincide con los hallazgos H5 y H8 del análisis exploratorio, lo que indica que la red aprovecha la misma estructura que el análisis descriptivo había anticipado, y no un patrón espurio. La lectura sigue siendo asociativa.

Tabla 10: Métricas del modelo canónico en la referencia histórica. Los intervalos son percentiles bootstrap al 95 % sobre remuestreo de filas con predicciones congeladas.

Métrica	Cruda, $t = 0.65$	Platt, $t = 0.15$
PR-AUC	0.3254 [0.2703, 0.3871]	0.3254 [0.2703, 0.3871]
ROC-AUC	0.7916 [0.7595, 0.8227]	0.7916 [0.7595, 0.8227]
F1	0.4030 [0.3496, 0.4487]	0.3989 [0.3523, 0.4423]
Precisión	0.3025	0.2830
Recall	0.6036	0.6757
Brier	0.1642	0.0777
ECE	0.2338	0.0133
<i>Accuracy</i> (solo referencia)	0.8221	0.7975

10. Resultados

10.1. Referencia histórica ya consultada

Los 2 232 registros de 2024–2025 contienen 222 multifatales. Este periodo no es un test nuevo: ya fue consultado y no autoriza reajustes. La finalidad del bundle no crea independencia científica. El cuadro 10 reúne el desempeño en ambas escalas de probabilidad.

La *accuracy* se reporta por coherencia con el protocolo predeclarado, y su lectura confirma exactamente por qué se descartó como criterio de calidad: un clasificador que respondiera siempre “letalidad simple” alcanzaría 0.9005 en esta misma partición, es decir, más que cualquiera de las dos escalas del modelo, sin identificar un solo siniestro multifatal. La escala calibrada exhibe menor *accuracy* que la cruda precisamente porque acepta más falsas alertas a cambio de recuperar más positivos.

Platt mejora la escala, no el ranking. La matriz calibrada contiene 1 630 TN, 380 FP, 72 FN y 150 TP. El mayor recall se obtiene a costa de más falsas alertas; no se presenta como desempeño excelente.

10.2. Capacidad de ordenamiento

Las curvas de la figura 22 separan la capacidad de ordenamiento del punto de decisión. La curva precisión-recall se lee contra la prevalencia de 0.099: la precisión se mantiene entre 0.30 y 0.40 en el rango de recall 0.2–0.7, es decir, tres a cuatro veces la línea base, pero nunca alcanza valores altos. La curva ROC muestra el comportamiento típico de una señal moderada, con la mayor ganancia concentrada en el primer 20 % de falsos positivos.

10.3. Calibración y estructura del error

La figura 23 contrasta ambas escalas de probabilidad. La sigmoide cruda es sistemáticamente optimista: en todos los bins la frecuencia observada queda por debajo de la diagonal, con ECE 0.2338. Tras Platt, los bins con soporte suficiente se alinean con la diagonal y el ECE baja a 0.0133. Los bins superiores de la escala calibrada reúnen entre 1 y 9 registros, por lo que su desviación aparente no es evidencia de descalibración.

La figura 24 traduce esa diferencia de escala en conteos de decisión y hace visible el intercambio que impone el umbral.

Desempeño de ranking en la referencia histórica 2024-2025 (scores crudos)




Figura 22: Curvas precisión-recall y ROC sobre los scores crudos de la referencia histórica. El punto de operación corresponde al umbral 0.65 fijado en 2023: recall 0.604 con precisión 0.302, sobre una tasa de falsos positivos de 0.154.

Diagrama de confiabilidad en la referencia histórica 2024-2025




Figura 23: Diagrama de confiabilidad por decil de probabilidad. El tamaño del punto es proporcional al número de registros del bin; se anota n cuando el bin reúne 25 registros o menos.

10.4. Separabilidad y elección del umbral

Las métricas agregadas no muestran cuánto se solapan las dos clases ni por qué el umbral se sitúa donde se sitúa. La figura 26 responde ambas cosas. El panel izquierdo superpone la distribución de la probabilidad calibrada según la clase observada, en escala logarítmica para que la clase minoritaria sea visible: las dos distribuciones se solapan de forma sustancial por debajo de 0.2, pero por encima de 0.35 los siniestros multifatales dominan, y prácticamente todos los casos con probabilidad superior a 0.55 pertenecen a esa clase. Ese es el origen de una PR-AUC moderada acompañada de un ordenamiento útil.

El panel derecho recorre la grilla completa de umbrales. La precisión crece de forma monótona y el *recall* decrece, como corresponde, y el F1 describe una meseta amplia entre




Figura 24: Matrices de confusión en ambas escalas. El umbral calibrado convierte 16 falsos negativos en verdaderos positivos (de 88 a 72) al precio de 71 falsas alertas adicionales (de 309 a 380): el desplazamiento de umbral redistribuye el error, no lo elimina.




Figura 25: Comparación descriptiva en la referencia histórica 2024-2025 sobre scores crudos. El liderazgo nominal no equivale a superioridad universal.

0.12 y 0.22 en lugar de un pico estrecho. El umbral 0.15, fijado en 2023 sin observar este periodo, cae dentro de esa meseta; el máximo de F1 sobre la referencia se alcanza en 0.17. Que la diferencia entre el umbral elegido a ciegas y el óptimo observado a posteriori sea de dos centésimas es evidencia de que la política de decisión se transfiere entre periodos.

10.5. Valor del ordenamiento y estabilidad por segmento

Para un uso realista importa menos la clase declarada que la capacidad de ordenar. La curva de ganancia acumulada de la figura 27 expresa esa capacidad en términos operativos: revisando el 10 % de los siniestros con mayor probabilidad se recupera el 32 % de los multifatales; revisando el 20 %, el 61 %; y revisando el 30 %, el 74 %. Frente a un orden aleatorio, que recuperaría respectivamente el 10, el 20 y el 30 %, el modelo triplica el rendimiento en el primer tramo.

Separabilidad de las clases y elección del umbral · referencia 2024-2025




Figura 26: Separabilidad de las clases y curva de decisión. El punto verde marca el umbral canónico de 0.15 sobre la curva de F1; la meseta a su alrededor indica que la decisión no es frágil ante pequeños desplazamientos del umbral.

Valor del ordenamiento y estabilidad por segmento · referencia 2024-2025




Figura 27: Ganancia acumulada y desempeño por segmento. La mejora se expresa como PR-AUC dividida por la prevalencia del propio segmento, de modo que segmentos con distinta proporción de multifatales resulten comparables; el valor 1 corresponde a no aportar información.

El panel derecho comprueba que esa capacidad no depende de un segmento particular. La mejora sobre la prevalencia se mantiene entre 1.8 y 3.5 veces en todas las particiones examinadas —por zona, por red vial y por año—, de modo que ningún grupo queda por debajo de la línea base. El extremo inferior corresponde a la red vial urbana, con 1.8 veces sobre una prevalencia de 0.034: es el entorno donde el modelo aporta menos, coherentemente con que la multifatalidad urbana sea un fenómeno poco frecuente y menos ligado al contexto vial. El extremo superior es la red departamental, con 3.4 veces. La comparación entre 2024 y 2025 (3.5 y 2.8) sugiere además cierto deterioro en el periodo más reciente, que conviene vigilar en futuras versiones y que es coherente con su carácter preliminar.

10.6. Baselines

La figura 25 compara la MLP con las líneas base clásicas en las tres métricas principales sobre la escala cruda. Las tres barras de cada panel están próximas entre sí, lo que anticipa el resultado del análisis pareado: el liderazgo nominal de la red no equivale a superioridad

estadística.

Las tres líneas base se implementaron con scikit-learn [8] sobre el mismo contrato de variables y la misma política de umbral. El DummyClassifier usa `strategy=prior`: probabilidad constante igual a la prevalencia de entrenamiento, no “clase mayoritaria”. La MLP supera nominalmente a logística y Random Forest en esta referencia. El bootstrap pareado muestra ventaja nominal frente a logística en PR-AUC, ROC-AUC y F1; frente a Random Forest, PR-AUC y ROC-AUC incluyen cero. F1 es la excepción nominal: la diferencia MLP menos Random Forest es +0.0252, con IC 95 % [0.00166, 0.04790], favorable a la MLP. En total se inspeccionan seis comparaciones con IC 95 % nominales, sin ajuste por multiplicidad ni cobertura familiar simultánea. La inferencia es condicional a las predicciones y recetas congeladas; no establece superioridad universal ni incorpora incertidumbre de reentrenamiento.

10.7. Diagnósticos rolling

Los dos outer internos obtienen PR-AUC 0.3459/0.3259, ROC-AUC 0.7961/0.8090 y F1 0.3960/0.3677. La variación entre ventanas confirma que una sola partición no basta y refuerza la necesidad de validación externa.

11. Interfaz gráfica

La interfaz Streamlit [10] es un consumidor de solo lectura. Verifica hashes, ancho 169, orden de variables, esquema y umbrales antes de inferir. El formulario excluye todos los campos PERSONAS y solicita únicamente contexto del registro y agregados VEHICULOS, con advertencia de alcance retrospectivo. La aplicación se organiza en cinco secciones navegables: panorama, inferencia, exploración de datos, patrones regionales y evidencia del modelo.

11.1. Panorama y arquitectura visible

La pantalla inicial (figura 28) declara el alcance del sistema antes de cualquier interacción y expone la arquitectura de la red como una cadena de bloques: 21 campos crudos, 169 características, las dos capas ocultas con su regularización, la calibración Platt externa y la clase estimada. Las tres tarjetas superiores anticipan el tamaño del universo, la prevalencia y la separación lograda, de modo que ninguna métrica aparece sin su referencia.



Figura 28: Sección *Panorama*. La cadena de bloques reproduce la arquitectura canónica del manifiesto; el texto asociado declara 12 993 parámetros y las 9 corridas de la búsqueda, en lugar de presentar el modelo como una caja cerrada.

11.2. Formulario de inferencia

El formulario (figura 29) solicita fecha, hora, ubicación, contexto de vía y agregados VEHICULOS. Las coordenadas son obligatorias y pueden fijarse con un selector cartográfico: el esquema canónico exige ubicación y la aplicación no imputa una localización de forma silenciosa. El pie del bloque de vehículos declara explícitamente por qué PERSONAS está excluida y cuál es el alcance defendible.

Probar la red neuronal

Complete un registro o seleccione uno de los 5 escenarios académicos. La salida es una probabilidad calibrada de multifatalidad y una clase estimada.

Escenario de demostración

TP real 2023 · multifatal correctamente estimado

Cargar escenario

Ubicación

> Elegir la ubicación en el mapa (OpenStreetMap)

Evento y ubicación

Fecha del siniestro	Hora del siniestro	Departamento	Código de vía (opcional)
25/10/2023	02:00	CUSCO	PE-34J

Vía y entorno

Clase de siniestro	Zona	Red vial	Tipo de vía
CHOQUE	RURAL	NACIONAL	CARRETERA
Clima	Característica vial	Perfil longitudinal	Superficie
DESPEJADO	CURVA	PLANA	ASFALTADA

Coordenadas (requeridas)

Latitud	Longitud
-15.142256	-71.122031

Ingrese ambas coordenadas. El esquema canónico exige ubicación para la inferencia final; la app no imputa una localización silenciosamente.

Vehículos registrados

Vehículos involucrados	Buses / minibuses	Pesados de carga	Motos / trimotos / bicis
2	2	0	0
Vehículos no identificados	Servicio interprovincial	Transporte público / taxi	
0	0	2	

Figura 29: Sección *Probar la red* con el escenario TP de 2023 cargado. Los campos reproducen un siniestro real: choque nocturno en carretera nacional rural de Cusco, en curva, con dos vehículos de transporte público involucrados.

11.3. Salida de la red

La decisión visible usa probabilidad Platt y umbral 0.15; la sigmoide cruda y su umbral 0.65 permanecen en un diagnóstico separado y plegado, para que ambas escalas no se confundan. Para el escenario de la figura 30, la red asigna 74.9 % de probabilidad calibrada y estima la clase multifatal, que coincide con lo observado en 2023. El gráfico de contexto sitúa esa estimación junto a las tasas históricas del subgrupo coincidente, la misma clase, la misma zona y el mismo clima, con intervalos Wilson al 95 %: describen tasas agregadas y no se presentan como incertidumbre de la predicción individual.




Figura 30: Resultado de la inferencia. La banda del medidor marca el umbral calibrado; el contexto histórico muestra que la estimación de 74.9 % se aparta de todas las tasas de referencia, que se ubican entre 10 % y 22 %.

Los cinco escenarios corresponden a un verdadero negativo, un falso positivo, un falso negativo limítrofe y un verdadero positivo reales de 2023, más un clon sintético que modifica únicamente `CODIGO_VIA` por un código no observado. Para los cuatro reales la interfaz separa lo observado de lo estimado; el sintético declara que su desenlace no está disponible y muestra la diferencia respecto del caso base, sin lenguaje causal. Al cargar un escenario, la aplicación comprueba que sus campos y su predicción coincidan con los valores registrados y rechaza la carga si difieren, de modo que la demostración no pueda alterarse sin que se advierta.

11.4. Evidencia y límites

La sección de evidencia (figura 31) publica las métricas de la referencia histórica con sus intervalos bootstrap y encabeza el bloque con la advertencia de que 2024–2025 ya fue consultado. Debajo reproduce la auditoría de diseño: la ablación de regularización y la comparación entre una y varias redes, con las barras de error que sostienen la decisión de conservar una sola MLP.




Figura 31: Sección *Evidencia del modelo*. Cada métrica aparece con su intervalo de confianza y la prevalencia se declara junto a PR-AUC, de modo que la cifra no pueda leerse contra 0.50 por descuido.

Gráficos y tablas incluyen texto además de color y alternativas descargables. La interfaz conserva navegación por teclado, foco visible, movimiento reducido y diseño responsivo; AppTest recorre la aplicación sin reentrenar ni escribir artefactos.

12. Discusión

La decisión metodológica central condiciona la interpretación del proyecto. PERSONAS no es una familia de variables predictoras legítima sino una fuente estructuralmente contaminada: el conteo de fallecidos por persona reproduce el target. Excluirlo reduce las métricas frente a un modelo que la incluyera, pero aumenta de forma decisiva la validez del experimento. Un resultado menor y honesto es científicamente superior a un resultado alto producido por un proxy del desenlace.

La MLP conserva señal por encima de la prevalencia: PR-AUC 0.325 frente a 0.099, es decir, una mejora de 3.3 veces sobre la línea base, y ROC-AUC 0.792. Sin embargo, 380 FP y 72 FN en la escala calibrada impiden describir el modelo como excelente. La calibración es buena en Brier/ECE, pero no resuelve límites de ranking.

12.1. Por qué la red no supera a los métodos clásicos

El hallazgo que más condiciona la interpretación del trabajo es que la red iguala al bosque aleatorio en lugar de superarlo. Conviene explicarlo, porque admite cuatro hipótesis y el proyecto puede descartar tres por medición directa.

La hipótesis más inmediata es que la red se quedó corta de capacidad. La auditoría de la sección 9.4 la refuta con nueve arquitecturas de una a tres capas ocultas y de 32 a 384 neuronas: el rango completo entre la mejor y la peor es 0.0179, prácticamente igual a la dispersión entre semillas de una sola configuración, que es 0.0162. Ni más neuronas ni más capas producen una mejora distinguible del ruido, y la red de 76 545 parámetros rinde por debajo de una única capa de 64. Tampoco falta entrenamiento: al extender el reajuste, la PR-AUC de entrenamiento llega a 0.727 mientras la de validación cae a 0.3054, la forma clásica de la memorización.

La segunda hipótesis es la representación. El contrato canónico es mayoritariamente disperso, y ese es precisamente el régimen donde los ensambles de árboles son más competitivos, ya que particionan sobre indicadores binarios de forma nativa. La auditoría de la sección 9.6 la puso a prueba con *embeddings* de entidad bajo protocolo idéntico y no encontró mejora: los tres intervalos pareados incluyen el cero y el signo de la diferencia se invierte entre las particiones de 2022 y 2023. La representación, por tanto, no es el factor limitante.

La tercera hipótesis es que el contrato desaprovechaba información ya disponible. La auditoría de la sección 9.7 incorporó diez agregados previos al impacto del libro VEHICULOS —elemento transportado, ámbito del servicio y situación reglamentaria de seguro, revisión técnica y habilitación— tras verificar que ninguno reproduce el desenlace. El contrato enriquecido no mejora: la PR-AUC cae 0.0252 y las demás métricas quedan indistinguibles. La señal de ocupación que esas variables prometían ya estaba contenida en los conteos de buses y servicio interprovincial.

Queda la cuarta hipótesis, y es la que el conjunto de la evidencia respalda por descarte: **el límite está en los datos y no en el modelo**. Conviene, sin embargo, precisar en qué sentido, porque la curva de aprendizaje de la sección 9.5 obliga a separar dos limitaciones distintas.

La primera es de *variables*. Los determinantes físicos de que un siniestro deje dos o más fallecidos —la ocupación real de los vehículos, la velocidad de impacto y la relación de masas— no están registrados en la fuente. El modelo solo puede aproximar la ocupación mediante los agregados de VEHICULOS, y es precisamente esa familia la que concentra el 21.6 % de la importancia global con apenas siete columnas. La red encuentra la señal disponible y la aprovecha bien; lo que no puede hacer es reconstruir una variable que nadie midió.

La segunda es de *tamaño de muestra*, y es la que impide dar por agotado el problema. La curva frente al número de registros sigue creciendo en su extremo derecho: el último cuarto de los datos aporta todavía 0.0140 de PR-AUC. El modelo no ha consumido la información de las variables que ya tiene; simplemente no dispone de observaciones suficientes para extraerla por completo. Con 510 casos positivos en la partición de ajuste y unos 25 parámetros por caso positivo, ese resultado es esperable.

Ambas limitaciones apuntan en la misma dirección práctica pero con horizontes distintos. Incorporar variables de impacto exigiría una fuente que hoy no existe como dato abierto; acumular registros solo exige esperar, porque la fuente publica un periodo nuevo cada año. Bajo esta lectura, una PR-AUC de 0.325 sobre una prevalencia de 0.099 —una mejora de 3.3 veces— no es un resultado mediocre ni un techo definitivo: es lo alcanzable

con variables de contexto, sin variables de impacto y con cinco años de registro.

VEHICULOS también carece de timestamps por campo. No se detectó identidad directa con el target, pero su disponibilidad operativa no está demostrada; el alcance se restringe a clasificación histórica retrospectiva. La explicación SHAP es global y estable entre muestras, pero sigue siendo asociativa.

Los IC bootstrap son estrechos solo respecto a remuestreo de filas congeladas. No representan selección, dependencia, referencia reutilizada ni futuro. Los folds rolling internos mejoran la evaluación, pero comparten historia y no sustituyen una cohorte externa/prospectiva. La siguiente evidencia confirmatoria debe definirse antes de abrir nuevas etiquetas.

13. Conclusiones

- Se construyó una única MLP 169–64–32–1 con 12 993 parámetros y técnicas de regularización realmente ejecutadas.
- La arquitectura se seleccionó con 2021/2022, se reajustó en 2021–2022 y se calibró en 2023; dos folds rolling verifican roles cronológicos disjuntos dentro de cada diagnóstico.
- La prueba ejecutable confirmó que PERSONAS reconstruye el objetivo para los 9 104 registros; excluir esa fuente completa era la única decisión defendible.
- En la referencia 2024–2025 ya consultada, PR-AUC es 0.3254 sobre una prevalencia de 0.099 —una mejora de 3.3 veces—, ROC-AUC 0.7916 y F1 calibrado 0.3989. El desempeño es moderado y se reporta sin sobreestimación.
- Un barrido de nueve arquitecturas, de una a tres capas ocultas y de 32 a 384 neuronas, mostró que el rango completo de desempeño (0.0179) es equiparable a la dispersión entre semillas de una sola configuración (0.0162): ni más neuronas ni más capas mejoran el resultado. Extender el reajuste lleva la PR-AUC de entrenamiento a 0.727 y la de validación a 0.3054, es decir, memorización.
- Una auditoría de representación con *embeddings* de entidad alcanzó discriminación equivalente con 54 entradas y 6 042 parámetros frente a 169 y 12 993, y un contrato enriquecido con diez agregados adicionales de VEHICULOS no mejoró. Ni la codificación ni la información desaprovechada del registro son el factor limitante.
- La curva de aprendizaje frente al tamaño de muestra no se ha estabilizado: el último cuarto de los registros aporta todavía 0.0140 de PR-AUC. El modelo está limitado por el número de observaciones además de por el conjunto de variables, de modo que acumular periodos es la vía de mejora más segura.
- La interfaz muestra cinco roles pedagógicos, separa verdad observada de estimación, valida paridad y no ofrece intervalos individuales inexistentes.

El modelo obtenido es reproducible a partir de las fuentes oficiales verificadas. No constituye una validación confirmatoria externa: el proyecto no dispone de una cohorte prospectiva o externa intacta. Esa distinción entre disponer de un modelo terminado y disponer de independencia científica es una conclusión del trabajo, no una nota al pie.

14. Trabajo futuro

Las líneas siguientes se derivan de limitaciones medidas en este trabajo, no de una lista genérica de mejoras posibles. Se ordenan por el valor esperado de la evidencia que producirían.

14.1. Acumular periodos antes que cambiar el modelo

Es la línea con mejor relación entre retorno y riesgo, y se apoya en la curva de la sección 9.5: el desempeño sigue creciendo con el número de registros y no se ha estabilizado. Como la fuente publica un periodo nuevo cada año, repetir el protocolo cuando el registro alcance siete u ocho años de cobertura debería mejorar el resultado sin modificar la arquitectura, sin incorporar fuentes externas y sin introducir ninguna decisión de selección adicional. Conviene fijar de antemano que esa repetición conserve el mismo desplazamiento de particiones, para que la comparación entre versiones siga siendo legítima.

14.2. Cohorte prospectiva o externa

Es la única vía que convierte el artefacto en evidencia confirmatoria. El proyecto carece de una partición intacta: la referencia 2024–2025 ya fue consultada y los diagnósticos rolling comparten historia. La verificación correcta consiste en congelar el paquete actual, esperar el cierre de un periodo posterior y evaluarlo una sola vez, con las reglas y umbrales fijados de antemano. Cualquier conclusión sobre superioridad frente a métodos clásicos debe posponerse hasta ese momento.

14.3. Ampliar el conjunto de variables antes que la arquitectura

La sección 12 muestra que el límite no está en la representación ni en la capacidad, sino en la información disponible. Las variables que determinan físicamente el número de víctimas —ocupación de los vehículos, velocidad de impacto y relación de masas— no figuran en la fuente, y la sección 9.7 confirma que tampoco pueden recuperarse de los campos no utilizados del propio registro.

Se revisó qué fuentes oficiales peruanas podrían aportarlas. El catálogo del ONSV publica únicamente los tres registros ya empleados más un histórico agregado por año, de modo que no existe información adicional por siniestro en el origen. Fuera del ONSV, las candidatas con datos tabulares descargables son el inventario de la Red Vial Nacional del MTC y los servicios geográficos de Provías Nacional, que aportan índice medio diario de tránsito, número de carriles, superficie, estado de conservación y geometría de la vía; los conteos de flujo vehicular en unidades de peaje del MTC; y los registros individuales de exceso de velocidad detectados por cinemómetros de SUTRAN.

Ese enriquecimiento, sin embargo, está sujeto a tres restricciones que deben resolverse antes de intentarlo y que condicionan su valor esperado.

1. **Cobertura espacial parcial.** El inventario vial nacional solo alcanza a los siniestros ocurridos en la Red Vial Nacional, que son el 55.1 % de los registros; el 22.5 % urbano, el 10.4 % provincial y el 8.4 % departamental quedarían sin valor. Además, esa ausencia no es aleatoria: coincide exactamente con la variable `RED_VIAL`, que el contrato ya contiene.

2. **Cobertura temporal incompleta.** Los registros de cinemómetros disponibles como dato abierto llegan hasta 2022. Una variable presente en el periodo de ajuste y ausente en las particiones de calibración y de referencia no es utilizable: el modelo aprendería a depender de ella y se enfrentaría después a su ausencia sistemática. Su incorporación exigiría, como mínimo, cobertura homogénea en todo el periodo 2021–2025.
3. **Disponibilidad en inferencia.** La interfaz estima la clase de un registro introducido por el usuario. Cualquier variable externa debe poder resolverse en ese momento a partir de los campos del formulario; los agregados mensuales de flujo vehicular no cumplen esa condición para una fecha futura.

Bajo esas restricciones, el subconjunto defendible es el de atributos estructurales de la vía —carriles, ancho de calzada, topografía, clase de superficie y curvatura derivada de la geometría— que varían lentamente y pueden resolverse en inferencia mediante una tabla de consulta por código de ruta y coordenadas. Cualquier fuente nueva debe incorporarse al manifiesto sellado por hash y superar la auditoría de fuga que descartó PERSONAS antes de entrar al contrato.

14.4. Reducir la capacidad del artefacto entregado

La auditoría de representación alcanzó desempeño equivalente con 6 042 parámetros y 54 dimensiones de entrada. Una versión posterior del paquete debería partir de esa evidencia: depurar las 18 columnas que nunca se activan en el ajuste, agrupar en una categoría común las que reúnen menos de 30 registros y redimensionar el modelo. El objetivo no es mejorar la métrica, que no mejoraría, sino entregar un artefacto cuya capacidad se corresponda con la información que lo sustenta.

14.5. Revisar el papel de la regularización

La ablación indica que L2 y *dropout* desplazan la métrica menos que el ruido entre semillas, y que el control efectivo del ajuste proviene del número fijo de épocas. Un trabajo posterior debería o bien explorar intensidades de regularización que produzcan un efecto medible, o bien declarar explícitamente el presupuesto de épocas como mecanismo de control y retirar los componentes inertes.

14.6. Comparación con equivalencia declarada

Las comparaciones frente a las líneas base se presentaron como intervalos de diferencia sin ajuste por multiplicidad. Un diseño posterior debería fijar de antemano un margen de equivalencia práctica y contrastar formalmente equivalencia en lugar de superioridad, que es la hipótesis que los datos realmente sostienen.

15. Anexos

15.1. Repositorio y estructura del proyecto

El código fuente completo, los datos, el modelo y este informe están versionados en el repositorio público https://github.com/ForLess01/Accident_NN. El cuaderno

`notebooks/modelo.ipynb` documenta el proyecto de forma ejecutable y es compatible con Google Colab.

```
Accident_NN/
|-- app/                Interfaz Streamlit (solo lectura del bundle)
|-- data/
|   |-- raw/            Libros oficiales ONSV + manifiesto SHA-256
|   |-- processed/      base_limpia.parquet y casos de demostracion
|   '-- geo/            GeoJSON de departamentos del Peru
|-- docs/               Procedencia y disponibilidad de los datos
|-- models/final/       Bundle canonico: modelo, encoders, calibrador
|-- notebooks/          modelo.ipynb (cuaderno academico integral)
|-- report/             Informe LaTeX, figuras, tablas y PDF final
|-- scripts/            Construccion del informe y verificacion final
|-- src/                Pipeline: auditoria, EDA, entrenamiento
'-- tests/              Suite de regresion (pytest)
```

15.2. Configuración canónica

```
1 canonical = {
2     "version": "canonical-3.0.0",
3     "raw_fields": 21,
4     "features": 169,
5     "hidden_units": [64, 32],
6     "dropout": 0.35,
7     "l2": 3e-4,
8     "learning_rate": 5e-4,
9     "batch_size": 64,
10    "seed": 42,
11    "fixed_refit_epochs": 14,
12    "parameters": 12993,
13    "raw_threshold": 0.65,
14    "calibrated_threshold": 0.15,
15    "calibration": "platt"
16 }
```

15.3. Artefactos de evidencia

- Procedencia: `data/raw/source_manifest.json` y `docs/data_provenance.md`.
- Proxy: `report/tables/personas_target_proxy_identity.json`.
- Curvas/brecha: `report/tables/model_learning_curves.csv`;
`report/tables/model_generalization_gap.json`.
- Folds rolling: `report/tables/temporal_nested_fold_roles.csv`;
`report/tables/temporal_nested_outer_metrics.csv`.
- Estabilidad SHAP: `report/tables/final_explainability_stability.csv`.
- Escenarios de demostración: `data/processed/demo_cases.csv`.
- Auditoría de capacidad:
`report/tables/design_capacity_architecture_summary.csv`;
`report/tables/design_capacity_sample_curve.csv`.

Referencias

- [1] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems. *arXiv preprint arXiv:1603.04467*, 2016. Acceso libre: <https://arxiv.org/abs/1603.04467>.
- [2] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002. Acceso libre: <https://www.jair.org/index.php/jair/article/view/10302>.
- [3] François Chollet et al. Keras. Documentación oficial, 2015. <https://keras.io/>.
- [4] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. Acceso libre: <https://www.deeplearningbook.org/>.
- [5] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014. Acceso libre: <https://arxiv.org/abs/1412.6980>.
- [6] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017. Acceso libre: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.
- [7] Observatorio Nacional de Seguridad Vial (ONSV), Ministerio de Transportes y Comunicaciones del Perú. Siniestros de tránsito fatales 2021–2025 (preliminar): detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional. Catálogo de datos abiertos, 2026. Publicado el 2026-02-27; enlace verificado el 2026-07-27. <https://www.onsv.gob.pe/datosabiertos>.
- [8] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. Acceso libre: <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [9] Lutz Prechelt. Early stopping—but when? In *Neural Networks: Tricks of the Trade*, pages 55–69. Springer, 1998. Acceso libre: https://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf.
- [10] Snowflake Inc. Streamlit: A faster way to build and share data apps. Documentación oficial, 2024. <https://streamlit.io/>.
- [11] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014. Acceso libre: <https://jmlr.org/papers/v15/srivastava14a.html>.
- [12] World Health Organization. Road traffic injuries. Fact sheet, 2023. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>.