

Clasificación de alta letalidad en siniestros viales fatales del Perú

Red neuronal para clasificación retrospectiva de multifatalidad (ONSV 2021–2025)

Rendo Alfonte Tarqui
Yimmy Yeyson Cuyo Zamata

Curso: Redes Neuronales — Segunda Unidad

2026

Resumen

Se desarrolló una única red neuronal para clasificar retrospectivamente siniestros viales ya fatales del Perú según hayan registrado un fallecido o dos o más. La fuente oficial ONSV 2021–2025 contiene 9 104 registros útiles y prevalencia multifatal de 10.19 %. Una auditoría estructural demostró que la tabla PERSONAS reconstruye el objetivo en 9 104 de 9 104 registros; por ello toda característica derivada de PERSONAS fue eliminada. Solo se conservaron agregados de VEHICULOS bajo alcance histórico retrospectivo.

El contrato final transforma 21 campos crudos en 169 características. La MLP es $169 \rightarrow 64 \rightarrow 32 \rightarrow 1$, con ReLU, *dropout* 0.35, L2 de 3×10^{-4} y 12 993 parámetros. La arquitectura se seleccionó con ajuste 2021 y selección 2022; el modelo se reajustó en 2021–2022 durante 14 épocas fijas; Platt y los umbrales se determinaron en 2023.

La referencia 2024–2025 ya había sido consultada y solo se usa de forma descriptiva. Allí, la escala calibrada obtuvo PR-AUC 0.3254 [IC 95 %: 0.2703–0.3871], ROC-AUC 0.7916 [0.7595–0.8227], F1 0.3989 [0.3523–0.4423], Brier 0.0777 y ECE 0.0133. Son resultados moderados, no una validación externa. El proyecto añade folds rolling internos, curvas de aprendizaje comparables, estabilidad SHAP, fuentes selladas por hash y cinco demostraciones pedagógicas. El artefacto es reproducible y está sellado por contenido, pero no existe una cohorte externa o prospectiva intacta.

1. Introducción

La siniestralidad vial constituye un problema de salud pública en el Perú y en el mundo [12]. Dentro de los siniestros con desenlace fatal existe una distinción operativa relevante: la mayoría deja un solo fallecido, pero una fracción (los siniestros *multifatales*) concentra dos, cinco o hasta decenas de víctimas en un solo evento, típicamente asociados a transporte interprovincial, vías rurales y condiciones adversas. El Observatorio Nacional de Seguridad Vial (ONSV) del Ministerio de Transportes y Comunicaciones publica

una base a nivel de registro de los siniestros fatales del país [7], con variables de contexto como zona rural/urbana, red vial, condición climática, característica de la vía, perfil longitudinal, superficie de calzada y coordenadas geográficas.

La pregunta de investigación que guía este trabajo es: *dado que ocurre un siniestro fatal, ¿qué condiciones del entorno y del evento se asocian a que sea de alta letalidad (dos o más fallecidos), y puede una red neuronal clasificarlas?* La consigna del curso pide una red neuronal para predicción o clasificación con un dataset de la región o a nivel nacional, acompañada de análisis exploratorio, preprocesamiento, ingeniería de características, una interfaz gráfica y un informe. En rigor técnico, el problema abordado es de **clasificación binaria** multifatal/letalidad-simple: la salida es una categoría discreta, y al clasificarla el modelo también produce una probabilidad de siniestro multifatal, lo que cubre ambos términos de la consigna con precisión.

Este encuadre condicional (*dentro* de los siniestros fatales) es una decisión metodológica deliberada: la base ONSV registra únicamente siniestros con al menos un fallecido, por lo que no existe clase negativa “no fatal”. En lugar de mezclar fuentes con criterios de registro distintos —lo que introduciría sesgo de selección—, se reformuló el problema hacia la pregunta que esta base sí puede responder con rigor. La hipótesis subyacente es que las variables pre-impacto disponibles (mecánica del siniestro, ruralidad, clima, geometría de la vía, momento del día) contienen señal suficiente para que una red neuronal supere a una línea base trivial y compita con métodos clásicos.

2. Objetivos

2.1. Objetivo general

Desarrollar una red neuronal de clasificación binaria de alta letalidad en siniestros viales fatales del Perú, con pipeline completo (análisis exploratorio → preprocesamiento → ingeniería de características → entrenamiento → evaluación → interfaz gráfica), reproducible y documentado.

2.2. Objetivos específicos

- **OE1.** Caracterizar la siniestralidad fatal nacional mediante análisis exploratorio de datos, con al menos ocho hallazgos interpretados.
- **OE2.** Construir al menos doce características derivadas de las variables pre-impacto del registro, cada una justificada.
- **OE3.** Entrenar un perceptrón multicapa (MLP) y compararlo contra tres líneas base: `DummyClassifier(strategy=prior)`, regresión logística y *random forest*. Si la MLP no supera a un método clásico, se reporta y discute honestamente.
- **OE4.** Identificar familias de variables asociadas al score mediante Gradient SHAP y comprobar la estabilidad de sus bandas de importancia.
- **OE5.** Desplegar una interfaz gráfica en Streamlit que consuma exactamente el bundle de inferencia canónico, con verificación de hashes y paridad.

2.3. Métricas comprometidas antes de entrenar

El dataset es desbalanceado: la clase multifatal es minoritaria (10.2 %). Por ello las métricas y las reglas de decisión se fijaron antes de entrenar:

- Selección de configuración completa: **mayor mediana de PR-AUC en selección 2022 entre semillas**; desempates por mayor F1 mediana y, después, menor IQR de PR-AUC. Cada configuración combina capas, dropout, L2 y tasa de aprendizaje.
- Métricas de reporte obligatorio: *precision* y *recall* de la clase multifatal, PR-AUC, ROC-AUC, matriz de confusión completa y *accuracy* solo como referencia.
- Se prohíbe argumentar calidad con *accuracy* aislada: un modelo que responde siempre “letalidad simple” alcanza *accuracy* alta y es inútil.
- Selección de umbral: máximo F1 en validación, con desempates predeclarados por *recall*, precisión y mayor umbral; no se ajusta después de observar 2024–2025.

3. Marco teórico

3.1. Clasificación binaria desbalanceada

La red estima un score $\hat{p} = \sigma(z)$ para la clase multifatal. La BCE guía el ajuste y los pesos de clase evitan que la clase positiva, cercana al 10 %, quede ignorada. PR-AUC es la métrica principal de ranking porque debe leerse contra la prevalencia; ROC-AUC se conserva como medida complementaria. F1, precisión y recall dependen del umbral.

3.2. Red neuronal multicapa

Cada capa Dense calcula $h = \text{ReLU}(Wx+b)$ y la salida aplica sigmoide [4]. Backpropagation obtiene gradientes de BCE más L2, y Adam actualiza pesos [5]. Dropout desactiva aleatoriamente unidades solo durante entrenamiento [11]. Early stopping y reducción de tasa controlan la trayectoria durante selección; no agregan capas ni parámetros [9].




Figura 1: Arquitectura canónica derivada del manifiesto final. Dropout opera solo durante entrenamiento.

3.3. Calibración y decisión

Platt aprende una regresión logística sobre el logit del score crudo. La calibración puede reducir Brier y ECE, pero una transformación monótona no mejora PR-AUC o ROC-AUC. El umbral crudo 0.65 y el calibrado 0.15 pertenecen a escalas distintas.

3.4. Regularización y complejidad

L2 penaliza magnitud de pesos; dropout reduce coadaptación; pesos de clase modifican el costo del desbalance; early stopping limita épocas; ReduceLROnPlateau refina el descenso. No son sinónimos ni una lista decorativa. La auditoría compara L2/dropout y alternativas de una o varias redes; solo se conservan técnicas ejecutadas y justificadas.

3.5. Explicabilidad e incertidumbre

Gradient SHAP describe cómo el modelo congelado distribuye su score respecto de un fondo [6]. Es asociación, no causalidad. La estabilidad se comprueba en tres muestras deterministas y se reporta por bandas. Los intervalos bootstrap de métricas son condicionales a predicciones congeladas y no constituyen intervalos individuales.

4. Metodología

4.1. Protocolo temporal

La arquitectura se seleccionó sin utilizar 2023 ni la referencia: fit 2021 y selección 2022. El número de épocas de la corrida seleccionada se fijó en 14; luego se reajustó una sola MLP con todo 2021–2022. En 2023 se compararon calibradores mediante predicciones OOF, se ajustó Platt y se fijaron los umbrales. Los 2 232 registros 2024–2025 se conservan como referencia histórica ya consultada.

Tabla 1: Roles cronológicos del artefacto final.

Periodo	n	Positivos	Rol
2021–2022	4 872	510	Reajuste final tras selección interna 2021/2022
2023	2 000	196	Calibración OOF y umbrales
2024–2025	2 232	222	Referencia histórica; sin ajustes

4.2. Diagnóstico rolling anidado

Se ejecutaron dos folds usando exclusivamente fechas anteriores a 2024. En cada fold, fit, selección, calibración y ventana outer son cronológicos y no se solapan. El primer outer corresponde a julio–diciembre de 2022 y el segundo a 2023. Los resultados son diagnósticos de variabilidad, no un test externo; los folds comparten historia y solo existen dos ventanas viables.

4.3. Técnicas aplicadas

La búsqueda cerrada comparó tres configuraciones por tres semillas. El paquete final usa BCE, pesos de clase, Adam, L2, *dropout*, *early stopping* y *ReduceLROnPlateau* durante selección. La calibración Platt corrige escala; no cambia ranking. No se aplicaron L1, SMOTE [2], *stacking* ni *batch normalization*, porque añadirlos sin evidencia y sin una cohorte nueva aumentaría multiplicidad.

4.4. Incertidumbre

Los IC bootstrap son percentiles por remuestreo de filas con pipeline y predicciones congeladas, sin reajuste. No incluyen incertidumbre de entrenamiento o selección, dependencia temporal/espacial, consulta repetida de la referencia, generalización externa/futura ni incertidumbre individual.

5. Dataset

La fuente es el catálogo oficial ONSV <https://www.onsv.gob.pe/datosabiertos>. Los archivos SINIESTROS, VEHICULOS, PERSONAS y el diccionario se declaran en `data/raw/source_manifest.json` con URL, tamaño, hojas y SHA-256. El pipeline verifica el conjunto exacto antes de leer; una fuente modificada, faltante o adicional detiene la ejecución. Los datos 2024–2025 son preliminares.

5.1. Objetivo

El universo contiene solo siniestros fatales. Por tanto, $y = 1$ cuando `FALLECIDOS` ≥ 2 y $y = 0$ cuando `FALLECIDOS` = 1. El modelo no estima la probabilidad de que cualquier accidente sea fatal.

5.2. Prueba de fuga PERSONAS

La auditoría por código comparó SINIESTROS con PERSONAS. El conteo `GRAVEDAD` = `FALLECIDO` coincide con `FALLECIDOS` y reconstruye el target en los 9 104 registros; además, el número de filas PERSONAS cubre necesariamente a los fallecidos. Excluir solamente `GRAVEDAD` era insuficiente. La decisión final excluye toda la fuente PERSONAS de los predictores; solo permanece como prueba de linaje.

5.3. Disponibilidad

Se conservan siete agregados VEHICULOS: total, buses, carga pesada, motos, no identificados, servicio interprovincial y transporte público. Los libros no incluyen timestamps por campo. Por ello su uso solo se defiende para clasificación histórica retrospectiva de registros consolidados, no para tiempo real o instante de notificación.

6. Análisis exploratorio de datos

Se ejecutó el análisis exploratorio sobre `base_limpia.parquet`: cada figura se guardó numerada en `report/figures/` (150 dpi, títulos y ejes en español) y cada figura tiene 2–4 líneas de interpretación escrita. Se generaron 14 figuras y un conjunto de hallazgos numerados H1–H11 que alimentaron las decisiones de ingeniería de características.

6.1. Distribución del objetivo y desbalance




Figura 2: Distribución del target. La clase multifatal (2+ fallecidos) representa el 10.2 % de los siniestros fatales, lo que confirma el desbalance y justifica evaluar con F1, *recall* y PR-AUC, no con *accuracy* aislada. (Hallazgo H1.)

6.2. Patrones temporales




Figura 3: Serie mensual de siniestros fatales. El mes con más registros fue junio 2021 con 229 (H2); la caída hacia 2024–2025 refleja en parte el carácter preliminar del cierre de registro.



Figura 4: Siniestros fatales por hora. La hora con más registros fue 19:00 con 667 (H3).



Figura 5: Tasa multifatal por hora. La mayor tasa (16.3 %) aparece a las 14:00 (H3): volumen y letalidad no son lo mismo.




Figura 6: Sinistros fatales y tasa multifatal por día de semana. Cantidad y letalidad deben leerse juntas (H4). Esto respalda incluir `dia_semana` y `fin_de_semana` como señales distintas.

6.3. Clase de siniestro



Figura 7: Cantidad de siniestros fatales por clase. La más frecuente fue CHOQUE con 3 260 casos (H5).



Figura 8: Tasa multifatal por clase. DESPISTE presenta 17.7 % (H5): los despistes —típicos de buses y camiones en vías rurales— concentran los eventos con múltiples víctimas.

6.4. Análisis territorial




Figura 9: Top-15 departamentos por número de siniestros fatales. LIMA concentra 1 917 (H6).



Figura 10: Top-15 departamentos por tasa multifatal. HUANCAVELICA lidera con 28.0 % entre departamentos con al menos 30 casos (H6). El ranking por volumen no equivale al ranking por letalidad.

6.5. Vías y condiciones pre-impacto




Figura 11: Top-15 códigos de carretera por siniestros fatales. La vía PE-1N encabeza con 1 032 casos (H7).




Figura 12: Tasa multifatal por zona, clima, característica y superficie de vía (H8). Estas variables aportan contexto inicial relevante para el modelo.

El hallazgo H8 es el más importante del análisis: la zona rural presenta una tasa multifatal de 15.1 % frente a 3.6 % en zona urbana (4.2 veces mayor), y el clima lluvioso 17.6 % frente a 9.8 % en despejado. Ambas separaciones anticipan que la red dispone de señal estructural real.

6.6. Patrones combinados, calidad de datos y geografía




Figura 13: Mapa de calor mes $\times$ hora. Los patrones combinados (H9) prueban que no basta con fecha u hora cruda: se requieren derivadas cíclicas y de franja.




Figura 14: Porcentaje de faltantes por columna. Las señales viales alcanzan 77.9 % (H10) y por eso se excluyen del modelo; el resto admite imputación simple con *flags*.




Figura 15: Ubicación de los siniestros fatales 2021–2025 (H11). Los eventos siguen los corredores viales del país; los multifatales (rojo) aparecen en todas las regiones. Las coordenadas entran al modelo como variables continuas estandarizadas.

6.7. Hallazgos H1–H11

Se redactaron once hallazgos en prosa, cada uno con referencia a su figura. Los más relevantes para el modelado:

- **H1:** la clase multifatal representa 10.2 % de los siniestros fatales (figura 2), confirma desbalance y justifica las métricas.
- **H3:** la hora con más siniestros (19:00) no coincide con la de mayor tasa multifatal (14:00, 16.3 %) (figuras 4 y 5).
- **H5:** CHOQUE es la clase más frecuente, pero DESPISTE tiene la mayor tasa multifatal (17.7 %) (figuras 7 y 8).
- **H6:** LIMA concentra la mayor cantidad de siniestros fatales, pero HUANCABELICA lidera la tasa multifatal con 28.0 % (figuras 9 y 10).
- **H8:** zona rural 15.1 % vs. urbana 3.6 %; lluvia 17.6 % vs. despejado 9.8 % (figura 12). Las condiciones pre-impacto separan el riesgo.
- **H11:** el scatter geográfico (figura 15) visualiza la red vial implícita y justifica las coordenadas como señal espacial continua.

7. Preprocesamiento

El preprocesamiento se ajusta únicamente en la partición de fit correspondiente. Normaliza categorías, crea una categoría DESCONOCIDO, asigna frecuencia cero a códigos de vía no vistos, estandariza continuas y genera codificación *one-hot*. Mes, día semanal y hora se representan cíclicamente. Se incluyen interacciones predeclaradas de contexto vial.

El contrato persistido contiene 21 campos crudos y 169 columnas `float32` en orden fijo. Se excluyen fallecidos, lesionados, vehículos dañados, causas investigadas, identificadores y toda característica PERSONAS. El esquema, escalador, encoders, modelo, calibrador y umbrales se verifican por hash antes de inferencia.

La curva de aprendizaje compara PR-AUC no ponderada de fit 2021 y selección 2022; no enfrenta pérdida ponderada con pérdida no ponderada. Para el modelo reajustado, PR-AUC de entrenamiento es 0.4332 y de 2023 es 0.3367; la brecha es 0.0965. El Brier aumenta solo 0.0036 entre entrenamiento y 2023, evidencia que debe leerse junto al deterioro de ranking.

8. Ingeniería de características

Las 169 características pertenecen a seis familias: tiempo cíclico; geografía; código, red y tipo de vía; clase y condiciones registradas; siete agregados VEHICULOS; e interacciones predeclaradas como `noche×rural`, `lluvia×curva`, `tipo×zona` y `red×clase`.

Tabla 2: Decisiones de disponibilidad.

Familia	Evidencia temporal	Decisión
SINIESTROS/ contexto	Sin timestamp por campo	Usar solo con alcance retrospectivo
VEHICULOS	Registro consolidado, sin timestamp	Incluir siete agregados con alcance restrin- gido
PERSONAS	Cardinalidad y falle- cidos reconstruyen el target	Excluir toda la fuente de predictores
Resultados/ causas	Posteriores o directos	Excluir

No se inventaron variables externas. Un código de vía no observado conserva su pre-
fijo si es válido y recibe frecuencia cero; la demo sintética verifica esta sensibilidad sin
atribución causal.

9. Modelo neuronal

9.1. Arquitectura exacta

La única red canónica es:

$$169 \rightarrow \text{Dense}(64, \text{ReLU}) \rightarrow \text{Dropout}(0.35) \\ \rightarrow \text{Dense}(32, \text{ReLU}) \rightarrow \text{Dropout}(0.35) \rightarrow \text{Dense}(1, \sigma).$$

Tiene dos capas ocultas, tres capas Dense entrenables y 12 993 parámetros: $(169 + 1)64 + (64 + 1)32 + (32 + 1)1$.

La configuración MLP_64_32, semilla 42, usa L2 3×10^{-4} , Adam con tasa 5×10^{-4} y lote 64. La implementación reproducible usa TensorFlow/Keras [1, 3]. La arquitectura se elige por mediana PR-AUC entre tres semillas en la selección 2022; la corrida mediana determina 14 épocas para el reajuste 2021–2022. El umbral crudo 0.65 y el calibrado 0.15 se validan y fijan en 2023.




Figura 16: PR-AUC por configuración completa y semilla durante la selección. La regla usa la mediana; la dispersión impide elegir por una corrida afortunada.

9.2. Entrenamiento y generalización

La figura 17 documenta el entrenamiento de la corrida seleccionada. Ambas series usan PR-AUC no ponderada, de modo que son directamente comparables; la curva de 2021 se calcula con *dropout* activo, mientras que la de 2022 se evalúa en modo inferencia, lo que explica que la serie de ajuste quede por debajo durante las primeras épocas. La época 14 es el máximo de PR-AUC en la partición de comparación y fija la duración del reajuste posterior en 2021–2022, sin *callbacks* de validación.




Figura 17: Curvas de aprendizaje de la corrida seleccionada. La meseta de la serie de comparación a partir de la época 12 indica que épocas adicionales no aportan capacidad de generalización: el criterio de parada no se eligió a posteriori.

Para el modelo reajustado, la PR-AUC de entrenamiento es 0.4332 y la de la partición 2023 es 0.3367, con una brecha de 0.0965. El Brier aumenta solo 0.0036 entre ambas particiones: la red no está severamente sobreajustada, pero pierde capacidad de ordenamiento fuera del periodo de ajuste.

9.3. Una red, no dos

La auditoría comparó una MLP congelada, un promedio de tres semillas y una multirrama contexto/VEHICULOS. Los IC pareados del ensemble frente a la red única incluyen cero en todas las métricas reportadas. Sin evidencia concluyente y sin una nueva cohorte, una segunda red agregaría complejidad y otra decisión de selección. Se conserva una sola MLP.




Figura 18: Auditoría 2023 de regularización y número de redes. El eje derecho muestra diferencias pareadas del ensemble respecto de la red única; los intervalos incluyen cero.

9.4. Explicabilidad estable

Gradient SHAP usa fondo 2021–2022 y ejemplos 2023, sin etiquetas ni filas 2024–2025. Tres muestras/semillas deterministas producen correlación de rangos Spearman mínima 0.9897. Se reportan bandas de estabilidad; el orden exacto dentro de una banda no se interpreta como estable ni causal.




Figura 19: Importancia global agrupada mediante Gradient SHAP. La magnitud resume asociación con el score congelado; el color no representa un efecto causal.

10. Resultados

10.1. Referencia histórica ya consultada

Los 2 232 registros de 2024–2025 contienen 222 multifatales. Este periodo no es un test nuevo: ya fue consultado y no autoriza reajustes. La finalidad del bundle no crea independencia científica.

Tabla 3: Métricas del modelo canónico en la referencia histórica.

Métrica	Cruda, $t = 0.65$	Platt, $t = 0.15$
PR-AUC	0.3254 [0.2703, 0.3871]	0.3254 [0.2703, 0.3871]
ROC-AUC	0.7916 [0.7595, 0.8227]	0.7916 [0.7595, 0.8227]
F1	0.4030 [0.3496, 0.4487]	0.3989 [0.3523, 0.4423]
Precisión	0.3025	0.2830
Recall	0.6036	0.6757
Brier	0.1642	0.0777
ECE	0.2338	0.0133

Platt mejora la escala, no el ranking. La matriz calibrada contiene 1 630 TN, 380 FP, 72 FN y 150 TP. El mayor recall se obtiene a costa de más falsas alertas; no se presenta

como desempeño excelente.

10.2. Capacidad de ordenamiento

Las curvas de la figura 20 separan la capacidad de ordenamiento del punto de decisión. La curva precisión-recall se lee contra la prevalencia de 0.099: la precisión se mantiene entre 0.30 y 0.40 en el rango de recall 0.2–0.7, es decir, tres a cuatro veces la línea base, pero nunca alcanza valores altos. La curva ROC muestra el comportamiento típico de una señal moderada, con la mayor ganancia concentrada en el primer 20 % de falsos positivos.




Figura 20: Curvas precisión-recall y ROC sobre los scores crudos de la referencia histórica. El punto de operación corresponde al umbral 0.65 fijado en 2023: recall 0.604 con precisión 0.302, sobre una tasa de falsos positivos de 0.154.

10.3. Calibración y estructura del error

La figura 21 contrasta ambas escalas de probabilidad. La sigmoide cruda es sistemáticamente optimista: en todos los bins la frecuencia observada queda por debajo de la diagonal, con ECE 0.2338. Tras Platt, los bins con soporte suficiente se alinean con la diagonal y el ECE baja a 0.0133. Los bins superiores de la escala calibrada reúnen entre 1 y 9 registros, por lo que su desviación aparente no es evidencia de descalibración.

Diagrama de confiabilidad en la referencia histórica 2024-2025




Figura 21: Diagrama de confiabilidad por decil de probabilidad. El tamaño del punto es proporcional al número de registros del bin; se anota n cuando el bin reúne 25 registros o menos.

Matrices de confusión en la referencia histórica 2024-2025 ($n = 2\,232$)




Figura 22: Matrices de confusión en ambas escalas. El umbral calibrado convierte 16 falsos negativos en verdaderos positivos (de 88 a 72) al precio de 71 falsas alertas adicionales (de 309 a 380): el desplazamiento de umbral redistribuye el error, no lo elimina.

Evidencia histórica 2024-2025: comparación en escala cruda




Figura 23: Comparación descriptiva en la referencia histórica 2024–2025 sobre scores crudos. El liderazgo nominal no equivale a superioridad universal.

10.4. Baselines

Las tres líneas base se implementaron con scikit-learn [8] sobre el mismo contrato de variables y la misma política de umbral. El DummyClassifier usa `strategy=prior`: probabilidad constante igual a la prevalencia de entrenamiento, no “clase mayoritaria”. La MLP supera nominalmente a logística y Random Forest en esta referencia. El bootstrap pareado muestra ventaja nominal frente a logística en PR-AUC, ROC-AUC y F1; frente a Random Forest, PR-AUC y ROC-AUC incluyen cero. F1 es la excepción nominal: la diferencia MLP menos Random Forest es +0.0252, con IC 95 % [0.00166, 0.04790], favorable a la MLP. En total se inspeccionan seis comparaciones con IC 95 % nominales, sin ajuste por multiplicidad ni cobertura familiar simultánea. La inferencia es condicional a las predicciones y recetas congeladas; no establece superioridad universal ni incorpora incertidumbre de reentrenamiento.

10.5. Diagnósticos rolling

Los dos outer internos obtienen PR-AUC 0.3459/0.3259, ROC-AUC 0.7961/0.8090 y F1 0.3960/0.3677. La variación entre ventanas confirma que una sola partición no basta y refuerza la necesidad de validación externa.

11. Interfaz gráfica

La interfaz Streamlit [10] es un consumidor de solo lectura. Verifica hashes, ancho 169, orden de variables, esquema y umbrales antes de inferir. El formulario excluye todos los campos PERSONAS y solicita únicamente contexto del registro y agregados VEHICULOS, con advertencia de alcance retrospectivo. La aplicación se organiza en cinco secciones navegables: panorama, inferencia, exploración de datos, patrones regionales y evidencia del modelo.

11.1. Panorama y arquitectura visible

La pantalla inicial (figura 24) declara el alcance del sistema antes de cualquier interacción y expone la arquitectura de la red como una cadena de bloques: 21 campos crudos, 169 características, las dos capas ocultas con su regularización, la calibración Platt externa y la clase estimada. Las tres tarjetas superiores anticipan el tamaño del universo, la prevalencia y la separación lograda, de modo que ninguna métrica aparece sin su referencia.



Figura 24: Sección *Panorama*. La cadena de bloques reproduce la arquitectura canónica del manifiesto; el texto asociado declara 12 993 parámetros y las 9 corridas de la búsqueda, en lugar de presentar el modelo como una caja cerrada.

11.2. Formulario de inferencia

El formulario (figura 25) solicita fecha, hora, ubicación, contexto de vía y agregados VEHICULOS. Las coordenadas son obligatorias y pueden fijarse con un selector cartográfico: el esquema canónico exige ubicación y la aplicación no imputa una localización de forma silenciosa. El pie del bloque de vehículos declara explícitamente por qué PERSONAS está excluida y cuál es el alcance defendible.

Probar la red neuronal

Complete un registro o seleccione uno de los 5 escenarios académicos. La salida es una probabilidad calibrada de multifatalidad y una clase estimada.

Escenario de demostración

TP real 2023 · multifatal correctamente estimado

Cargar escenario

Ubicación

> Elegir la ubicación en el mapa (OpenStreetMap)

Evento y ubicación

Fecha del siniestro	Hora del siniestro	Departamento	Código de vía (opcional)
25/10/2023	02:00	CUSCO	PE-34J

Vía y entorno

Clase de siniestro	Zona	Red vial	Tipo de vía
CHOQUE	RURAL	NACIONAL	CARRETERA
Clima	Característica vial	Perfil longitudinal	Superficie
DESPEJADO	CURVA	PLANA	ASFALTADA

Coordenadas (requeridas)

Latitud	Longitud
-15.142256	-71.122031

Ingrese ambas coordenadas. El esquema canónico exige ubicación para la inferencia final; la app no imputa una localización silenciosamente.

Vehículos registrados

Vehículos involucrados	Buses / minibuses	Pesados de carga	Motos / trimotos / bicis
2	2	0	0
Vehículos no identificados	Servicio interprovincial	Transporte público / taxi	
0	0	2	

Figura 25: Sección *Probar la red* con el escenario TP de 2023 cargado. Los campos reproducen un siniestro real: choque nocturno en carretera nacional rural de Cusco, en curva, con dos vehículos de transporte público involucrados.

11.3. Salida de la red

La decisión visible usa probabilidad Platt y umbral 0.15; la sigmoide cruda y su umbral 0.65 permanecen en un diagnóstico separado y plegado, para que ambas escalas no se confundan. Para el escenario de la figura 26, la red asigna 74.9 % de probabilidad calibrada y estima la clase multifatal, que coincide con lo observado en 2023. El gráfico de contexto sitúa esa estimación junto a las tasas históricas del subgrupo coincidente, la misma clase, la misma zona y el mismo clima, con intervalos Wilson al 95 %: describen tasas agregadas y no se presentan como incertidumbre de la predicción individual.




Figura 26: Resultado de la inferencia. La banda del medidor marca el umbral calibrado; el contexto histórico muestra que la estimación de 74.9 % se aparta de todas las tasas de referencia, que se ubican entre 10 % y 22 %.

Los cinco escenarios están sellados por hash y orden: TN, FP, FN limítrofe y TP reales de 2023, más un clon sintético que cambia solo `CODIGO_VIA` a un código no visto. Para los cuatro reales se separa observado de estimado. El sintético declara verdad no disponible y muestra el delta respecto al clon base, sin lenguaje causal. La carga valida roles, fechas, paridad de predicción y hash; cualquier alteración falla cerrada.

11.4. Evidencia y límites

La sección de evidencia (figura 27) publica las métricas de la referencia histórica con sus intervalos bootstrap y encabeza el bloque con la advertencia de que 2024–2025 ya fue consultado. Debajo reproduce la auditoría de diseño: la ablación de regularización y la comparación entre una y varias redes, con las barras de error que sostienen la decisión de conservar una sola MLP.




Figura 27: Sección *Evidencia del modelo*. Cada métrica aparece con su intervalo de confianza y la prevalencia se declara junto a PR-AUC, de modo que la cifra no pueda leerse contra 0.50 por descuido.

Gráficos y tablas incluyen texto además de color y alternativas descargables. La interfaz conserva navegación por teclado, foco visible, movimiento reducido y diseño responsivo; AppTest recorre la aplicación sin reentrenar ni escribir artefactos.

12. Discusión

La decisión metodológica central condiciona la interpretación del proyecto. PERSONAS no es una familia de variables predictoras legítima sino una fuente estructuralmente contaminada: el conteo de fallecidos por persona reproduce el target. Excluirla reduce las métricas frente a un modelo que la incluyera, pero aumenta de forma decisiva la validez del experimento. Un resultado menor y honesto es científicamente superior a un resultado alto producido por un proxy del desenlace.

La MLP conserva señal por encima de la prevalencia: PR-AUC 0.325 frente a 0.099 y ROC-AUC 0.792. Sin embargo, 380 FP y 72 FN en la escala calibrada impiden describir el modelo como excelente. La calibración es buena en Brier/ECE, pero no resuelve límites de ranking.

VEHICULOS también carece de timestamps por campo. No se detectó identidad directa con el target, pero su disponibilidad operativa no está demostrada; el alcance se

restringe a clasificación histórica retrospectiva. La explicación SHAP es global y estable entre muestras, pero sigue siendo asociativa.

Los IC bootstrap son estrechos solo respecto a remuestreo de filas congeladas. No representan selección, dependencia, referencia reutilizada ni futuro. Los folds rolling internos mejoran la evaluación, pero comparten historia y no sustituyen una cohorte externa/prospectiva. La siguiente evidencia confirmatoria debe definirse antes de abrir nuevas etiquetas.

13. Conclusiones

- Se construyó una única MLP 169–64–32–1 con 12 993 parámetros y técnicas de regularización realmente ejecutadas.
- La arquitectura se seleccionó con 2021/2022, se reajustó en 2021–2022 y se calibró en 2023; dos folds rolling verifican roles cronológicos disjuntos dentro de cada diagnóstico.
- La prueba ejecutable confirmó que PERSONAS reconstruye el objetivo para los 9 104 registros; excluir esa familia fue obligatorio.
- En la referencia 2024–2025 ya consultada, PR-AUC es 0.3254, ROC-AUC 0.7916 y F1 calibrado 0.3989. El desempeño es moderado y se reporta sin sobreestimación.
- La interfaz muestra cinco roles pedagógicos, separa verdad observada de estimación, valida paridad y no ofrece intervalos individuales inexistentes.
- El bundle, las fuentes, las demos, la explicabilidad y el PDF están sellados por contenido.

El artefacto entregado es reproducible y está verificado por contenido. No constituye una validación confirmatoria externa: el proyecto no dispone de una cohorte prospectiva o externa intacta. Esa distinción entre finalización del artefacto e independencia científica es una conclusión, no una nota al pie.

14. Anexos

14.1. Repositorio y estructura del proyecto

El código fuente completo, los datos, el modelo y este informe están versionados en el repositorio público https://github.com/ForLess01/Accident_NN. El cuaderno `notebooks/modelo.ipynb` documenta el proyecto de forma ejecutable y es compatible con Google Colab.

```
Accident_NN/
|-- app/           Interfaz Streamlit (solo lectura del bundle)
|-- data/
|   |-- raw/       Libros oficiales ONSV + manifiesto SHA-256
|   |-- processed/ base_limpia.parquet y casos de demostracion
|   |-- geo/       GeoJSON de departamentos del Peru
|-- docs/          Procedencia y disponibilidad de los datos
|-- models/final/  Bundle canonico: modelo, encoders, calibrador
```

```
|-- notebooks/      modelo.ipynb (cuaderno academico integral)
|-- report/         Informe LaTeX, figuras, tablas y PDF final
|-- scripts/        Construcción del informe y gate de release
|-- src/            Pipeline: auditoria, EDA, entrenamiento
'-- tests/          Suite de regresion (pytest)
```

14.2. Configuración canónica

```
1 canonical = {
2     "version": "canonical-3.0.0",
3     "raw_fields": 21,
4     "features": 169,
5     "hidden_units": [64, 32],
6     "dropout": 0.35,
7     "l2": 3e-4,
8     "learning_rate": 5e-4,
9     "batch_size": 64,
10    "seed": 42,
11    "fixed_refit_epochs": 14,
12    "parameters": 12993,
13    "raw_threshold": 0.65,
14    "calibrated_threshold": 0.15,
15    "calibration": "platt"
16 }
```

14.3. Artefactos de evidencia

- Procedencia: data/raw/source_manifest.json y docs/data_provenance.md.
- Proxy: report/tables/personas_target_proxy_identity.json.
- Curvas/brecha: report/tables/model_learning_curves.csv;
report/tables/model_generalization_gap.json.
- Folds rolling: report/tables/temporal_nested_fold_roles.csv;
report/tables/temporal_nested_outer_metrics.csv.
- Estabilidad SHAP: report/tables/final_explainability_stability.csv.
- Demos: data/processed/demo_cases.csv y su manifiesto.
- PDF: report/build_manifest.json; la frescura depende de hashes, no mtime.

Referencias

- [1] Martín Abadi, Ashish Agarwal, Paul Barham, Eugene Brevdo, Zhifeng Chen, Craig Citro, Greg S. Corrado, Andy Davis, Jeffrey Dean, et al. Tensorflow: Large-scale machine learning on heterogeneous distributed systems. *arXiv preprint arXiv:1603.04467*, 2016. Acceso libre: <https://arxiv.org/abs/1603.04467>.

- [2] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, and W. Philip Kegelmeyer. SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16:321–357, 2002. Acceso libre: <https://www.jair.org/index.php/jair/article/view/10302>.
- [3] François Chollet et al. Keras. Documentación oficial, 2015. <https://keras.io/>.
- [4] Ian Goodfellow, Yoshua Bengio, and Aaron Courville. *Deep Learning*. MIT Press, 2016. Acceso libre: <https://www.deeplearningbook.org/>.
- [5] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014. Acceso libre: <https://arxiv.org/abs/1412.6980>.
- [6] Scott M. Lundberg and Su-In Lee. A unified approach to interpreting model predictions. In *Advances in Neural Information Processing Systems 30*, pages 4765–4774, 2017. Acceso libre: https://proceedings.neurips.cc/paper_files/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html.
- [7] Observatorio Nacional de Seguridad Vial (ONSV), Ministerio de Transportes y Comunicaciones del Perú. Siniestros de tránsito fatales 2021–2025 (preliminar): detalle de siniestros de tránsito con consecuencias fatales ocurridos a nivel nacional. Catálogo de datos abiertos, 2026. Publicado el 2026-02-27; enlace verificado el 2026-07-27. <https://www.onsv.gob.pe/datosabiertos>.
- [8] Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011. Acceso libre: <https://jmlr.org/papers/v12/pedregosa11a.html>.
- [9] Lutz Prechelt. Early stopping—but when? In *Neural Networks: Tricks of the Trade*, pages 55–69. Springer, 1998. Acceso libre: https://page.mi.fu-berlin.de/prechelt/Biblio/stop_tricks1997.pdf.
- [10] Snowflake Inc. Streamlit: A faster way to build and share data apps. Documentación oficial, 2024. <https://streamlit.io/>.
- [11] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov. Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(56):1929–1958, 2014. Acceso libre: <https://jmlr.org/papers/v15/srivastava14a.html>.
- [12] World Health Organization. Road traffic injuries. Fact sheet, 2023. <https://www.who.int/news-room/fact-sheets/detail/road-traffic-injuries>.